
Übungsbuch Angewandte Statistik

Aufgaben und ausführliche Lösungswege
für interdisziplinäre Bachelorstudiengänge

Isabell Fetzer

Impressum

Konzeption, Erstellung & L^AT_EX-Satz:

Isabell Fetzner

Urheberrecht & Eigenständigkeit:

Dieses Übungsbuch sowie alle darin enthaltenen Aufgabenstellungen, Rechenwege und Erläuterungen wurden von Isabell Fetzner eigenständig ausgearbeitet und verfasst.

Haftungsausschluss:

Dieses Übungsbuch entstand auf freiwilliger Basis als begleitendes Zusatz- und Übungsmaterial für eine Bachelorvorlesung an der Technischen Universität Berlin. Alle Aufgaben und Rechenwege wurden eigenständig ausgearbeitet. Für die Richtigkeit, Vollständigkeit und Aktualität der Inhalte wird keine Gewähr übernommen.

Lizenz:

© 2026 Isabell Fetzner. Alle Rechte vorbehalten.

Das Werk einschließlich aller seiner Teile ist urheberrechtlich geschützt. Jegliche Vervielfältigung, kommerzielle Nutzung oder die Einspeicherung in elektronischen Systemen sowie Weitergabe an Dritte ohne schriftliche Genehmigung der Autorin ist untersagt.

Inhaltsverzeichnis

1	Deskriptive Statistik	1
1.1	Grundbegriffe	1
1.2	Empirische Verteilungen diskreter Merkmale	6
1.3	Empirische Verteilungen klassierter Merkmale	14
1.4	Lage-, Streuungs- Formmaße, Varianzzerlegung	28
1.5	Konzentrationsmaße	38
1.6	Bivariate empirische Häufigkeitsverteilungen	49
1.7	χ^2 - und Kontingenzkoeffizient	59
1.8	Korrelationsanalyse	63
2	Wahrscheinlichkeitstheorie	78
2.1	Kombinatorische Grundlagen	78
2.2	Diskrete Zufallsvariablen	89
2.3	Ereignisse und Mengen	104
2.4	Diskrete Verteilungen	116
2.4.1	Bernoulli- und Binomialverteilung	116
2.4.2	Geometrische Verteilung	118
2.4.3	Hypergeometrische Verteilung	118
2.4.4	Poissonverteilung	119
2.4.5	Negative Binomialverteilung	120
2.4.6	Multinomialverteilung	121
2.5	Stetige Verteilungen	150
2.5.1	Stetige Gleichverteilung	150
2.5.2	Exponentialverteilung	152
2.5.3	Normalverteilung	153
2.6	Asymptotische Verteilungen	178

1 Deskriptive Statistik

1.1 Grundbegriffe

Aufgabe 1

Erklären Sie die Begriffe

- a) *Grundgesamtheit, Stichprobe, statistische Einheit und statistische Größe,*
- b) *Merkmalsausprägung, Beobachtung und Urliste.*

Aufgabe 2

Wie lassen sich statistische Größen klassifizieren? Erklären Sie in diesem Zusammenhang die Skalierungsarten.

Aufgabe 3

Eine Forscherin erhebt die monatliche Arbeitszeit neben dem Studium (in Stunden) von Studierenden.

- a) Wie lautet das statistische Merkmal und wie ist es skaliert?
- b) Wie können wir das statistische Merkmal diskretisieren?
- c) Reduzieren Sie die Daten zuerst auf ein ordinales und dann auf ein nominales Skalenniveau, indem Sie sinnvolle neue Ausprägungen bilden. Erläutern Sie kurz, welche Informationen jeweils verloren gehen.

Aufgabe 1 Lösungen

Erklären Sie die Begriffe

a) *Grundgesamtheit, Stichprobe, statistische Einheit, statistische Größe,*

Die *Grundgesamtheit* Ω ist eine Menge von *statistischen Einheiten* e_i (z.B. Individuen), die verschiedene Merkmale aufweisen (z.B. Wohnort, Alter) – diese Merkmale nennen wir *statistische Größen*. Eine *Stichprobe* ist eine Teilmenge der Grundgesamtheit, welche über ein Auswahlverfahren entsteht.

☞ *Synonyme:*

- Grundgesamtheit Ω : Population, statistische Masse
- Stichprobe: Beobachtungsgesamtheit
- i -te statistische Einheit e_i : Merkmalsträger, Proband
- statistische Größe X : statistisches Merkmal, Merkmal

Definition: Statistische Größe

Eine statistische Größe X ist eine *Funktion*, die jedem Element der Grundgesamtheit Ω eine Ausprägung zuordnet

$$X : \Omega \rightarrow A,$$

wobei A die Menge der möglichen Ausprägungen von X ist.

b) *Merkmalsausprägung, Beobachtung und Urliste.*

Eine statistische Größe X (z.B. $X \hat{=}$ Wohnort) kann verschiedene Werte a_j annehmen (z.B. $a_1 =$ „Berlin“, $a_2 =$ „Potsdam“) – diese Werte nennen wir (mögliche) *Ausprägungen*.

Eine Beobachtung x_i ist die erhobene Merkmalsausprägung von der statistischen Einheit e_i – also das was wir beobachten. Man schreibt auch: $X(e_i) = x_i$, wobei x_i die Werte $a_1, \dots, a_k$ annehmen kann (z.B. $X(e_2) = x_2 =$ „Berlin“).

Eine Urliste $(x_1, \dots, x_n)$ im Umfang von n Beobachtungen ist eine unsortierte Folge von Beobachtungen.

Fortsetzung Aufgabe 1b)

☞ *Synonyme:*

- Ausprägung a_j : Merkmalsausprägung, Realisierungsmöglichkeiten
- Beobachtung x_i : realisierte Beobachtung, Beobachtungswert, Realisierung
- Urliste $(x_1, \dots, x_n)$: Stichprobe
- Umfang der Urliste n : Stichprobenumfang, Beobachtungsumfang

Aufgabe 2 Lösungen

Wie lassen sich statistische Größen klassifizieren? Erklären Sie in diesem Zusammenhang die Skalierungsarten.

Klassifizierung einer statistischen Größe X mit $X : \Omega \rightarrow A$

☞ nach *Anzahl aller Ausprägungen* d.h. Mächtigkeit von A :

- Anzahl ist endlich oder abzählbar unendlich, d.h. $|A| < \infty \iff X$ ist diskret
- Anzahl ist nicht abzählbar (überabzählbar), d.h. $|A| = \infty \iff X$ ist stetig⁽¹⁾

☞ nach *Skalierungsart der Ausprägungen a_j von X :*

- a_j sind nominalskaliert
 $\iff$ keine Ordnung der Ausprägungen möglich
- a_j sind ordinalskaliert
 $\iff$ Ordnung möglich, aber keine interpretierbaren Abstände
- a_j sind kardinalskaliert (metrisch)⁽²⁾
 $\iff$ Abstände (und ggf. Verhältnisse) sind interpretierbar

Hinweis:

⁽¹⁾ Ein diskretes Merkmal mit sehr vielen Ausprägungen kann in der Praxis oft als *quasi-stetig* approximiert werden, wenn die Abstände zwischen den Ausprägungen sehr klein sind.

⁽²⁾ Häufig werden die Intervall-, Verhältnis- und Absolutskala, siehe Zusatzkasten auf der nächsten Seite, in der Kardinalskala zusammengefasst.

Quelle: Fahrmeir, L., Heumann, C., Künstler, R., Pigeot, I. & Tutz, G. (2016). Statistik: Der Weg zur Datenanalyse (8. Auflage). Springer Spektrum. S. 16

Beispiele

Statistische Größe	Skalierungsart	diskret/stetig
Farbe eines Shirts	nominal	diskret
Staatsangehörigkeit	nominal	diskret
Wettkampfplatzierungen	ordinal	diskret
Getränkepräferenzen	ordinal	diskret
Anzahl Personen im Raum	kardinal	diskret
Einkommen in Tsd. Euro	kardinal	diskret
Stundenlohn	kardinal	stetig
Körpergröße	kardinal	stetig

Aufgabe 3 Lösungen

Eine Forscherin erhebt die monatliche Arbeitszeit neben dem Studium (in Stunden) von Studierenden.

a) Wie lautet das statistische Merkmal und wie ist es skaliert?

X : „monatliche Arbeitszeit neben dem Studium in Stunden“
 X ist stetig und kardinalskaliert (Verhältnisskala).

💬 *Begründung:*

- X kann (unter der fehlenden Annahme von *ganzen Stunden*) jede nichtnegative reelle Zahl annehmen; Wertebereich von X ist $\mathbb{R}$, also überabzählbar.
- X besitzt einen natürlichen Nullpunkt ($0 \text{ h} \hat{=}$ keine Arbeitszeit); X hat jedoch keine natürliche Maßeinheit

b) Wie können wir das statistische Merkmal diskretisieren?

Wir können die realisierten Stundenzahlen auf die nächste natürliche Zahl runden. Somit betrachten wir die monatliche Arbeitszeit in *ganzen* Stunden.

💬 *Begründung:*

Runden wir auf die nächste natürliche Zahl haben wir nur noch abzählbar unendlich viele mögliche Ausprägungen. Das Merkmal ist somit diskret.

- c) Reduzieren Sie die Daten zuerst auf ein ordinales und dann auf ein nominales Skalenniveau, indem Sie sinnvolle neue Ausprägungen bilden. Erläutern Sie kurz, welche Informationen jeweils verloren gehen.

☞ Ordinalskala:

Studierende geben an, in welcher *Gruppe* sie sich befinden. Mögliche Gruppen (neue Ausprägungen) sind z.B. unter 40 h , 40-80 h, über 80 h. Die Informationen über die Abstände zwischen den Arbeitszeiten gehen verloren, wodurch keine Quotienten- und Differenzbildung mehr möglich ist.

💬 *Begründung:*

Die Ausprägungen (Einkommensgruppen) sind geordnet, aber die Abstände zwischen ihnen sind nicht mehr eindeutig interpretierbar.

☞ Nominalskala:

Studierende geben an, ob ihre auf eine ganze Zahl gerundete Gesamtanzahl an monatlichen Arbeitsstunden gerade oder ungerade ist. Die neuen Ausprägungen sind *gerade* und *ungerade*. Die Informationen über die Rangordnung gehen zusätzlich verloren.

💬 *Begründung:*

Die Ausprägungen (Ja/Nein) sind nicht geordnet, sondern rein qualitativ unterschiedlich.

1.2 Empirische Verteilungen diskreter Merkmale

Aufgabe 4

Teil A

Um zu untersuchen, wie lange Studierende für ihre Bachelorarbeit brauchen, wurden 200 Studierende befragt, die ihre Arbeit im letzten Jahr abgegeben haben. Die Bearbeitungszeit wurde in *ganzen* Wochen gemessen. In der Stichprobe ergaben sich folgende (realisierte) Ausprägungen:

Wochen	10	11	12	13	14	15
relative Häufigkeiten	0,1	0,1	0,4	0,2	0,15	0,05

- Wie heißt die statistische Größe und wie ist diese skaliert?
- Bestimmen Sie die absoluten Häufigkeiten aller realisierten Ausprägungen.
- Skizzieren Sie die relative sowie die absolute Häufigkeitsverteilung der statistischen Größe in einem Stabdiagramm.
- Bestimmen Sie die relativen sowie absoluten kumulierten Häufigkeiten.
- Skizzieren Sie die empirische relative sowie die empirische absolute Verteilungsfunktion der statistischen Größe.
- Wie viele Wochen benötigen die 10% schnellsten Studierenden höchstens?
- Wie viele Wochen benötigen die 80% langsamsten Studierenden mindestens?
- Geben Sie die Wochenanzahl an, die genau 20% der Studierenden benötigen.

Teil B

Sei nun das Merkmal Y „Bearbeitungszeit der Bachelorarbeit“ mit den folgenden Ausprägungen gegeben:

- „schnell“, falls weniger als 12 Wochen Bearbeitungszeit
 - „normal“, falls genau 12 Wochen Bearbeitungszeit
 - „langsam“, falls mehr als 12 Wochen Bearbeitungszeit
- Bestimmen Sie die Skalierungsart, die absoluten Häufigkeiten der neuen Ausprägungen und skizzieren Sie die absolute Häufigkeitsfunktion in einem geeigneten Diagramm.
 - Konstruieren Sie sich aus dem statistischen Merkmal aus Teil A ein neues Merkmal, welches nominalskaliert ist.

Aufgabe 4 Lösungen

Teil A

Um zu untersuchen, wie lange Studierende für ihre Bachelorarbeit brauchen, wurden 200 Studierende befragt, die ihre Arbeit im letzten Jahr abgegeben haben. Die Bearbeitungszeit wurde in *ganzen* Wochen gemessen. In der Stichprobe ergaben sich folgende (realisierte) Ausprägungen:

Wochen	10	11	12	13	14	15
relative Häufigkeiten	0,1	0,1	0,4	0,2	0,15	0,05

a) Wie heißt die statistische Größe und wie ist diese skaliert?

X : Bearbeitungszeit bis zur Vollendung der Bachelorarbeit in ganzen Wochen
 X ist diskret und kardinalskaliert (Absolutskala).

☺ *Begründung:*

- X kann jede natürliche Zahl annehmen; Wertebereich ist abzählbar.
- X besitzt einen natürlichen Nullpunkt (0 Wochen $\hat{=}$ keine Bearbeitungszeit $\Rightarrow$ keine negativen Werte möglich) sowie eine natürliche Maßeinheit (d.h. eine Maßeinheit mit Werten aus den natürlichen Zahlen (Anzahl))

b) Bestimmen Sie die absoluten Häufigkeiten aller realisierten Ausprägungen.

Für unsere $i = 1, \dots, 6$ in der Stichprobe beobachteten, d.h. realisierten, Ausprägungen a_j gilt:

j	a_j	$f(a_j)$	$h(a_j)$
1	10	0,1	20
2	11	0,1	20
3	12	0,4	80
4	13	0,2	40
5	14	0,15	30
6	15	0,05	10
Σ	—	1,00	$n = 200$

Fortsetzung Aufgabe 4b)


 Notation:

- $h(a_j) = h_j$ bezeichnet die absolute Häufigkeit der Ausprägung a_j , d.h. die Anzahl der x_i aus $x_1, \dots, x_n$ mit $x_i = a_j$.
- $f(a_j) = f_j := \frac{h_j}{n}$ bezeichnet die relative Häufigkeit von der Ausprägung a_j

Quelle: Fahrmeir, L., Heumann, C., Künstler, R., Pigeot, I. & Tutz, G. (2016). Statistik: Der Weg zur Datenanalyse (8. Auflage). Springer Spektrum. S. 30

- c) Skizzieren Sie die relative sowie die absolute Häufigkeitsverteilung der statistischen Größe in einem Stabdiagramm.

Relative und absolute Häufigkeitsverteilung von X



 Notation:

- $h_1, h_2, \dots, h_k$ (die Gesamtheit aller absoluten Häufigkeiten) stellt die *absolute Häufigkeitsverteilung* dar. Sie wird auch *absolute Häufigkeitsfunktion* genannt.
- $f_1, f_2, \dots, f_k$ (die Gesamtheit aller relativen Häufigkeiten) stellt die *relative Häufigkeitsverteilung* dar. Sie wird auch *relative Häufigkeitsfunktion* genannt.

Quelle: Fahrmeir, L., Heumann, C., Künstler, R., Pigeot, I. & Tutz, G. (2016). Statistik: Der Weg zur Datenanalyse (8. Auflage). Springer Spektrum. S. 30

Definition: relative/absolute Häufigkeitsfunktion/-verteilung

Die relative Häufigkeitsfunktion $f(x)$ ordnet jeder möglichen Realisierung x die relative Häufigkeit seines Auftretens in der Urliste zu. Formal lässt sie sich schreiben als

$$f(x) = \begin{cases} f(a_j), & \text{wenn } x = a_j, j = 1, \dots, k, \\ 0, & \text{sonst.} \end{cases}$$

Die Funktion f kann als *empirische Wahrscheinlichkeitsfunktion* einer diskreten statistischen Größe interpretiert werden. Graphisch werden die Ausprägungen a_j auf der x-Achse abgetragen und die entsprechenden relativen Häufigkeiten $f(a_j)$ z.B. als “Stäbe” visualisiert. Die Darstellung unterscheidet sich damit nicht wesentlich von derjenigen der absoluten Häufigkeitsfunktion $h(a_j)$; der Unterschied liegt lediglich in der Skalierung der y-Achse. Eine grundlegende Eigenschaft jeder Häufigkeitsverteilung ist, dass sich die Häufigkeiten über alle möglichen Ausprägungen aufsummieren. Es gilt:

$$\sum_{j=1}^k h(a_j) = n \quad \text{und} \quad \sum_{j=1}^k f(a_j) = 1,$$

d.h. die absoluten Häufigkeiten ergeben den Stichprobenumfang n , während die relativen Häufigkeiten eine normierte Verteilung bilden, deren Gesamtmasse 1 ist.

Quelle: Stocker, T. C., & Steinke, I. (2022). Statistik: Grundlagen und Methodik (2., korrigierte Auflage). De Gruyter Oldenbourg. S.48

d) Bestimmen Sie die relativen sowie absoluten kumulierten Häufigkeiten.


j	a_j	$f(a_j)$	$h(a_j)$	$F(a_j)$	$H(a_j)$
1	10	0,1	20	0,1	20
2	11	0,1	20	0,2	40
3	12	0,4	80	0,6	120
4	13	0,2	40	0,8	160
5	14	0,15	30	0,95	190
6	15	0,05	10	1	200
Σ	—	1,00	$n = 200$	—	—

 *Notation:*

- $F(a_j)$ stellen den Funktionswert von der empirischen relativen Verteilungsfunktion $F(x)$ an dem Punkt a_j dar.
- $H(a_j)$ stellen den Funktionswert von der empirischen absoluten Verteilungsfunktion $H(x)$ an dem Punkt a_j dar.

e) Skizzieren Sie die empirische relative sowie die empirische absolute Verteilungsfunktion der statistischen Größe.

Relative und absolute empirische Verteilungsfunktion von X



 *Notation:*

- $F(x)$ bezeichnet die *relative empirische Verteilungsfunktion*.
- $H(x)$ bezeichnet die *absolute empirische Verteilungsfunktion*.

Definition: Empirische relative Verteilungsfunktion $F(x)$ für die Urliste

Die *empirische Verteilungsfunktion* $F(x)$ eines kardinal-diskreten statistischen Merkmals X gibt für jedes $x \in \mathbb{R}$ den Anteil der Beobachtungen in der Urliste $(x_1, \dots, x_n)$ an, deren realisierte Ausprägung kleiner oder gleich x ist. Sie lässt sich darstellen als

$$F(x) = \sum_{j: a_j \leq x} f(a_j), \quad \text{für alle } x \in \mathbb{R},$$

wobei die Summe über alle j läuft, für die $a_j \leq x$ gilt. $F(x)$ bleibt zwischen den realisierten Ausprägungen a_j konstant, sodass sich eine Treppenfunktion ergibt, die bei jedem a_j “nach oben” springt. Sie besitzt folgende Eigenschaften:

- F ist monoton steigend (nicht streng!) in $x \in \mathbb{R}$.
- $F(x) = 0$ für alle $x < a_{(1)}$, wobei $a_{(1)}$ die kleinste realisierte Ausprägung in der Urliste bezeichne.
- $F(x) = 1$ für alle $x \geq a_{(k)}$, wobei $a_{(k)}$ die größte realisierte Ausprägung in der Urliste bezeichne.
- Die Sprungstellen liegen bei den Ausprägungen a_j .
- Die Sprunghöhen entsprechen den relativen Häufigkeiten $f(a_j) = F(a_j) - \lim_{x \uparrow a_j} F(x)$.

Quelle: Stocker, T. C., & Steinke, I. (2022). Statistik: Grundlagen und Methodik (2., korrigierte Auflage). De Gruyter Oldenbourg. S.49

f) Wie viele Wochen benötigen die 10% schnellsten Studierenden höchstens?

10 Wochen, siehe Tabelle in 4d) oder Skizze in 4e)

g) Wie viele Wochen benötigen die 80% langsamsten Studierenden mindestens?

12 Wochen, siehe Tabelle in 4d) oder Skizze in 4e)

h) Geben Sie die Wochenanzahl an, die genau 20% der Studierenden benötigen.

13 Wochen, siehe Tabelle in 4d) oder Skizze in 4c)

Teil B

Sei nun das Merkmal Y „Bearbeitungszeit der Bachelorarbeit“ mit den folgenden Ausprägungen betrachtet:

- “schnell”, falls weniger als 12 Wochen Bearbeitungszeit
- “normal”, falls genau 12 Wochen Bearbeitungszeit
- “langsam”, falls mehr als 12 Wochen Bearbeitungszeit


- i) Bestimmen Sie die Skalierungsart, die absoluten Häufigkeiten der neuen Ausprägungen und skizzieren Sie die absolute Häufigkeitsfunktion in einem geeigneten Diagramm.

Y ist ordinalskaliert.

☺ *Begründung:*

- Wir können zwischen Gleichheit und Ungleichheit unterscheiden sowie eine Rangordnung bilden.
- Differenzen und Quotienten können nun nicht mehr sinnvoll gebildet werden.

Absolute Häufigkeitsfunktion von Y



- j) Konstruieren Sie sich aus dem statistischen Merkmal X (Teil A) ein neues Merkmal, welches nominal skaliert ist.

Sei Z : „Bachelorarbeit in Soll-Zeit (12 Wochen) abgeschlossen“

$$\text{mit } Z := \begin{cases} 1, & \text{falls } X = 12 \\ 0, & \text{sonst,} \end{cases}$$

wobei $\{Z = 1\} \hat{=} Ja$ und $\{Z = 0\} \hat{=} Nein$.⁽¹⁾

☞ *Begründung:*

Wir können nur noch zwischen Gleichheit und Ungleichheit unterscheiden. Rangordnung, Differenzen und Quotienten können nicht mehr gebildet werden.


Hinweis:

⁽¹⁾ Ein diskretes Merkmal, das nur die Ausprägungen 0 und 1 annimmt, wird als *dichotomes* oder *binäres Merkmal* bezeichnet. In der Praxis spricht man auch von einer *Dummy-Variable*.

1.3 Empirische Verteilungen klassierter Merkmale

Aufgabe 5

In Berlin wurden 4000 Bewohner mit $50m^2$ Wohnfläche nach der Höhe ihrer Monatsmiete (in EUR) befragt. Um eine bessere Übersicht zu erhalten, wurden die Mietbeträge in Gruppen eingeteilt. Es ergab sich folgendes Histogramm:



- Wie lautet das *zugrundeliegende* statistische Merkmal und wie ist es skaliert?
- Beschreiben Sie das Prinzip der Flächentreue.
- Welche Annahme über die Verteilung innerhalb der Gruppen wurde durch das Histogramm vorgegeben?
- Zeichnen Sie die zum Histogramm gehörende empirische relative Verteilungsfunktion mithilfe nachfolgender Tabelle.

j	von g_{j-1} bis g_j	f_j	$F(x)$	h_j	b_j	$\tilde{f}_j$	m_j	$m_j \cdot h_j$
Σ	-		-		-	-	-	

- Lesen sie den Wert $F(1300)$ aus dem Histogramm und der empirischen relativen Verteilungsfunktion ab. Interpretieren Sie das Ergebnis im Kontext der Aufgabe.
- Berechnen Sie die Werte der empirischen relativen Verteilungsfunktion für die folgenden Beobachtungen:

i) $x_1 = 1000$


ii) $x_2 = 1300$

iii) $x_3 = 1950$

- g) Lesen Sie den Mietpreis ab, der
- i) von den teuersten 70% der 50 m^2 Wohnungen mindestens erreicht wird.
 - ii) von den günstigsten 70% der 50 m^2 Wohnungen höchstens erreicht wird.
- h) Berechnen Sie das arithmetische Mittel und interpretieren Sie das Ergebnis im Kontext der Aufgabe.

Aufgabe 6


Für das monatliche Einkommen (in Tsd. EUR) der 2000 Angestellten eines Unternehmens erhielt man folgende empirische relative Verteilungsfunktion $F(x)$.



- a) Wie heißt die *zugrundeliegende* statistische Größe und wie ist sie skaliert?
- b) Welche Annahme treffen wir, um die empirische relative Verteilungsfunktion zwischen den Gruppengrenzen stückweise linear interpolieren zu dürfen?
- c) Zeichnen Sie das zur empirischen relativen Verteilungsfunktion gehörende Histogramm mithilfe einer geeigneten Tabelle.
- d) Wie groß ist der relative Anteil der Angestellten, die monatlich
- i) genau 6400 EUR ii) weniger als 6400 EUR iii) mehr als 6400 EUR
- verdienen?

Aufgabe 5 Lösungen

In Berlin wurden 4000 Bewohner mit $50m^2$ Wohnfläche nach der Höhe ihrer Monatsmiete (in EUR) befragt. Um eine bessere Übersicht zu erhalten, wurden die Mietbeträge in Gruppen eingeteilt. Es ergab sich folgendes Histogramm:



a) Wie lautet das *zugrundeliegende* statistische Merkmal und wie ist es skaliert?

X : „Monatsmiete einer $50m^2$ großen Wohnung in Berlin (in EUR)“

X ist stetig und kardinalskaliert (Verhältnisskala).

☺ *Begründung:*

– X kann jede positive reelle Zahl annehmen; Wertebereich ist überabzählbar, d.h.

$$X : \Omega \rightarrow \mathbb{R}_0^+$$

– X besitzt einen natürlichen Nullpunkt (0 EUR entspricht keiner Miete), jedoch keine eindeutig festgelegte („natürliche“) Maßeinheit (da EUR und Cent möglich).

Definition: zugrundeliegendes statistisches Merkmal

Wenn im Rahmen dieses Werkes vom *zugrundeliegenden statistischen Merkmal* gesprochen wird, ist stets das Merkmal *vor der Gruppierung/ Klassierung* gemeint. Durch die Gruppierung wird das Merkmal zunächst diskretisiert. Ohne weitere Annahmen liegt somit ein diskretes Merkmal vor. Nun werden implizit oder explizit Verteilungsannahmen innerhalb der einzelnen Gruppe getroffen (siehe Aufgabe 5c), z.B.:

- stetige Gleichverteilung innerhalb der Gruppe (führt zu einem stetigen Merkmal),
- Einpunktverteilung auf der Gruppenmitte (führt zu einem diskreten Merkmal).

Die Verteilungsart (diskret bzw. stetig) legt fest, ob das Merkmal nach dieser Annahme diskret oder stetig ist. Damit ergibt sich folgender konzeptioneller Ablauf:

- (1) zugrundeliegendes Merkmal (ungruppiert)
 - (2) gruppiertes Merkmal ohne Verteilungsannahme (diskret)
 - (3) gruppiertes Merkmal mit Verteilungsannahme

b) Beschreiben Sie das Prinzip der Flächentreue.

Das *Prinzip der Flächentreue* besagt, dass die Flächen der dargestellten Balken den relativen bzw. absoluten Häufigkeiten der jeweiligen Gruppen in der Urliste entsprechen.

☺ *Begründung:*

Damit dies gewährleistet ist, wird auf der y-Achse nicht direkt die relative Häufigkeit f_j der Klasse j abgetragen. Stattdessen wird diese durch die Klassenbreite b_j normiert. Die Höhe des Balkens ergibt sich somit als $\tilde{f}_j := \frac{f_j}{b_j}$.

Die Fläche eines Balkens ist dann gegeben durch

$$\text{Fläche} = b_j \cdot \tilde{f}_j = f_j,$$

sodass das Prinzip der Flächentreue erfüllt ist. Das Prinzip der Flächentreue gewährleistet, dass die Summe der Balkenflächen gleich 1 ist.

c) Welche Annahme über die Verteilung innerhalb der Gruppen wurde durch das Histogramm vorgegeben?


Es wird eine *stetige Gleichverteilung innerhalb jeder Gruppe* angenommen.

☺ *Begründung:*

Im Histogramm wird die um die Gruppenbreite reskalierte relative Häufigkeit einer Gruppe $\tilde{f}_j$ als konstant dargestellt (waagrechte Linie innerhalb einer Gruppe). Das bedeutet, dass *innerhalb einer Gruppe eine Gleichverteilung der Beobachtungen* angenommen wird. Diese Annahme wird *für alle Gruppen* getroffen.

⚠ *Vorsicht!*

Zwischen den Gruppen kann sich die reskalierte relative Häufigkeit $\tilde{f}_j$ unterscheiden, wir nehmen also keine (!) Gleichverteilung über alle Beobachtungen an.



Hinweis:

Sei für die Beobachtungen innerhalb jeder Gruppe j eine stetige Gleichverteilung angenommen. Sei dazu $\tilde{X}_j$: „Mietpreis in Gruppe j “ die statistische Größe, die den Mietpreis innerhalb der Gruppe j beschreibt. Dann gilt per Annahme: $\tilde{X}_j \sim \text{Uniform}([g_{j-1}, g_j])$ mit Dichte $f_{\tilde{X}_j}(x) = \frac{1}{g_j - g_{j-1}} \mathbb{1}_{[g_{j-1}, g_j]}(x) = \frac{1}{b_j} \mathbb{1}_{[g_{j-1}, g_j]}(x)$, wobei $b_j = g_j - g_{j-1}$ die Gruppenbreite ist. Die neue statistische Größe $X \hat{=}$ „Mietpreis (nach Gruppierung)“ wird als Mischung der Gruppenverteilungen modelliert. Ihre (empirische) Dichte ergibt sich als konvexe Kombination der Gruppen-Dichten mit Gewichten f_j (relative Häufigkeiten): $f_X(x) = \sum_{j=1}^k f_j \cdot f_{\tilde{X}_j}(x) = \sum_{j=1}^k f_j \cdot \frac{1}{b_j} \mathbb{1}_{[g_{j-1}, g_j]}(x)$, $x \in \mathbb{R}$. Da $f_j \geq 0$ und $\sum_{j=1}^k f_j = 1$ gilt, ist f_X eine gültige (empirische) Dichtefunktion. Insbesondere folgt $\int_{\mathbb{R}} f_X(x) dx = 1$, d.h. die Gesamtfläche unter dem Histogramm/ der (empirischen) Dichtefunktion beträgt 1.

- d) Zeichnen Sie die zum Histogramm gehörende empirische relative Verteilungsfunktion mithilfe nachfolgender Tabelle.

j	von g_{j-1} bis g_j	f_j	$F(x)$	h_j	b_j	$\tilde{f}_j$	m_j	$m_j \cdot h_j$
1	[800 ; 1000)	0,3	0,3	1200	200	0,0015	900	1080000
2	[1000 ; 1400)	0,4	0,7	1600	400	0,0010	1200	1920000
3	[1400 ; 1500)	0,2	0,9	800	100	0,0020	1450	1160000
4	[1500 ; 2000]	0,1	1,0	400	500	0,0002	1750	700000
Σ	-	1,0	-	$n = 4000$	-	-	-	4860000

 *Notation:*


- j gibt den Index der Gruppe an, welches als Intervall durch die untere Gruppengrenze g_{j-1} und die obere Gruppengrenze g_j aufgespannt wird.
- $f_j := f([g_{j-1}; g_j])$ bzw. $f_j := f([g_{j-1}; g_j])$ ist die relative Häufigkeit von j .
- $h_j := h([g_{j-1}; g_j])$ bzw. $h_j := h([g_{j-1}; g_j])$ ist die absolute Häufigkeit von j .
- $b_j := g_j - g_{j-1}$ ist die Gruppenbreite.
- $\tilde{f}_j := \frac{f_j}{b_j}$ gibt die *um die Gruppenbreite b_j reskalierte relative Häufigkeit* an.
- m_j bezeichnet die Mitte der j -ten Gruppe und ist definiert als das arithmetische Mittel der beiden Gruppengrenzen: $m_j := \frac{g_{j-1} + g_j}{2}$.
- Das Produkt $m_j \cdot h_j$ approximiert die Merkmalssumme der j -ten Gruppe unter der Annahme einer *stetigen* Verteilung innerhalb dieser Gruppe. Für den Fall, dass zusätzlich angenommen wird, dass die stetige Verteilung um die Gruppenmitte m_j symmetrisch ist (wie z.B. bei der stetigen Gleichverteilung), gilt Gleichheit.

 *Interpretation* von $m_j \cdot h_j$ im Kontext der Aufgabe:

Für alle $h_1 = 1200$ Bewohner (aus Gruppe $j = 1$) mit einer $50m^2$ Wohnung und einer durchschnittlichen Monatsmiete von $m_1 = 900$ EUR betragen die gesamten Mietausgabe $m_j \cdot h_j = 1,08$ Mio EUR (unter der Annahme der stetigen Gleichverteilung innerhalb der Gruppe $j = 1$).

Hinweis:

Die zugrunde liegende statistische Größe X („Mietpreis in EUR“) ist ursprünglich kardinal-stetig und liegt ungruppiert vor. Durch die Gruppierung in der tabellarischen Darstellung wird sie implizit nun als ordinal-diskrete Größe behandelt, vgl. Fahrmeir, L., Heumann, C., Künstler, R., Pigeot, I. & Tutz, G. (2016). Statistik: Der Weg zur Datenanalyse (8. Auflage). Springer Spektrum. S. 17 (Beispiel „Altersgruppen für das Ferienprogramm“). Unter der Annahme einer stetigen Gleichverteilung innerhalb der Gruppen wird X bei der grafischen Darstellung (z.B. im Histogramm) wieder zu einer kardinal-stetigen Größe, diesmal aber gruppiert.



Definition: Empirische relative Verteilungsfunktion $F(x)$ für gruppierte Daten

Die empirische Verteilungsfunktion $F(x)$ eines kardinal-stetigen Merkmals X bei gruppierten Daten mit der Verteilungsannahme einer stetigen Gleichverteilung innerhalb der Gruppen ist wie folgt definiert:



$$F(x) = \begin{cases} 0, & \text{für } x < g_0, & \text{('Randfall')} \\ F(g_{j-1}) + (x - g_{j-1}) \cdot \tilde{f}_j, & \text{für } x \in [g_{j-1}, g_j) \\ 1 & \text{für } x \geq g_k & \text{('Randfall')} \end{cases}$$

Notation:

- Wir nehmen hier k Gruppen an, also $j = 1, \dots, k$.
- Die Untergrenze von Gruppe j bezeichnen wir mit g_{j-1} ; die Obergrenze mit g_j .
- In der Tabelle werden die Randfälle häufig nicht abgetragen. Diese gehören aber zu $F(x)$ in der Skizze dazu!
- Für die letzte Gruppe setzen wir die Gruppengrenzen in der Tabelle zu $[g_{k-1}, g_k]$.



$F(x)$ besitzt folgende Eigenschaften:

- $F(x)$ ist monoton (nicht streng!) steigend in $x \in \mathbb{R}$.
- $0 \leq F(x) \leq 1$.
- $F(x) \rightarrow 0$ für $x \rightarrow -\infty$, $F(x) \rightarrow 1$ für $x \rightarrow \infty$. (
- Bei einer stetigen Verteilungsfunktion ändert sich der Funktionswert nur über Intervalle hinweg. Unter einem einzelnen Punkt liegt keine Fläche!
- $F(b) - F(a) =$ "relative Häufigkeit aller Beobachtungen $x \in [a, b]$ ", und im Spezialfall $x \in [g_{j-1}, g_j)$ gilt: $F(g_j) - F(g_{j-1}) = f_j$.



Interpretation:

$F(x_0)$ gibt den relativen Anteil aller Beobachtungen in der Stichprobe an, deren Merkmalswert *höchstens* x_0 beträgt. Damit beschreibt $F(x_0)$ die *kumulierte relative Häufigkeit* aller Beobachtungen bis zu x_0 . Graphisch entspricht dies der Fläche unter dem Histogramm der statistischen Größe X bis zur Stelle x_0 .



🔗 *Intuition* hinter der obigen Definition von $F(x)$:


Wir integrieren ab der unteren Gruppengrenze g_{j-1} , weil die Flächen der vorherigen Gruppen bereits in $F(g_{j-1})$ enthalten sind. Das Integral addiert nun die zusätzliche Fläche innerhalb der aktuellen Gruppe j bis x_0 .

$$\begin{aligned} F(x_0) &= F(g_{j-1}) + \int_{g_{j-1}}^{x_0} \tilde{f}_j \, dx \quad (\text{da } \tilde{f}_j \text{ konstant gilt } \int \tilde{f}_j \, dx = \tilde{f}_j \cdot x) \\ &= F(g_{j-1}) + \left[\tilde{f}_j \cdot x \right]_{g_{j-1}}^{x_0} \\ &= F(g_{j-1}) + (x_0 - g_{j-1}) \cdot \tilde{f}_j, \quad \text{für alle } x_0 \in [g_{j-1}, g_j), \end{aligned}$$

Bilden wir die Stammfunktion von $\tilde{f}_j$ für Gruppe j , so erhalten wir eine *lineare* Funktion mit Steigung $\tilde{f}_j$ — das ist unser “Funktionsabschnitt” für Gruppe j in der Definition von $F(x)$ für alle $x \in [g_{j-1}, g_j)$:

$$\int \tilde{f}_j \, dx = \tilde{f}_j \cdot x + c,$$

wobei wir die Integrationskonstante c hier der Einfachheit halber vernachlässigen. Die Steigung der blauen Geraden (rechts) entspricht $\tilde{f}_1$, also der Höhe des Balkens von Gruppe $j = 1$ im Histogramm (links).




Das ist äquivalent zu einer *linearen Interpolation* der empirischen Verteilungsfunktion zwischen den Gruppengrenzen: Man verbindet für jede Gruppe j die Punkte $(g_{j-1}, F(g_{j-1}))$ und $(g_j, F(g_j))$ jeweils durch eine Gerade, wodurch eine lineare Funktion innerhalb Gruppe entsteht — und insgesamt die stückweise lineare Funktion $F(x)$. Entsprechend ergibt sich die Steigung innerhalb einer Gruppe auch direkt über

$$\frac{F(g_j) - F(g_{j-1})}{g_j - g_{j-1}} = \frac{f_j}{b_j} = \tilde{f}_j.$$

- e) Lesen sie den Wert $F(1300)$ aus dem Histogramm und der empirischen relativen Verteilungsfunktion ab. Interpretieren Sie das Ergebnis im Kontext der Aufgabe.

$F(1300)$ stellt die *kumulierte relative Häufigkeit* aller Beobachtungen bis zu $x = 1300$ dar und entspricht der Fläche unter dem Histogramm bis zu diesem Wert:



🧩 Interpretation von $F(1300)$ im Kontext der Aufgabe:

60% der befragten Bewohner zahlen eine Miete von **höchstens** (d.h. weniger oder genau) 1,300 EUR. Es bedeutet nicht (!), dass 60% der befragten Bewohner eine Miete von *genau* 1,300 EUR zahlen.

- f) Berechnen Sie die Werte der empirischen relativen Verteilungsfunktion für die folgenden Beobachtungen:

i) $x_1 = 1000$

ii) $x_2 = 1300$

iii) $x_3 = 1950$

Für $x \in [g_{j-1}, g_j)$ gilt: $F(x) = F(g_{j-1}) + (x - g_{j-1}) \cdot \tilde{f}_j$ mit $f_j = \frac{\tilde{f}_j}{b_j}$, also

- i) Da $x = 1000 \in [1000; 1400)$, d.h. in Gruppe $j = 2$ gilt

$$\begin{aligned} F(1000) &= F(g_{2-1}) + (1000 - g_{2-1}) \cdot \tilde{f}_2 \\ &= F(1000) + (1000 - 1000) \cdot 0,0010 \\ &= 0,3 + 0 \end{aligned}$$

ii) Da $x = 1300 \in [1000; 1400]$, d.h. in Gruppe $j = 2$ gilt

$$\begin{aligned} F(1300) &= F(g_{2-1}) + (1300 - g_{2-1}) \cdot \tilde{f}_2 \\ &= F(1000) + (1300 - 1000) \cdot 0,0010 \\ &= 0,3 + 0,3 = 0,6 \end{aligned}$$

iii) Da $x = 1950 \in [1500; 2000]$, d.h. in Gruppe $j = 4$ gilt

$$\begin{aligned} F(1950) &= F(g_{4-1}) + (1950 - g_{4-1}) \cdot \tilde{f}_4 \\ &= F(1500) + (1950 - 1500) \cdot 0,0002 \\ &= 0,9 + 0,09 = 0,99 \end{aligned}$$

g) Lesen Sie den Mietpreis ab, der

- i) von den teuersten 70% der 50 m^2 Wohnungen mindestens erreicht wird.
- ii) von den günstigsten 70% der 50 m^2 Wohnungen höchstens erreicht wird.

i) 1000 EUR und ii) 1400 EUR

 *Intuition:*

Es ist in i) nach dem 30% Quantil und in ii) nach dem 70% Quantil gefragt.

h) Berechnen Sie das arithmetische Mittel und interpretieren Sie das Ergebnis im Kontext der Aufgabe.

Es gilt

$$\bar{x} = \sum_{j=1}^4 m_j \cdot f_j = \frac{1}{n} \sum_{j=1}^4 m_j \cdot h_j = \frac{1}{4000} \cdot 4.860.000 = 1215,$$

 *Interpretation* von $\bar{x}$ im Kontext der Aufgabe:

Unter den 4.000 Befragten beträgt die durchschnittliche Monatsmiete für eine 50 m^2 Wohnung in Berlin 1.215 EUR.

Definition: Arithmetisches Mittel

- Für n Beobachtungen (Rohdaten) einer kardialen (ungruppierten) statistischen Größe X gilt für das arithmetische Mittel stets:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i. \quad (1)$$

- Falls X kardial-diskret ist und nicht die Urliste, sondern die absoluten bzw. relativen Häufigkeiten der $j = 1, \dots, k$ realisierten Ausprägungen a_j vorliegen:

$$\bar{x} = \frac{1}{n} \sum_{j=1}^k a_j \cdot h_j = \sum_{j=1}^k a_j \cdot f_j \quad (2)$$

- Falls X gruppiert vorliegt und innerhalb der Gruppen eine stetige Verteilung unterstellt wird, gilt unter Vorgabe absoluter oder relativer Gruppenhäufigkeiten für die $j = 1, \dots, k$ Gruppen mit Gruppenmitte m_j :

$$\bar{x} \approx \frac{1}{n} \sum_{j=1}^k m_j \cdot h_j = \sum_{j=1}^k m_j \cdot f_j. \quad (3)$$

Die Approximation entsteht dadurch, dass alle Beobachtungen einer Gruppe durch die jeweilige Gruppenmitte m_j ersetzt werden. Wird zusätzlich angenommen, dass die Verteilung innerhalb jeder Gruppe symmetrisch um m_j ist, gilt die Gleichheit (=) in (3). Die stetige Gleichverteilung ist ein Spezialfall dieser Annahme. Bei stark schiefen Verteilungen innerhalb der Gruppen kann die Approximation deutlich vom exakten arithmetischen Mittel abweichen.


Hinweis:

Formel (3) beschreibt eine Approximation des arithmetischen Mittels in einer vorliegenden endlichen Stichprobe (nicht der zugrundeliegenden Grundgesamtheit!) unter einer (impliziten) Verteilungsannahme (z.B. stetige Gleichverteilung) innerhalb der Gruppen. Dabei wird die wahre Verteilung von X (innerhalb der Gruppen) durch ein vereinfachtes Modell ersetzt. Formel (3) kann daher auch im Falle unterstellter Symmetrie um m_j als modellbasierte Approximation interpretiert werden (Modell Bias).

Quelle: Stocker, T. C., & Steinke, I. (2022). Statistik: Grundlagen und Methodik (2., korrigierte Auflage). De Gruyter Oldenbourg. S. 61

Aufgabe 6 Lösungen

Für das monatliche Einkommen (in Tsd. EUR) der 2.000 Beschäftigten eines Unternehmens erhielt man folgende empirische relative Verteilungsfunktion $F(x)$.



a) Wie heißt die *zugrundeliegende* statistische Größe und wie ist sie skaliert?

X : „Monatliches Einkommen eines Angestellten (in Tsd. EUR)“
 X ist stetig und kardinalskaliert (Verhältnisskala).


b) Welche Annahme treffen wir, um die empirische relative Verteilungsfunktion zwischen den Gruppengrenzen stückweise linear interpolieren zu dürfen?

stetige Gleichverteilung innerhalb der Gruppen

- c) Zeichnen Sie das zur empirischen relativen Verteilungsfunktion gehörende Histogramm mithilfe einer geeigneten Tabelle.

j	von g_{j-1} bis g_j	f_j	$F(x)$	b_j	$\tilde{f}_j$
1	[1 ; 3)	0,15	0,15	2	0,075
2	[3 ; 4)	0,25	0,40	1	0,250
3	[4 ; 5)	0,30	0,70	1	0,300
4	[5 ; 6)	0,15	0,85	1	0,150
5	[6 ; 8)	0,10	0,95	2	0,050
6	[8 ; 10]	0,05	1,00	2	0,025
Σ	-	1,00	-	-	-

Histogramm



- d) Wie groß ist der relative Anteil der Angestellten, die monatlich
i) genau 6400 EUR ii) weniger als 6400 EUR iii) mehr als 6400 EUR verdienen?

- i) 0, weil X stetig (keine Fläche unter Einpunkt).
ii) $F(6,4) = F(6) + (6,4 - 6) \cdot 0,050 = 0,87$, da nach den kumulierten relativen Anteil bis $x = 6,4$ gefragt ist (also für alle $x \leq 6,4$).
iii) $1 - F(6,4) = 1 - 0,87 = 0,13$, da wir aus dem Prinzip der Flächentreue folgern können, dass die Gesamtfläche des Histogramms 1 beträgt.

1.4 Lage-, Streuungs- Formmaße, Varianzzerlegung

Aufgabe 7

Teil A

Mia soll für den Online-Shop „Uni A Campus Merch“ eine deskriptive Datenanalyse über den Umsatz des Oktobers diesen Jahres erstellen. Dafür hat sie alle Bestellungen nach ihrer Bestellhöhe (in EUR) gruppiert und ausgewertet. Sie geht davon aus, dass sich die Bestellwerte gleichmäßig innerhalb einer Gruppe verteilt sind. Zur besseren Übersicht hat Mia folgende Tabelle erstellt:

j	von g_{j-1} bis g_j	f_j	$F(x)$	h_j	b_j	$\tilde{f}_j$	m_j	$m_j \cdot h_j$
1	[0; 20)	0,15	0,15	15	20	0,0075	10	150
2	[20; 50)	0,30	0,45	30	30	0,0100	35	1050
3	[50; 150)	0,45	0,90	45	100	0,0045	100	4500
4	[150; 300]	0,10	1,00	10	150	0,0007	225	2250
Σ	-	1,00	-	$n = 100$	-	-	-	7950

- Berechnen Sie die empirischen Quartile, welche notwendig für die Erstellung eines Boxplots sind. Zeichnen Sie den Boxplot sowie den modifizierten Boxplot. Runden Sie auf ganze Zahlen.
- Berechnen Sie die durchschnittliche Bestellhöhe (arithmetisches Mittel). Von welcher Annahme gehen Sie bei dieser Berechnung aus?
- Welche Aussage kann Mia bezüglich der Schiefe der empirischen (relativen) Verteilung mithilfe
 - der Lageregel,
 - des empirischen Quartilkoeffizienten der Schiefe
 treffen. Warum sind unterschiedliche Ergebnisse in i) und ii) möglich?
- Wie weit kann das arithmetische Mittel der Beobachtungen der letzten Gruppe maximal von jenem Wert abweichen, den Sie als Mittelwert dieser Gruppe angenommen haben?

Teil B

Mia beschafft sich zum Vergleich Informationen über den Umsatz des Online-Shops „Uni B Campus Merch“. Die verfügbaren Kennzahlen stammen jedoch aus dem Oktober des Vorjahres; die Betreiber teilen Mia mit, dass dieses Jahr im Oktober die gleichen Bestellungen getätigt wurden, jedoch mit einem 20% Anstieg des Bestellwertes über alle Bestellungen hinweg.

$$95 \text{ Bestellungen} \mid \bar{x}_{B,Vorjahr} = 80 \text{ (EUR)} \mid s_{B,Vorjahr}^2 = 1600 \text{ (EUR)}^2$$

- e) Mia möchte nun anhand der Vorjahreswerte und des Anstiegs der Bestellwerte um 20% das arithmetische Mittel und die Standardabweichung für den Online-Shop „Uni B Campus Merch“ für den Oktober dieses Jahres berechnen.

Teil C

Mia bittet ebenso um Stellungnahme des Online-Shops „Uni C Campus Merch“. Dieser konnte im ganzen Oktober jedoch lediglich fünf Bestellungen verzeichnen. Die Bestellwerte werden wie folgt übermittelt.

Bestellung	1	2	3	4	5
Bestellhöhe (in EUR)	20	120	120	170	2000

- f) Welche Mittelwerte können Sie in diesem Fall eindeutig angeben? Geben Sie diese an.

Eine E-Mail korrigiert die Höhe des Umsatzes der fünften Gruppe auf 20 EUR.

- g) Welchen Mittelwert können Sie nun nicht mehr eindeutig angeben?
- h) Berechnen Sie aus den korrigierten Bestellhöhen das arithmetische Mittel und die Standardabweichung.
- i) Vergleichen Sie die Streuung der Bestellhöhen von „Uni B Campus Merch“ und „Uni C Campus Merch“ mithilfe des Variationskoeffizienten. Verbalisieren Sie das Ergebnis.
- j) Berechnen Sie die durchschnittliche Bestellhöhe (arithmetisches Mittel) in EUR für alle drei Shops zusammen.
- k) Berechnen Sie die empirische Varianz der Bestellhöhe in EUR^2 für alle drei Shops zusammen. Nutzen Sie: $s_A^2 = 4000$
- l) Welcher Anteil der Gesamtvarianz wird durch die Unterschiede zwischen den drei Shops verursacht? Runden Sie auf vier Nachkommastellen.

Aufgabe 7 Lösungen

Teil A

Mia soll für den Online-Shop „Uni A Campus Merch“ eine deskriptive Datenanalyse über den Umsatz des Oktobers diesen Jahres erstellen. Dafür hat sie alle Bestellungen nach ihrer Bestellhöhe (in EUR) gruppiert und ausgewertet. Sie geht davon aus, dass sich die Bestellwerte gleichmäßig innerhalb einer Gruppe verteilt sind. Zur besseren Übersicht hat Mia folgende Tabelle erstellt:

j	von g_{j-1} bis g_j	f_j	$F(x)$	h_j	b_j	$\tilde{f}_j$	m_j	$m_j \cdot h_j$
1	[0; 20)	0,15	0,15	15	20	0,0075	10	150
2	[20; 50)	0,30	0,45	30	30	0,0100	35	1050
3	[50; 150)	0,45	0,90	45	100	0,0045	100	4500
4	[150; 300]	0,10	1,00	10	150	0,0007	225	2250
Σ	-	1,00	-	$n = 100$	-	-	-	7950

- a) Berechnen Sie die empirischen Quartile, welche notwendig für die Erstellung eines Boxplots sind. Zeichnen Sie den Boxplot sowie den modifizierten Boxplot. Runden Sie auf ganze Zahlen.

Es ist:

$$x_{0,25} = 20 + [0,25 - 0,15] \cdot \frac{1}{0,01} = 30$$

$$x_{0,5} = 50 + [0,5 - 0,45] \cdot \frac{1}{0,0045} \approx 61$$

$$x_{0,75} = 50 + [0,75 - 0,45] \cdot \frac{1}{0,0045} \approx 117$$

Weiter gilt:

$$d_q = x_{0,75} - x_{0,25} = 117 - 30 = 87,$$

$$z_u = \max\{x_{\min}; x_{0,25} - 1,5 \cdot d_q\} = \max(0; -100,5) = 0,$$

$$z_o = \min\{x_{\max}; x_{0,75} + 1,5 \cdot d_q\} = \min\{300; 247,5\} \approx 248.$$

Zusatz: p -tes (empirisches) Quantil von X

Die Umkehrfunktion der empirischen Verteilungsfunktion F gruppierter Daten unter der Annahme einer stetigen Gleichverteilung innerhalb der Gruppen heißt für $p \in (0, 1)$ p -Quantilsfunktion. Für $p \in (0, 1)$ sei j die Klasse mit $F(g_{j-1}) < p \leq F(g_j)$. Das empirische p -Quantil ergibt sich durch lineare Interpolation als

$$x_p := g_{j+1} + (p - F(g_{j-1})) \frac{1}{\tilde{f}_j}, \text{ wobei } \frac{1}{\tilde{f}_j} = \frac{b_j}{f_j}, .$$

Quartile sind spezielle Quantile für $p \in \{0,25, 0,5, 0,75\}$. Sie teilen die Verteilung in vier gleich große Teile.

 *Interpretation:*


Das p -te empirische Quantil gibt den Beobachtungswert x_p an, unterhalb dessen ein relativer Anteil von $p \cdot 100$ (%) der Beobachtungen aus der Stichprobe liegen.


 *Intuition* hinter der obigen Definition von x_p :

Wir suchen also den Wert x_p , für den gilt

$$\begin{aligned} p &\stackrel{!}{=} F(x_p) \\ \Leftrightarrow p &\stackrel{!}{=} F(g_{j-1}) + (x_p - g_{j-1}) \cdot \tilde{f}_j \\ \Rightarrow x_p - g_{j-1} &= \frac{p - F(g_{j-1})}{\tilde{f}_j} \quad \text{mit } \tilde{f}_j > 0 \\ \Leftrightarrow x_p &= g_{j-1} + (p - F(g_{j-1})) \frac{1}{\tilde{f}_j} \quad \text{mit } \frac{1}{\tilde{f}_j} = \frac{b_j}{f_j}, \end{aligned}$$

d.h. x_p kann als Inverse der linearen Interpolation innerhalb einer Gruppe ausgedrückt werden.





 Notation:

- x_{min} ist der kleinste Beobachtungswert.
- x_{max} ist der größten Beobachtungswert.
- x_p beschreibt das p -te empirische Quantil, also den Wert x_p , für den gilt $F(x_p) = p$. Die speziellen Quantile $p = 0,25$, $p = 0,5$ und $p = 0,75$ werden auch *Quartile* genannt, da sie die relative Verteilungsfunktion in vier gleich große Teile unterteilen:
 - $x_{0,25}$ ist das *untere/erste Quartil*, also der Beobachtungswert, unter dem 25% aller Beobachtungen liegen.
 - $x_{0,5}$ ist der *Median*, auch mit $\tilde{x}$ bezeichnet, ist der Beobachtungswert unter dem, und über dem 50% aller Beobachtungen liegen.
 - $x_{0,75}$ ist das *obere/dritte Quartil*, also der Beobachtungswert, über dem 25% aller Beobachtungen liegen.
- Der *mittlere Datenkörper* umfasst alle Beobachtungswerte x , die zwischen dem ersten und dritten Quartil liegen, d.h. $x \in [x_{0,25}, x_{0,75}]$.
- $d_q := x_{0,75} - x_{0,25}$ ist der *Interquartilsabstand*. Er gibt die Breite des mittleren Datenkörpers an.
- $[z_u, z_o]$ bilden den *inneren Zaun*:
 - z_u beschreibt den *unteren inneren Zaun*. Falls x_{min} kleiner als $x_{0,25} - 1,5 \cdot d_q$ ist, so gilt $z_u := x_{0,25} - 1,5 \cdot d_q$; falls x_{min} größer als $x_{0,25} - 1,5 \cdot d_q$ ist, so gilt $z_u := x_{min}$. Kurz: $z_u = \max(x_{min}; x_{0,25} - 1,5 \cdot d_q)$
 - z_o beschreibt den *oberen inneren Zaun*, es gilt analog: $z_o = \min\{x_{max}; x_{0,75} + 1,5 \cdot d_q\}$.

- b) Berechnen Sie die durchschnittliche Bestellhöhe (arithmetisches Mittel). Von welcher Annahme gehen Sie bei dieser Berechnung aus?

Unter der Annahme einer *symmetrischen Verteilung der Beobachtungen einer Gruppe j um die jeweilige Gruppenmitte m_j* gilt, dass das arithmetische Mittel aller Beobachtungen einer der Gruppe gleich der Gruppenmittel m_j ist, d.h.

$$\bar{x}_j = m_j.$$

Die Gleichverteilung erfüllt o.g. Annahme, sodass:

$$\bar{x}_{TU} = \frac{1}{n} \sum_{j=1}^4 m_j \cdot h_j = \frac{1}{100} \cdot 7950 = 79,5$$

Zusatz: Beurteilung der Schiefe

☞ nach der *Lageregel*:

Die Lageregel vergleicht (für *unimodale* d.h. *eingipflige* Verteilungen) das ausreißerempfindliche arithmetischen Mittel $\bar{x}$, den ausreißerunempfindlichen Median $x_{0,5}$ und den Modus x_{mod} . Ausreißer werden also bei der Beurteilung der Schiefe berücksichtigt.

$$\bar{x} = x_{0,5} = x_{mod} \Rightarrow \text{symmetrische empirische Verteilung}$$

$$\bar{x} < x_{0,5} < x_{mod} \Rightarrow \text{linksschiefe/rechtssteile empirische Verteilung}$$

$$x_{mod} < x_{0,5} < \bar{x} \Rightarrow \text{rechtsschiefe/linkssteile empirische Verteilung}$$

☞ nach dem *empirischen Quartilkoeffizienten der Schiefe*:

Der empirische Quartilkoeffizienten der Schiefe $g_{0,25}$ setzt die Differenz der Abstände des 3. Quartils und 1. Quartils zum Median ins Verhältnis zum Interquartilsabstand. Die Division durch den Interquartilsabstand erwirkt eine Normierung, so dass $g_{0,25} \in [-1; 1]$ gilt. Dementsprechend wird nur der *mittlere Datenkörper*, d.h. $x \in [x_{0,25}; x_{0,75}]$, berücksichtigt, während Beobachtungen außerhalb nicht mehr berücksichtigt werden.

$$g_{0,25} = 0 \Rightarrow \text{symmetrische empirische Verteilung}$$

$$g_{0,25} < 0 \Rightarrow \text{linksschiefe/rechtssteile empirische Verteilung}$$

$$g_{0,25} > 0 \Rightarrow \text{rechtsschiefe/linkssteile empirische Verteilung}$$

- c) Welche Aussage kann Mia bezüglich der Schiefe der empirischen (relativen) Verteilung mithilfe
- i) der Lageregel,
 - ii) des empirischen Quartilkoeffizienten der Schiefe
- treffen. Warum sind unterschiedliche Ergebnisse in i) und ii) möglich?

i) $\tilde{x} = 61 < 79,5 = \bar{x}_{TU} \Rightarrow$ Die empirische Verteilung ist rechtsschief/linkssteil.

ii) $g_{0,25} := \frac{(x_{0,75} - x_{0,5}) - (x_{0,5} - x_{0,25})}{x_{0,75} - x_{0,25}} = \frac{(117 - 61) - (61 - 30)}{117 - 30} = \frac{25}{87} \approx 0,2874 > 0$
 $\Rightarrow$ Die empirische Verteilung ist rechtsschief/linkssteil.

☺ *Begründung:*

Der Quartilkoeffizient der Schiefe berücksichtigt lediglich den *mittleren Datenkörper*, d.h. alle $x \in [x_{0,25}; x_{0,75}]$, während die Lageregel auch Beobachtungen außerhalb berücksichtigt. Dadurch kann es zu unterschiedlichen Ergebnissen kommen.

- d) Wie weit kann das arithmetische Mittel der Beobachtungen der letzten Gruppe maximal von jenem Wert abweichen, den Sie als Mittelwert dieser Gruppe angenommen haben?

Das arithmetische Mittel kann maximal um ± 75 EUR vom angenommenen Wert abweichen.

☺ *Begründung:*

In Gruppe $j = 4$ liegen die Beobachtungen im Intervall $[150, 300]$ EUR. In Teilaufgabe b) wurde unter der Annahme einer *symmetrischen Verteilung um die Gruppenmitte* der Mittelwert der Gruppe als Gruppenmitte $m_4 = 225$ EUR angenommen ($\bar{x}_4 = m_4 = 225$ EUR). Ohne diese Annahme kann das arithmetische Mittel theoretisch jeden Wert zwischen 150 EUR und 300 EUR annehmen. Die maximale Abweichung beträgt somit: $\pm 0.5 \cdot (300 - 150) = \pm 75$ EUR.

Teil B

Mia beschafft sich zum Vergleich Informationen über den Umsatz des Online-Shops „Uni B Campus Merch“. Die verfügbaren Kennzahlen stammen jedoch aus dem Oktober des Vorjahres; die Betreiber teilen Mia mit, dass dieses Jahr im Oktober die gleichen Bestellungen getätigt wurden, jedoch mit einem 20% Anstieg des Bestellwertes über alle Bestellungen hinweg.

$$95 \text{ Bestellungen} \mid \bar{x}_{B,Vorjahr} = 80 \text{ (EUR)} \mid s_{B,Vorjahr}^2 = 1600 \text{ (EUR)}^2$$

- e) Mia möchte nun anhand der Vorjahreswerte und des Anstiegs der Bestellwerte um 20% das arithmetische Mittel und die Standardabweichung für den Online-Shop „Uni B Campus Merch“ für den Oktober dieses Jahres berechnen.

Für alle Beobachtungen aus dem Oktober dieses Jahres, x_i , gilt $x_i = 1,2 \cdot x_i^{Vorjahr}$, $i = 1, \dots, 95$ und damit:

$$\bar{x}_B = \frac{1}{95} \sum_{i=1}^{95} x_i = \frac{1}{95} \sum_{i=1}^{95} 1,2 \cdot x_i^{Vorjahr} = 1,2 \cdot \bar{x}_{B,Vorjahr} = 1,2 \cdot 80 = 96 \text{ EUR}$$

$$\begin{aligned} s_B^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_B)^2 = \frac{1}{n} \sum_{i=1}^n (1,2 \cdot x_i^{Vorjahr} - 1,2 \cdot \bar{x}_{B,Vorjahr})^2 \\ &= 1,2^2 \cdot \frac{1}{n} \sum_{i=1}^n (x_i^{Vorjahr} - \bar{x}_{B,Vorjahr})^2 = 1,2^2 \cdot s_{B,Vorjahr}^2 = 2304 \text{ EUR}^2 \end{aligned}$$

$$\Rightarrow s_B = \sqrt{s_B^2} = \sqrt{2304} = 48 \text{ EUR}$$

⚠ Vorsicht!

Man beachte, dass die (empirische) Varianz s^2 quadrierte Einheiten besitzt. Die Einheiten der (empirischen) Standardabweichung s entsprechen den ursprünglichen Einheiten der Beobachtungswerte und sind daher leichter interpretierbar.

Teil C

Mia bittet ebenso um Stellungnahme des Online-Shops „Uni C Campus Merch“. Dieser konnte im ganzen Oktober jedoch lediglich fünf Bestellungen verzeichnen. Die Bestellwerte werden wie folgt übermittelt.

Bestellung	1	2	3	4	5
Bestellhöhe (in EUR)	20	120	120	170	2000

- f) Welche Mittelwerte können Sie in diesem Fall eindeutig angeben? Geben Sie diese an.

$$\begin{aligned}\bar{x}_C &= \frac{1}{5} \cdot (20 + 120 + 120 + 170 + 2000) = 486 \\ \tilde{x}_C &= 120 \\ \hat{x}_C &= 120\end{aligned}$$

Eine E-Mail korrigiert die Höhe der fünften Bestellung auf 20 EUR.

- g) Welchen Mittelwert können Sie nun nicht mehr eindeutig angeben?

Der Modus kann nun nicht mehr eindeutig angegeben werden, da die Ausprägungen 20 und 120 jeweils zwei mal vorkommen.

- h) Berechnen Sie aus den korrigierten Bestellhöhen das arithmetische Mittel und die Standardabweichung.

$$\begin{aligned}\bar{x}_C &= \frac{1}{5} \cdot (20 + 120 + 120 + 170 + 20) = 90 \\ s_C^2 &= \frac{1}{5} \cdot [(20 - 90)^2 \cdot 2 + (120 - 90)^2 \cdot 2 + (170 - 90)^2] = 3600 \\ s_C &= \sqrt{s_C^2} = \sqrt{3600} = 60\end{aligned}$$

- i) Vergleichen Sie die Streuung der Bestellhöhen von „Uni B Campus Merch“ und „Uni C Campus Merch“ mithilfe des Variationskoeffizienten. Verbalisieren Sie das Ergebnis.

$$\begin{aligned}V_B &= \frac{s_B}{\bar{x}_B} = \frac{48}{96} = \frac{1}{2} \\ V_C &= \frac{s_C}{\bar{x}_C} = \frac{60}{90} = \frac{2}{3}\end{aligned}$$

$V_B < V_C \Rightarrow$ relative Streuung der Bestellhöhen bei „Uni C Campus Merch“ größer als bei „Uni B Campus Merch“ nach dem Variationskoeffizienten.

Zusatz: Variationskoeffizient

Für statistische Größen mit nichtnegativen Ausprägungen und einem positiven arithmetischem Mittel ($\bar{x} > 0$) kann der Variationskoeffizient wie folgt berechnet werden:

$$V := \frac{s}{\bar{x}}$$

V ist maßstabslos (d.h. ohne Einheit) und kann daher zum Vergleich von Streuungen statistischer Größen mit unterschiedlichen Maßeinheiten genutzt werden.

Quelle: Fahrmeir, L., Heumann, C., Künstler, R., Pigeot, I. & Tutz, G. (2016). Statistik: Der Weg zur Datenanalyse (8. Auflage). Springer Spektrum. S. 68

- j) Berechnen Sie die durchschnittliche Bestellhöhe (arithmetisches Mittel) in EUR für alle drei Shops zusammen.

$$\bar{x}_{Ges} = \bar{x}_A \cdot \frac{100}{200} + \bar{x}_B \cdot \frac{95}{200} + \bar{x}_C \cdot \frac{5}{200} = 79,5 \cdot \frac{100}{200} + 96 \cdot \frac{95}{200} + 90 \cdot \frac{5}{200} = 87,6$$

- k) Berechnen Sie die empirische Varianz der Bestellhöhe in EUR² für alle drei Shops zusammen. Nutzen Sie: $s_B^2 = 4000$

Es gilt: $s_{Ges}^2 = s_{Ges,int}^2 + s_{Ges,ext}^2 = \frac{1}{n_{Ges}} \sum_{j=1}^r n_j s_j^2 + \frac{1}{n_{Ges}} \sum_{j=1}^r n_j (\bar{x}_j - \bar{x}_{Ges})^2$, also

$$\begin{aligned} s_{Ges}^2 &= \frac{1}{200} (100 \cdot 4000 + 95 \cdot 2304 + 5 \cdot 3600) + \frac{1}{200} (100 \cdot (79,5 - 87,6)^2 \\ &\quad + 95 \cdot (96 - 87,6)^2 + 5 \cdot (90 - 87,6)^2) \\ &= \underbrace{3184,4}_{\text{Streuung innerhalb der Shops}} + \underbrace{66,465}_{\text{Streuung zwischen den Shops}} = 3250,865 \end{aligned}$$

- l) Welcher Anteil der Gesamtvarianz wird durch die Unterschiede zwischen den drei Shops verursacht? Runden Sie auf vier Nachkommastellen.

$$\frac{66,465}{3250,865} \approx 0,0204$$

 **Interpretation:**

Nur 2,04% der gesamten Unterschiede (Streuung) in den Bestellhöhen lassen sich durch die Unterschiede zwischen den drei verschiedenen Shops erklären. Die restlichen 97,96% der Streuung entstehen innerhalb der einzelnen Shops. Das bedeutet, dass die Bestellhöhen der Kundinnen und Kunden in jedem einzelnen Shop in sich sehr stark variieren, während sich die Shops im direkten Vergleich (anhand ihrer Mittelwerte) überraschend ähnlich sind.

1.5 Konzentrationsmaße

Aufgabe 8

Teil A

Zur Analyse der finanziellen Leistungsfähigkeit im Profifußball sollen die Jahresgewinne aus dem laufenden Geschäft vor Abzügen der Vereine aus der 1. und 2. Liga untersucht werden. Um eine bessere Übersicht zu erhalten, werden die Vereine der 1. und 2. Liga getrennt betrachtet und die Vereine nach ihrer Gewinnhöhe (in Mio EUR) gruppiert. Jede Gruppe fasst Vereine mit ähnlichen Gewinnniveaus zusammen. Wir nehmen eine *Einpunktverteilung auf der Gruppenmitte für jede Gruppe* an.

Für die 18 Vereine der **1. Liga** ist folgende Tabelle gegeben:

j	von g_{j-1} bis g_j	f_j	u_j	h_j	m_j	$m_j \cdot h_j$	$\frac{m_j \cdot h_j}{V}$	v_j
1	[0 ; 2)			3				
2	[2 ; 10)			12				
3	[10 ; 12]			3				
Σ	-		-	$n = 18$	-	$V =$		-

Für die 20 Mannschaften der **2. Liga** ist folgende Tabelle gegeben:

j	von g_{j-1} bis g_j	f_j	u_j	h_j	m_j	$m_j \cdot h_j$	$\frac{m_j \cdot h_j}{V}$	v_j
1	[0 ; 2)			10				
2	[2 ; 4)			10				
Σ	-		-	$n = 20$	-	$V =$		-

- Wie lautet das *zugrundeliegende* statistische Merkmal und wie ist es skaliert? Wie verändert sich die Skalierung dieses Merkmals nach der Annahme der Einpunktverteilung.
- Vervollständigen Sie die beiden Tabellen.
- Verbalisieren Sie u_j und v_j für $j = 1$ in der 2. Liga.
- Zeichnen Sie die Lorenzkurve für beide Ligen in ein geeignetes Diagramm. Können Sie anhand der Lorenzkurven die beiden Ligen hinsichtlich der relativen Konzentration ihrer Gewinne vergleichen?

- e) Berechnen Sie den Gini-Koeffizienten für beide Ligen. Vergleichen Sie beide Ligen bezüglich ihrer relativen Konzentration.
- f) Wie hoch ist der relative Anteil am Gewinnvolumen in der 2. Liga, den die 50% gewinnstärksten Vereine besitzen?
- g) Welcher relativer Anteil der gewinnstärksten Vereine der 1. Liga besitzt 30% des Gewinnvolumens dieser Liga?
- h) Welchen relativen Anteil am Gewinnvolumen der 2. Liga haben die Vereine, die von ihrem finanziellen Erfolg her gesehen die mittleren 50% ausmachen?


Teil B

Der Wert des Herfindahl-Index für die 1. Liga beträgt $H_1 = \frac{1}{15}$.

- i) Berechnen Sie den Wert des Herfindahl-Index für die 2. Liga H_2 .
- j) Vergleichen Sie beide Ligen bezüglich ihrer absoluten Konzentration.
- k) In welcher Liga ist die absolute Konzentration größer, wenn man nur den Merkmals-effekt berücksichtigt?

Teil C

Ein Fußballverein bietet für Stehplätze zwei Preiskategorien an. Dauerkartenbesitzer zahlen pro Spiel 15 EUR, während Nicht-Dauerkartenbesitzer 100 EUR pro Spiel zahlen. Es gibt insgesamt 10000 Stehplätze. Für das statistische Merkmal *Preis eines Stehplatzes pro Spiel (in EUR)* liegt eine relative Häufigkeitsfunktion vor, die die Anteile der beiden Preiskategorien beschreibt.



- l) Wie ist das statistische Merkmal skaliert?
- m) Zeichnen Sie die Lorenzkurve in ein geeignetes Diagramm.

Motivation

Um das Zustandekommen der Gruppenhäufigkeiten h_j in Aufgabe 8 besser nachzuvollziehen, zeigt der nachfolgende fiktive Datensatz das Prinzip der Klassierung. Die anschließende Konzentrationsanalyse beantwortet eine zentrale Frage des Sportmanagements: *Wie stark sind die finanziellen Gewinne innerhalb einer Liga verteilt? Erzielen nur wenige Top-Clubs den Großteil des Gesamtertrags oder verteilen sich die Gewinne gleichmäßig?* Die Methode hilft so, die wirtschaftliche Machtverteilung in einer Liga (auf einem “Markt”) statistisch fundiert zu bewerten.

Eine interaktive Visualisierung zu der Aufgabe 8 finden Sie unter https://isabellftz.github.io/statviz/lorenz_demo.html.

💡 EBITA (Earnings Before Interest, Taxes and Amortization) bezeichnet den Gewinn vor Zinsen, Steuern und Abschreibungen auf immaterielle Vermögenswerte und spiegelt die reine operative Leistungsfähigkeit eines Vereins wider.

# 1. Liga (18 Vereine)		# 2. Liga (20 Vereine)	
Verein	EBITA	Verein	EBITA
FC Bayern München	11.8	Hamburger SV	3.8
Borussia Dortmund	10.4	FC St. Pauli	3.8
RB Leipzig	10.0	Hertha BSC	3.8
Bayer Leverkusen	9.4	Schalke 04	3.6
Eintracht Frankfurt	7.9	1. FC Nürnberg	3.3
VfB Stuttgart	6.8	Karlsruher SC	3.1
TSG Hoffenheim	6.4	Holstein Kiel	2.9
SC Freiburg	5.5	SC Paderborn	2.8
1. FSV Mainz 05	3.8	Greuther Fürth	2.6
Borussia Mönchengladbach	3.2	1. FC Kaiserslautern	2.0
1. FC Union Berlin	2.7	SV Elversberg	1.3
Werder Bremen	2.4	Hansa Rostock	1.2
VfL Bochum	2.1	Eintracht Braunschweig	1.0
FC Augsburg	2.1	SV Wehen Wiesbaden	0.9
1. FC Köln	2.0	SSV Ulm	0.8
Fortuna Düsseldorf	1.9	Jahn Regensburg	0.7
Hannover 96	1.6	FC Magdeburg	0.6
1. FC Heidenheim	0.3	VfL Osnabrück	0.5
		Rot-Weiss Essen	0.4
		Preußen Münster	0.3

Hinweis: Bei allen ausgewiesenen Vereinen und Kennzahlen handelt es sich um vollständig fiktive Werte, die ausschließlich zu Lehr- und Demonstrationszwecken dienen.

Aufgabe 8 Lösungen

Teil A

Zur Analyse der finanziellen Leistungsfähigkeit im Profifußball sollen die Jahresgewinne aus dem laufenden Geschäft vor Abzügen der Vereine aus der 1. und 2. Liga untersucht werden. Um eine bessere Übersicht zu erhalten, werden die Vereine der 1. und 2. Liga getrennt betrachtet und die Vereine nach ihrer Gewinnhöhe (in Mio EUR) gruppiert. Wir nehmen für beide Ligen eine *Einpunktverteilung auf der Gruppenmitte* innerhalb jeder Gruppe an.

Für die 18 Vereine der **1. Liga** ist folgende Tabelle gegeben:

j	von g_{j-1} bis g_j	f_j	u_j	h_j	m_j	$m_j \cdot h_j$	$\frac{m_j \cdot h_j}{V}$	v_j
1	[0 ; 2)			3				
2	[2 ; 10)			12				
3	[10 ; 12]			3				
Σ	-		-	$n = 18$	-	$V =$		-

Für die 20 Mannschaften der **2. Liga** ist folgende Tabelle gegeben:

j	von g_{j-1} bis g_j	f_j	u_j	h_j	m_j	$m_j \cdot h_j$	$\frac{m_j \cdot h_j}{V}$	v_j
1	[0 ; 2)			10				
2	[2 ; 4)			10				
Σ	-		-	$n = 20$	-	$V =$		-

- a) Wie lautet das *zugrundeliegende* statistische Merkmal und wie ist es skaliert? Wie verändert sich die Skalierung dieses Merkmals nach der Annahme der Einpunktverteilung.

X_i : Jahresgewinn vor Abzügen in Mio EUR für Liga i , $i = 1, 2$


X_i ist kardinal-stetig skaliert.

$\Rightarrow$ Durch die Annahme der Einpunktverteilung wird das statistische Merkmal kardinal-diskret.

Definition: Einpunktverteilung auf der Gruppenmitte m_j

Anstatt *innerhalb* der Gruppen eine *stetige Gleichverteilung* anzunehmen, verwenden wir nun die *Einpunktverteilung auf der Gruppenmitte*. Diese Annahme besagt, dass die gesamte Häufigkeit (“Häufigkeitsmasse”) einer Gruppe auf einen einzigen Punkt, die Gruppenmitte m_j , konzentriert wird. Mit anderen Worten: Alle Beobachtungen innerhalb der Gruppe werden als gleich der Gruppenmitte angenommen. Man sagt auch, dass “innerhalb der Gruppe keine (Verteilungs-)Konzentration vorliegt”. Diese Annahme der Einpunktverteilung ist also noch stärker als die Annahme einer stetigen Gleichverteilung. Die wahre Verteilung innerhalb der Gruppen wird bei beiden Annahmen vollständig vernachlässigt.

Durch die Annahme der Einpunktverteilung wird das statistische Merkmal X *diskretisiert*: Unsere realisierten Ausprägungen a_j entsprechen nun den (endlich vielen) Gruppenmitten m_j , also $X : \Omega \rightarrow \{m_1, \dots, m_k\}$. Das *zugrundeliegende* statistische Merkmal bleibt jedoch *stetig*.



b) Vervollständigen Sie die beiden Tabellen.

Für **Liga 1**:

j	von g_{j-1} bis g_j	f_j	u_j	h_j	m_j	$m_j \cdot h_j$	$\frac{m_j \cdot h_j}{V}$	v_j
1	[0 ; 2)	1/6	1/6	3	1	3	1/36	1/36
2	[2 ; 10)	4/6	5/6	12	6	72	24/36	25/36
3	[10 ; 12]	1/6	1	3	11	33	11/36	1
Σ	-	1	-	$n = 18$	-	$V = 108$	1	-

Für **Liga 2**:


j	von g_{j-1} bis g_j	f_j	u_j	h_j	m_j	$m_j \cdot h_j$	$\frac{m_j \cdot h_j}{V}$	v_j
1	[0 ; 2)	0,50	0,50	10	1	10	0,25	0,25
2	[2 ; 4]	0,50	1,00	10	3	30	0,75	1,00
Σ	-	1	-	$n = 20$	-	$V = 40$	1	-

c) Verbalisieren Sie u_j und v_j für $j = 1$ in der 2. Liga.

 *Interpretation:*

$(u_1; v_1) = (0,5; 0,25)$, d.h. die 50% gewinnschwächsten Vereine der $n = 20$ Vereine der 2. Liga erwirtschaften 25% des $V = 40$ Mio EUR gesamten Gewinnvolumens.

d) Zeichnen Sie die Lorenzkurve für beide Ligen in ein geeignetes Diagramm. Können Sie anhand der Lorenzkurven die beiden Ligen hinsichtlich der relativen Konzentration ihrer Gewinne vergleichen?



 Da sich die beiden Lorenzkurven schneiden, lässt sich die relative Konzentration der Gewinne der Ligen nicht eindeutig vergleichen. Eine eindeutige Beurteilung ist nur möglich, wenn die Kurven keine Schnittpunkte haben oder identisch sind.

Definition: Lorenzkurve

Die Lorenzkurve ist – im Rahmen dieses Werkes – für ein *kardinal-stetiges zugrundeliegendes Merkmal* als *durchgezogener Streckenzug* und für ein *kardinal-diskretes zugrundeliegendes Merkmal* als *gestrichelter Streckenzug* durch die Punkte

$$\{(0, 0), (u_1, v_1), \dots, (u_k, v_k) = (1, 1)\}$$

definiert, wobei

 *Notation:*

- u_j den kumulierten Anteil der Stichprobe bis einschließlich Gruppe/statistische Einheit j bezeichnet und
- v_j den kumulierten Anteil der (Gesamt-)Merkmalssumme V bis einschließlich Gruppe/statistische Einheit j bezeichnet.

Die Punkte (u_j, v_j) ergeben sich dabei für $j = 1, \dots, k$ aus

$$u_j := \frac{\sum_{i=1}^j h(a_i)}{\sum_{i=1}^k h(a_i)} = \frac{\sum_{i=1}^j f(a_i)}{\sum_{i=1}^k f(a_i)}, \quad v_j := \frac{\sum_{i=1}^j h(a_i) \cdot a_i}{\sum_{i=1}^k h(a_i) \cdot a_i},$$

wobei $h(a_j)$ bekanntermaßen die absolute Häufigkeit der statistischen Einheiten mit Merkmalsausprägung a_j angibt. Für gruppierte Daten gilt durch die Annahme der Einpunktverteilung auf der Gruppenmitte $a_j = m_j$. Alternativ lässt sich statt der Indizes h_j , f_j und $F(x)$ auch die funktional bezogene Schreibweise $h(m_j)$, $f(m_j)$ und $F(m_j)$ verwenden.

- e) Berechnen sie den Gini-Koeffizienten für beide Ligen. Vergleichen Sie beide Ligen bezüglich ihrer relativen Konzentration.

Es gilt $G = \frac{F}{1/2} = 2 \cdot F$. Mit der Trapezformel ergibt sich:

$$G_1 = 2 \cdot F_1 = 2 \cdot \left[\frac{1}{2} - \left(\frac{(1/6) \cdot ((1/36) + 0)}{2} + \frac{(4/6) \cdot ((1/36) + (25/36))}{2} + \frac{(1/6) \cdot ((25/36) + 1)}{2} \right) \right] \approx 0,2315$$

$$G_2 = 2 \cdot F_2 = 2 \cdot \left[\frac{1}{2} - \left(\frac{0,5 \cdot (0,25 + 0)}{2} + \frac{0,5 \cdot (0,25 + 1)}{2} \right) \right] = 0,25$$

$G_1 < G_2 \Rightarrow$ Die relative Konzentration der Gewinne nach Lorenz ist in der 2. Liga höher als in der 1. Liga.

 *Notation:*

- F beschreibt die Fläche zwischen der Winkelhalbierenden und der Lorenzkurve.
- G setzt F ins Verhältnis zu der Fläche zwischen Winkelhalbierenden und u -Achse, wobei Letztere 0,5 beträgt. Das daraus resultierende *Konzentrationsmaß* heißt Gini-Koeffizient.

- f) Wie hoch ist der relative Anteil am Gewinnvolumen in der 2. Liga, den die 50% gewinnstärksten Vereine besitzen?

0,75 (siehe Tabelle)

- g) Welcher relativer Anteil der gewinnstärksten Vereine der 1. Liga besitzt 30% des Gewinnvolumens dieser Liga?

$$\frac{3/10}{11/36} \cdot \frac{1}{6} = \frac{9}{55} \approx 0,164$$

- h) Welchen relativen Anteil am Gewinnvolumen der 2. Liga haben die Vereine, die von ihrem finanziellen Erfolg her gesehen die mittleren 50% ausmachen?

$$\frac{1}{2} \cdot 0,25 + \frac{1}{2} \cdot 0,75 = 0,5$$

Teil B

Definition: Herfindahl-Index

Der Herfindahl-Index H ist ein Konzentrationsmaß für statistische Größen mit nicht-negativen Ausprägungen. Er wird wie folgt berechnet:

$$H := \sum_{i=1}^n p_i^2,$$

wobei $p_i = \frac{x_i}{\sum_{j=1}^n x_j}$ der Marktanteil der statistischen Einheit i ist, mit $x_i \in \{a_1, \dots\}$. Alternativ lässt sich H wie folgt berechnen:

$$H := \frac{\left(\frac{s}{x}\right)^2 + 1}{n}$$

Für die Extremfälle der Konzentration ergeben sich:

i) *Nullkonzentration*, d.h. $x_1 = x_2 = \dots = x_n = a_j$

$$\Leftrightarrow H_{\min} = \sum_{i=1}^n \left(\frac{1}{n}\right)^2 = n \cdot \frac{1}{n^2} = \frac{1}{n}$$

ii) *Totale Konzentration*, d.h. $x_i = a_j$ für genau ein i ; $x_\ell = 0$ für alle $\ell \neq i$

$$\Leftrightarrow H_{\max} = (n-1) \cdot \left(\frac{0}{1}\right)^2 + 1 \cdot \left(\frac{1}{1}\right)^2 = 1$$

Damit ist der Wertebereich von H bestimmt durch: $\frac{1}{n} \leq H \leq 1$

 Um die *absolute Konzentration* zweier unterschiedlich großer Märkte zu vergleichen, kann man den Herfindahl-Index um den Anzahleffekt bereinigen. Diese Bereinigung erfolgt wie folgt:

$$H'_1 = \frac{H_1}{n_2} \quad H'_2 = \frac{H_2}{n_1},$$

wobei n_1 bzw. n_2 (mit $n_1 \neq n_2$) die Anzahl der Marktteilnehmer des ersten bzw. zweiten Marktes ist.

Quelle: Fahrmeir, L., Heumann, C., Künstler, R., Pigeot, I. & Tutz, G. (2016). Statistik: Der Weg zur Datenanalyse (8. Auflage). Springer Spektrum. S. 79

Der Wert des Herfindahl-Index für die 1. Liga beträgt $H_1 = \frac{1}{15}$.

i) Berechnen Sie den Wert des Herfindahl-Index für die 2. Liga H_2 .

Unter der Annahme der Einpunktverteilungen auf den Gruppenmitten gilt:
 $\sum_{i=1}^n x_i = 10 \cdot m_1 + 10 \cdot m_2 = 10 \cdot 1 + 10 \cdot 3 = 40$
 $\Rightarrow H_2 = \sum_{i=1}^n p_i^2 = \left(\frac{1}{40}\right)^2 \cdot 10 + \left(\frac{3}{40}\right)^2 \cdot 10 = \frac{1}{16}$

j) Vergleichen Sie beide Ligen bezüglich ihrer absoluten Konzentration.

$H_2 < H_1 \Rightarrow$ Die absolute Konzentration der Gewinne nach Herfindahl ist in der 1. Liga höher als in der 2. Liga.

k) In welcher Liga ist die absolute Konzentration höher, wenn man nur den Merkmals-effekt berücksichtigt?


$$n_1 = 18 \quad n_2 = 20$$

$$H'_1 = \frac{H_1}{n_2} = \frac{\frac{1}{15}}{20} = \frac{1}{300} \quad H'_2 = \frac{H_2}{n_1} = \frac{\frac{1}{16}}{18} = \frac{1}{288}$$

$H'_1 < H'_2 \Rightarrow$ Betrachtet man lediglich den Merkmalseffekt, so ist die absolute Konzentration der Gewinne nach Herfindahl in der 2. Liga höher als in der 1. Liga.

Teil C

Ein Fußballverein bietet für Stehplätze zwei Preiskategorien an. Dauerkartenbesitzer zahlen pro Spiel 15 EUR, während Nicht-Dauerkartenbesitzer 100 EUR pro Spiel zahlen. Es gibt insgesamt 10000 Stehplätze. Für das statistische Merkmal *Preis eines Stehplatzes pro Spiel (in EUR)* liegt eine relative Häufigkeitsfunktion vor, die die Anteile der beiden Preiskategorien beschreibt.



l) Wie ist das statistische Merkmal skaliert?

Y : Stehplatzpreis pro Spiel (in EUR)


Y ist kardinal-diskret skaliert. $Y : \Omega \rightarrow \{15, 100\}$

m) Zeichnen Sie die Lorenzkurve in ein geeignetes Diagramm.

Hilfstabelle:

j	a_j	$f(a_j)$	u_j	$h(a_j)$	$a_j \cdot h(a_j)$	$\frac{a_j \cdot h(a_j)}{V}$	v_j
1	15	0,85	0,85	8500	127500	0,4595	0,4595
2	100	0,15	1,00	1500	150000	0,5405	1,0000
Σ	-	1	-	$n = 10000$	$V = 277500$	1	-

Lorenzkurve für Y :



1.6 Bivariate empirische Häufigkeitsverteilungen

Aufgabe 9

Teil A

Im Rahmen einer Studienqualitätsumfrage wurden 200 Studierende nach dem Besuch eines Unterrichts ihrer Wahl befragt. Dabei wurden zwei statistische Größen erhoben:

X : Wie gut konnten die Studierenden dem Unterricht folgen?

mit den möglichen Ausprägungen: *schlecht* (a_1), *mittelmäßig* (a_2), *sehr gut* (a_3)

Y : Haben sich die Studierenden vor dem Unterricht mit dem Stoff befasst?


mit den möglichen Ausprägungen: *ja* (b_1), *nein* (b_2)

Aus der Umfrage ergab sich, dass **jeweils** 70 Studierende angaben, dem Unterricht schlecht bzw. sehr gut folgen zu können. Insgesamt gaben 120 Studierende an, sich vor dem Unterricht mit dem Stoff befasst zu haben.

- Wie sind die statistische Merkmale skaliert?
- Skizzieren Sie jeweils die relative Häufigkeitsfunktion für X und Y in einem Stabdiagramm.

Teil B

Nun wurden die Antworten beider Merkmale (X, Y) gemeinsam ausgewertet. Die zugehörige gemeinsame relative Häufigkeitsfunktion $f(a_i, b_j) := f_{ij}$ wurde grafisch dargestellt und in einer Kontingenztafel zusammengefasst.



		Y		
X		ja (b_1)	nein (b_2)	Σ
schlecht	(a_1)	0,05	0,30	0,35
mittelmäßig	(a_2)	0,20	0,10	0,30
sehr gut	(a_3)	0,35	0,00	0,35
Σ		0,60	0,40	1,00

- c) Verbalisieren Sie f_{21} , $f_{\cdot 1}$, $f_{2\cdot}$, $f_x(a_1|b_1)$ und $f_y(b_2|a_1)$ im Kontext der Aufgabe.
- d) Erläutern Sie, weshalb die Gesamtheit aller
- i) gemeinsamen relativen Häufigkeiten f_{ij} ,
 - ii) relativen Randhäufigkeiten $f_{i\cdot}$ bzw. $f_{\cdot j}$ und
 - iii) bedingten relativen Häufigkeiten $f_x(a_i|b_j)$ bzw. $f_y(b_j|a_i)$
- jeweils** eine diskrete Häufigkeitsverteilung bildet.
- e) Skizzieren Sie die relativen Randhäufigkeiten von X und Y in Stabdiagrammen und erläutern Sie formal und grafisch den Zusammenhang zu den gemeinsamen relativen Häufigkeiten.
- f) Skizzieren Sie die relative Häufigkeitsfunktion von X ,
- i) bedingt auf die Studierenden, die sich vor dem Unterricht mit dem Stoff beschäftigen haben und
 - ii) bedingt auf die Studierenden, die dies nicht getan haben
- in einem Stabdiagramm. Beurteilen Sie eine mögliche empirische Abhängigkeit zwischen den Merkmalen X und Y .
- g) Vergleichen Sie die in f) skizzierten bedingten relativen Häufigkeitsfunktionen mit der gemeinsamen relativen Häufigkeitsfunktion grafisch.

Aufgabe 9 Lösungen

Teil A

Im Rahmen einer Studienqualitätsumfrage wurden 200 Studierende nach dem Besuch eines Unterrichts ihrer Wahl befragt. Dabei wurden zwei statistische Größen erhoben:

X : Wie gut konnten die Studierenden dem Unterricht folgen?

mit den möglichen Ausprägungen: *schlecht* (a_1), *mittelmäßig* (a_2), *sehr gut* (a_3)

Y : Haben sich die Studierenden vor dem Unterricht mit dem Stoff befasst?


mit den möglichen Ausprägungen: *ja* (b_1), *nein* (b_2)

Aus der Umfrage ergab sich, dass **jeweils** 70 Studierende angaben, dem Unterricht schlecht bzw. sehr gut folgen zu können. Insgesamt gaben 120 Studierende an, sich vor dem Unterricht mit dem Stoff befasst zu haben.

a) Wie sind die statistische Merkmale skaliert?

X ist diskret und ordinalskaliert; Y ist diskret und nominalskaliert.

b) Skizzieren Sie jeweils die relative Häufigkeitsfunktion für X und Y in einem Stabdiagramm.




+ *Zusatz:* Die relativen Häufigkeiten bilden in ihrer Gesamtheit die relative Häufigkeitsverteilung/Häufigkeitsfunktion, also

$(f_x(a_1); f_x(a_2); f_x(a_3)) = (0,35; 0,3; 0,35)$ relative Häufigkeitsverteilung von X

$(f_y(b_1); f_y(b_2)) = (0,6; 0,4)$ relative Häufigkeitsverteilung von Y

Teil B

Nun wurden die Antworten beider Merkmale (X, Y) gemeinsam ausgewertet. Die zugehörige gemeinsame relative Häufigkeitsfunktion $f(a_i, b_j) := f_{ij}$ wurde grafisch dargestellt und in einer Kontingenztabelle zusammengefasst.



X	Y		Σ
	ja (b_1)	nein (b_2)	
schlecht (a_1)	0,05	0,30	0,35
mittelmäßig (a_2)	0,20	0,10	0,30
sehr gut (a_3)	0,35	0,00	0,35
Σ	0,60	0,40	1,00

Bivariate empirische Analyse

Bei der Analyse empirischer Zusammenhänge geht es darum, Abhängigkeiten zwischen *mehreren* statistischen Merkmalen sichtbar zu machen und zu quantifizieren.

Im bivariaten Fall werden die erhobenen Merkmale X und Y mit den zugehörigen Beobachtungswerten $x_1, x_2, \dots, x_n$ bzw. $y_1, y_2, \dots, y_n$ als **Merkmalsvektor** (X, Y) aufgefasst. Die Beobachtungen liegen dann paarweise in Form von 2-Tupeln $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ vor. Die möglichen Ausprägungen von X und Y werden beispielsweise durch $a_1, \dots, a_k$ bzw. $b_1, \dots, b_l$ bezeichnet.

Eine Kontingenztabelle/Kontingenztafel ist eine Möglichkeit, die gemeinsame absolute bzw. relative Häufigkeitsfunktion darzustellen: Sie erfasst die Häufigkeiten aller Kombinationen von a_i und b_j tabellarisch. Die Einträge entsprechen den Höhen der jeweiligen „Stäbe“ im zugehörigen Stabdiagramm.

Die relativen Häufigkeiten f_{ij} bilden in ihrer Gesamtheit die *gemeinsame relative Häufigkeitsverteilung/Häufigkeitsfunktion* von (X, Y) , also

$$(f_{11}; f_{12}; f_{21}; f_{22}; f_{31}; f_{32}) = (0,05; 0,30; 0,20; 0,10; 0,35; 0,00)$$

c) Verbalisieren Sie f_{21} , $f_{\cdot 1}$, $f_{2\cdot}$, $f_x(a_1|b_1)$ und $f_y(b_2|a_1)$ im Kontext der Aufgabe.



Interpretation:

– $f_{21} = f(a_2, b_1) = 0, 20$,

d.h. 20% aller Studierenden geben an, dem Unterricht mittelmäßig folgen zu können und sich vor dem Unterricht mit dem Stoff befasst zu haben.

– $f_{\cdot 1} = f(b_1) = 0, 60$,

d.h. 60% aller Studierenden haben sich vor dem Unterricht mit dem Stoff befasst.

– $f_{2\cdot} = f(a_2) = 0, 3$,

d.h. 30% aller Studierenden können dem Unterricht mittelmäßig folgen.

– $f_x(a_1|b_1) = \frac{f_{11}}{f_{\cdot 1}} = \frac{f(a_1, b_1)}{f(b_1)} = \frac{0,05}{0,6} = \frac{1}{12}$,

d.h. ein Zwölftel der Studierenden, die sich vor dem Unterricht mit dem Stoff befasst haben, kann dem Unterricht schlecht folgen.

– $f_y(b_2|a_1) = \frac{f_{12}}{f_{1\cdot}} = \frac{f(a_1, b_2)}{f(a_1)} = \frac{0,3}{0,35} = \frac{6}{7}$,

d.h. sechs Siebtel der Studierenden, die dem Unterricht schlecht folgen können, befassten sich vor dem Unterricht nicht mit dem Stoff.

d) Erläutern Sie, weshalb die Gesamtheit aller

- i) gemeinsamen relativen Häufigkeiten f_{ij} ,
- ii) relativen Randhäufigkeiten $f_{i\cdot}$ bzw. $f_{\cdot j}$ und
- iii) bedingten relativen Häufigkeiten $f_x(a_i|b_j)$ bzw. $f_y(b_j|a_i)$

jeweils eine diskrete relative Häufigkeitsverteilung bildet.

Es gilt:

$$\begin{aligned}
 i) \quad \sum_{i=1}^3 \sum_{j=1}^2 f_{ij} &= (0,05 + 0,30) + (0,20 + 0,10) + (0,35 + 0,00) = 1 \\
 ii) \quad \sum_{i=1}^3 f_{i\cdot} &= (f_{1\cdot} + f_{2\cdot} + f_{3\cdot}) = 0,35 + 0,3 + 0,35 = 1 \quad \text{bzw.} \\
 &\quad \sum_{j=1}^2 f_{\cdot j} = (f_{\cdot 1} + f_{\cdot 2}) = 0,60 + 0,4 = 1 \\
 iii) \quad \sum_{i=1}^3 f_x(a_i|b_1) &= f_x(a_1|b_1) + f_x(a_2|b_1) + f_x(a_3|b_1) \\
 &= \frac{f(a_1, b_1) + f(a_2, b_1) + f(a_3, b_1)}{f_{\cdot 1}} \\
 &= \frac{0,05 + 0,20 + 0,35}{0,60} = 1 \quad (\text{analog für } f_x(a_i|b_2)) \\
 &\quad \sum_{j=1}^2 f_y(b_j|a_1) = f_y(b_1|a_1) + f_y(b_2|a_1) \\
 &= \frac{f(b_1, a_1) + f(b_2, a_1)}{f_{1\cdot}} \\
 &= \frac{0,05 + 0,30}{0,35} = 1 \quad (\text{analog für } f_y(b_j|a_2) \text{ und } f_y(b_j|a_3))
 \end{aligned}$$

☺ *Begründung:*

Per Definition, bilden die relative Häufigkeiten eines diskreten Merkmals X (bzw. eines Merkmalsvektors (X, Y)) genau dann eine (gemeinsame) *diskrete relative Häufigkeitsverteilung*, wenn **(i)** sie sich zu 1 aufsummieren ($\rightarrow$ vgl. Prinzip der Flächentreue bei stetigen Merkmalen) **und (ii)** jede Einzelhäufigkeit einen Wert zwischen 0 und 1 annimmt.

🌀 *Synonyme* (bei diskreten Merkmalen):

- absolute/relative Häufigkeitsverteilung: absolute/relative Häufigkeitsfunktion, Gesamtheit aller absoluten/relativen Häufigkeiten

- e) Skizzieren Sie die relativen Randhäufigkeiten von X und Y in Stabdiagrammen und erläutern Sie formal und grafisch den Zusammenhang zu den gemeinsamen relativen Häufigkeiten.





Skizze des Stabdiagramms, wie in b) mit neuer Notation auf y-Achse:

$$f_x(a_i) := f_{i.} \quad \text{und} \quad f_y(b_j) := f_{.j}$$

☞ Formaler Zusammenhang:

$$f_{i.} = \sum_{j=1}^2 f_{ij} \quad \text{für alle } i = 1, 2, 3 \quad \text{bzw.} \quad f_{.j} = \sum_{i=1}^3 f_{ij} \quad \text{für alle } j = 1, 2$$

☞ Grafischer Zusammenhang: Die Häufigkeiten („Stäbe“) der gemeinsamen relativen Häufigkeitsfunktion werden zum jeweiligen Rand hin aufsummiert. Daraus ergeben sich die Randhäufigkeiten.



✚ *Zusatz:* Die relativen Randhäufigkeiten bilden in ihrer Gesamtheit wieder die relative Randverteilung, also

$$(f_{1.}, f_{2.}, f_{3.}) = (0,35; 0,3; 0,35) \quad \text{relative Randverteilung von } X$$

$$(f_{.1}, f_{.2}) = (0,6; 0,4) \quad \text{relative Randverteilung von } Y$$

Diese Randverteilungen entsprechen genau den relativen (univariaten) Häufigkeitsverteilungen bzw. Häufigkeitsfunktionen von X und Y (vgl. b)). Der Begriff „Randhäufigkeitsfunktion“ wird in der Literatur üblicherweise *nicht* verwendet.

Man erhält die relativen Randhäufigkeiten aus der Kontingenztabelle, indem man die gemeinsamen relativen Häufigkeiten für X zeilenweise und für Y spaltenweise aufsummiert.

- f) Skizzieren Sie die relative Häufigkeitsfunktion von X ,
- i) bedingt auf die Studierenden, die sich vor dem Unterricht mit dem Stoff beschäftigt haben und
 - ii) bedingt auf die Studierenden, die dies nicht getan haben
- in einem Stabdiagramm. Beurteilen Sie eine mögliche empirische Abhängigkeit zwischen den Merkmalen X und Y .

Es gilt zu berechnen:

$$i) \quad f_x(a_i|b_1) = \frac{f(a_i, b_1)}{f_{.1}} = \frac{f(a_i, b_1)}{0,6} \quad \text{für alle } i = 1, 2, 3$$

$\Rightarrow$ relative Häufigkeitsverteilung von X bedingt auf $Y = b_1$


$$(f_x(a_1|b_1); f_x(a_2|b_1); f_x(a_3|b_1)) = \left(\frac{1}{12}; \frac{4}{12}; \frac{7}{12}\right)$$

$$ii) \quad f_x(a_i|b_2) = \frac{f(a_i, b_2)}{f_{.2}} = \frac{f(a_i, b_2)}{0,4} \quad \text{für alle } i = 1, 2, 3$$

$\Rightarrow$ relative Häufigkeitsverteilung von X bedingt auf $Y = b_2$

$$(f_x(a_1|b_2); f_x(a_2|b_2); f_x(a_3|b_2)) = \left(\frac{9}{12}; \frac{3}{12}; 0\right)$$

Fortsetzung: siehe nächste Seite



☞ *Begründung:*

Die bedingten relativen Häufigkeitsverteilungen von X unterscheiden sich deutlich, je nachdem, ob $Y = b_1$ oder $Y = b_2$ gilt. Dies zeigt, dass X von der Ausprägung von Y abhängt, also X und Y *empirisch nicht unabhängig* sind. Interessanterweise sieht die univariate relative Häufigkeitsverteilung von X (vgl. a) oder e)) fast wie eine diskrete Gleichverteilung aus. Erst durch das Bedingen auf $Y = b_1$ bzw. $Y = b_2$ lassen sich deutliche Trends erkennen.

Hinweis:

An dieser Stelle ist zu betonen, dass hier von einer *empirischen* Abhängigkeit zwischen den statistischen Größen X und Y die Rede ist. Diese Abhängigkeit basiert ausschließlich auf den beobachteten Daten, sie ist somit rein *datengestützt*, und entsteht nicht durch einen Zufallsvorgang. Sie ist daher klar von der *stochastischen* Abhängigkeit beziehungsweise Unabhängigkeit im Sinne von Zufallsvariablen zu unterscheiden.





- g) Vergleichen Sie die in f) skizzierten bedingten relativen Häufigkeitsfunktionen mit der gemeinsamen relativen Häufigkeitsfunktion grafisch.

- *Unterschied:* Die bedingten relativen Häufigkeiten bilden jeweils eine vollständige diskrete Häufigkeitsverteilung, da ihre Summe 1 ergibt. Die Werte f_{11}, f_{21}, f_{31} sind dagegen nur einzelne Punkthäufigkeiten der gemeinsamen Verteilung von (X, Y) , deren Summe nicht unbedingt 1 beträgt (analog für f_{12}, f_{22}, f_{32}).
- *Gemeinsamkeit:* Die Proportionalität bleibt erhalten. Die Proportionen von f_{11}, f_{21} und f_{31} stimmen mit denen von $f_x(a_1|b_1), f_x(a_2|b_1)$ und $f_x(a_3|b_1)$ überein (analog für $Y = b_2$).

Fortsetzung: siehe nächste Seite

☺ Begründung (und Visualisierung) zu "Gemeinsamkeit":

Die Verhältnisse zwischen den Ausprägungen bleiben unverändert, da sie nur durch eine feste relative Häufigkeit $f_{\cdot j}$ geteilt werden. Grafisch übersetzt sich die Proportionalität in den selben Trend, die bedingten Häufigkeiten heben dabei nur die Anteile für den jeweiligen Wert von Y hervor.



1.7 χ^2 - und Kontingenzkoeffizient

Aufgabe 10

- a) Aufbauend auf Aufgabe 9, vervollständigen Sie die folgende Kontingenztafel, indem Sie die (tatsächlichen) gemeinsamen absoluten Häufigkeiten $h(a_i, b_j) := h_{ij}$ eintragen. Berechnen Sie außerdem die (hypothetischen) absoluten Häufigkeiten $\tilde{h}_{ij}$, die Sie *unter der Annahme von empirischer Unabhängigkeit der Merkmale X und Y* erwarten würden.

$X \backslash Y$	ja (b_1)	nein (b_2)	Σ
schlecht (a_1)	h_{11} $\tilde{h}_{11}$	h_{12} $\tilde{h}_{12}$	70
mittelmäßig (a_2)	h_{21} $\tilde{h}_{21}$	h_{22} $\tilde{h}_{22}$	60
sehr gut (a_3)	h_{31} $\tilde{h}_{31}$	h_{32} $\tilde{h}_{32}$	70
Σ	120	80	200

- b) Berechnen Sie den *Chi-Quadrat-Koeffizienten* χ^2 . Geben Sie eine Intuition für die χ^2 Berechnungsformel.
- c) Berechnen Sie den *Kontingenzkoeffizienten* K und den *korrigierten Kontingenzkoeffizienten* K^* und interpretieren Sie Ihr Ergebnis im Kontext der Aufgabe.

Aufgabe 10 Lösungen

- a) Aufbauend auf Aufgabe 9, vervollständigen Sie die folgende Kontingenztafel, indem Sie die (tatsächlichen) gemeinsamen absoluten Häufigkeiten $h(a_i, b_j) := h_{ij}$ eintragen. Berechnen Sie außerdem die (hypothetischen) absoluten Häufigkeiten $\tilde{h}_{ij}$, die Sie unter der Annahme von empirischer Unabhängigkeit der Merkmale X und Y erwarten würden.

$X \backslash Y$	ja (b_1)	nein (b_2)	Σ
schlecht (a_1)	10 42	60 28	70
mittelmäßig (a_2)	40 36	20 24	60
sehr gut (a_3)	70 42	0 28	70
Σ	120	80	200

☞ An dieser Stelle fällt bereits auf, dass sich die beobachteten absoluten Häufigkeiten h_{ij} von den unter empirischer Unabhängigkeit erwarteten absoluten Häufigkeiten $\tilde{h}_{ij}$ für alle (i, j) unterscheiden.

- b) Berechnen Sie den *Chi-Quadrat-Koeffizienten* χ^2 . Geben Sie eine Intuition für die χ^2 Berechnungsformel.

Es gilt $\chi^2 := \sum_{i=1}^k \sum_{j=1}^l \frac{(h_{ij} - \tilde{h}_{ij})^2}{\tilde{h}_{ij}}$, also

$$\begin{aligned}
 \chi^2 &= \frac{(10 - 42)^2}{42} + \frac{(60 - 28)^2}{28} + \frac{(40 - 36)^2}{36} + \frac{(20 - 24)^2}{24} + \frac{(70 - 42)^2}{42} + \frac{(0 - 28)^2}{28} \\
 &= \frac{1024}{42} + \frac{1024}{28} + \frac{16}{36} + \frac{16}{24} + \frac{784}{42} + \frac{784}{28} \\
 &\approx 108,73
 \end{aligned}$$

Fortsetzung: siehe nächste Seite

 Intuition:

Bei der Berechnung von χ^2 summieren wir die Brüche $\frac{(h_{ij} - \tilde{h}_{ij})^2}{\tilde{h}_{ij}}$ für alle (i, j) auf. Die genaue Betrachtung von Zähler und Nenner liefert folgende Intuition:

- Zähler (für jedes (i, j)): Die quadrierte Abweichung zwischen der beobachteten absoluten Häufigkeit und der unter empirischer Unabhängigkeit erwarteten absoluten Häufigkeit $(h_{ij} - \tilde{h}_{ij})^2$ steht im Zähler. Eine niedrige quadrierte Abweichung spricht für empirische Unabhängigkeit, während eine hohe quadrierte Abweichung gegen empirische Unabhängigkeit spricht. Hieraus ergibt sich bereits, dass ein größeres χ^2 eher gegen empirische Unabhängigkeit spricht. Damit sich positive und negative Abweichungen nicht gegenseitig aufheben, wird quadriert.
- Nenner (für jedes (i, j)): Die quadrierte Abweichung im Zähler $(h_{ij} - \tilde{h}_{ij})^2$ wird durch $\tilde{h}_{ij}$ geteilt und damit *in Relation* zu $\tilde{h}_{ij}$ betrachtet. Dies ist notwendig, da die „Relevanz“ einer quadrierten Abweichung davon abhängt, welche absolute Häufigkeit wir unter Unabhängigkeit erwarten. Eine quadrierte Abweichung von 5^2 ist „relevanter“ wenn wir eine absolute Häufigkeit von 10 unter Unabhängigkeit erwarten würden, als wenn wir eine absolute Häufigkeit von 1000 erwarten würden.

- c) Berechnen Sie den *Kontingenzkoeffizienten* K und den *korrigierten Kontingenzkoeffizienten* K^* und interpretieren Sie Ihr Ergebnis im Kontext der Aufgabe.

$$K := \sqrt{\frac{\chi^2}{\chi^2 + n}}, \text{ also } \Rightarrow K := \sqrt{\frac{108,73}{108,73 + 200}} \approx 0,5935$$

$$K^* := \frac{K}{K_{\max}} \text{ mit } K_{\max} = \sqrt{\frac{m-1}{m}} \text{ und } m = \min\{k, l\}, \text{ also } \Rightarrow K^* = \frac{0,5935}{\sqrt{\frac{2-1}{2}}} \approx 0,8393$$

 Der Wert von $K^* = 0,8393$ spricht für ein hohes Maß an empirischer Abhängigkeit zwischen den Merkmalen X und Y .

Hinweis:

In der Literatur existiert keine allgemein anerkannte numerische Skala, die die Werte der Maße χ^2 , K oder K^* Abhängigkeitsstärken wie „schwach“, „mittelstark“ oder „stark“ zuordnet.

Definition: Zusammenhangsmaß für beliebiges Skalenniveaus

☞ Der **Chi-Quadrat-Koeffizient** χ^2 liegt im Intervall

$$[0, (m-1) \cdot n], \quad \text{mit } m := \min\{k, l\},$$

und hängt damit sowohl von der Anzahl der Merkmalsausprägungen (l und k) als auch vom Stichprobenumfang n ab. χ^2 wächst mit dem Stichprobenumfang. Verzehnfacht man etwa alle Häufigkeiten h_{ij} und $\tilde{h}_{ij}$, so verzehnfacht sich auch χ^2 .

☞ Um die Abhängigkeit vom Stichprobenumfang zu entfernen wird der **Kontingenzkoeffizient** $K = \sqrt{\frac{\chi^2}{\chi^2 + n}}$ (nach Karl Pearson) verwendet. Er nimmt Werte in

$$\left[0, \underbrace{\sqrt{\frac{(m-1)}{m}}}_{=: K_{max}} \right] \subset [0, 1], \quad \text{mit } m := \min\{k, l\}$$

an und hängt damit weiterhin von der Anzahl der Merkmalsausprägungen ab.

☞ Um die Abhängigkeit von der Anzahl der Merkmalsausprägungen zu entfernen und damit die Vergleichbarkeit zu gewährleisten, wird der **korrigierte Kontingenzkoeffizient** $K^* := \frac{K}{K_{max}}$ verwendet. Er nimmt nun Werte in

$$[0, 1]$$

an. Werte nahe 0 sprechen für empirische Unabhängigkeit, Werte nahe 1 für ein hohes Maß an empirischer Abhängigkeit zwischen den Merkmalen.

Eigenschaften von χ^2 , K und K^*

Die Maße χ^2 , K und K^* weisen insbesondere folgende Eigenschaften auf:

- Sie erfassen nur die *Stärke* des Zusammenhangs, nicht dessen Richtung; kausale Aussagen sind damit nicht möglich.
- Sie sind vergleichende Maße: Man kann die Stärke des Zusammenhangs zwischen Populationen vergleichen.

Quelle: Ludwig Fahrmeir, Christian Heumann, Rita Künstler, Iris Pigeot, Gerhard Tutz (2016): Statistik. Der Weg zur Datenanalyse. 8. Auflage. Springer, Berlin/Heidelberg. S. 199


1.8 Korrelationsanalyse

Aufgabe 11

Teil A

Moderne Fitnessuhren zeigen nach dem Training unter anderem die Herzfrequenz, die Geschwindigkeit und die erreichte Trainingszone an. Da die Trainingszonen an der Laktatkonzentration des Körpers orientiert sind, die nur im Labor direkt messbar ist, wird der Zusammenhang zwischen Laktat und Herzfrequenz genutzt, um die erreichte Trainingszone zu bestimmen. Bei ausgewählten Leistungssportlern werden hierfür die *Herzfrequenz* X (*Schläge/min*) und die *Laktatkonzentration* Y (*mmol/l*) unter verschiedenen Belastungsstufen auf dem Fahrradergometer im Labor gemessen. Diese Daten dienen als Grundlage, um die Trainingszonen zu schätzen. Die Messungen einer Leistungssportlerin wurden beispielhaft aufgezeichnet und in einem Streudiagramm visualisiert.

Messung	1	2	3	4	5	6	7	8	9	10	11
X	110	130	158	185	166	180	175	175	140	178	150
Y	1,0	1,2	2,0	3,5	2,5	5,5	3,5	4,4	1,5	6,0	2,0



Das arithmetische Mittel und die empirischen Varianz von X bzw. Y wurden bereits

ermittelt:

$$\begin{aligned}\bar{x} &= 158,8182 \text{ (Schläge/min)} & \text{und} & \quad \bar{y} = 3,0091 \text{ (mmol/l)} \\ s_x^2 &= 520,3306 \text{ (Schläge/min)}^2 & \text{und} & \quad s_y^2 = 2,6772 \text{ (mmol/l)}^2\end{aligned}$$

- a) Wie sind die statistischen Merkmale X und Y skaliert?
- b) Berechnen Sie die *empirische Kovarianz* s_{xy} zwischen X und Y . Interpretieren Sie das Ergebnis inhaltlich und statistisch exakt.
- c) Berechnen Sie den *Korrelationskoeffizienten nach Bravais-Pearson* r . Interpretieren Sie das Ergebnis statistisch exakt.
- d) Welches der beiden Maßzahlen s_{xy} und r eignet sich besser, um die Stärke eines möglichen linearen Zusammenhangs zwischen X und Y zu beurteilen? Begründen Sie Ihre Antwort.
- e) Bestimmen Sie den *korrigierten Rangkorrelationskoeffizienten nach Kendall* τ^* . Interpretieren Sie das Ergebnis statistisch exakt.
- f) Warum müssen wir in e) die korrigierte Version des *Rangkorrelationskoeffizienten nach Kendall* berechnen?
- g) Welches der beiden Zusammenhangsmaße r und τ eignet sich Ihrer Meinung nach besser zur Beschreibung des Zusammenhangs von X und Y in diesen beobachteten Daten? Begründen Sie Ihre Wahl unter Bezugnahme auf das Streudiagramm.

Teil B

Zusätzlich wird im Labor zu jeder in Teil A aufgeführte Messung *die auf dem Fahrradergometer erbrachte Leistung* W in Watt dokumentiert.

Messung	1	2	3	4	5	6	7	8	9	10	11
W	75	100	125	185	140	165	150	160	90	175	120

Der Rangkorrelationskoeffizienten nach Kendall τ zwischen X und W sowie zwischen Y und W wurde bereits ermittelt:

$$\tau_{xw} = 0,9175 \quad \text{und} \quad \tau_{yw} = 0,8335$$

- h) Berechnen sie den *partiellen Rangkorrelationskoeffizient nach Kendall* $\tau_{xy \circ w}$. Interpretieren Sie das Ergebnis statistisch exakt.

Teil C

Die Fitnessuhr schätzt nun anhand der während des Trainings gemessenen Herzfrequenz den Laktatwert und zeigt darauf basierend die erreichte Trainingszone an. Für einen Hobbyläufer wurden nach dem Joggen die *durchschnittliche Herzfrequenz* $\bar{X}$ (Schläge/min) sowie die *erreichte Trainingszone* Z auf einer Skala von 1 (sehr leichte sportliche Belastung) bis 5 (maximale sportliche Belastung) an fünf Tagen gemessen.

Tag	1	2	3	4	5
$\bar{X}$	170	140	135	165	120
Z	5	4	2	3	1


- i) Berechnen Sie den *Korrelationskoeffizienten nach Spearman* r_{sp} zwischen $\bar{X}$ und Z . Interpretieren Sie das Ergebnis statistisch exakt.
- j) Berechnen Sie den *Korrelationskoeffizienten nach Kendall* τ zwischen $\bar{X}$ und Z . Interpretieren Sie das Ergebnis statistisch exakt.

Aufgabe 11 Lösungen

Teil A

Moderne Fitnessuhren zeigen nach dem Training unter anderem die Herzfrequenz, die Geschwindigkeit und die erreichte Trainingszone an. Da die Trainingszonen an der Laktatkonzentration des Körpers orientiert sind, die nur im Labor direkt messbar ist, wird der Zusammenhang zwischen Laktat und Herzfrequenz genutzt, um die erreichte Trainingszone zu bestimmen. Bei ausgewählten Leistungssportlern werden hierfür die *Herzfrequenz* X (*Schläge/min*) und die *Laktatkonzentration* Y (*mmol/l*) unter verschiedenen Belastungsstufen auf dem Fahrradergometer im Labor gemessen. Diese Daten dienen als Grundlage, um die Trainingszonen zu schätzen. Die Messungen einer Leistungssportlerin wurden beispielhaft aufgezeichnet und in einem Streudiagramm visualisiert.


Messung	1	2	3	4	5	6	7	8	9	10	11
X	110	130	158	185	166	180	175	175	140	178	150
Y	1,0	1,2	2,0	3,5	2,5	5,5	3,5	4,4	1,5	6,0	2,0



Das arithmetische Mittel und die empirischen Varianz von X bzw. Y wurden bereits ermittelt:

$$\begin{aligned} \bar{x} &= 158,8182 \text{ (Schläge/min)} & \text{und} & \quad \bar{y} = 3,0091 \text{ (mmol/l)} \\ s_x^2 &= 520,3306 \text{ (Schläge/min)}^2 & \text{und} & \quad s_y^2 = 2,6772 \text{ (mmol/l)}^2 \end{aligned}$$

Übersicht: Koeffizienten und Skalenniveaus von X und Y



a) Wie sind die statistischen Merkmale X und Y skaliert?

X ist diskret und kardinalskaliert; Y ist stetig und kardinalskaliert.

☺ *Begründung:*

Die Herzfrequenz X wird in Schlägen pro Minute gemessen. Da ein Mensch nur eine ganze Zahl von Herzschlägen pro Minute haben kann, nimmt X abzählbar viele Werte an, also diskret. (Halbe Herzschläge gibt es nicht; entweder es schlägt oder es schlägt nicht!) Die Laktatkonzentration Y wird in Millimol pro Liter gemessen und kann beliebige positive reelle Werte annehmen. Deshalb ist Y stetig.

b) Berechnen Sie die *empirische Kovarianz* s_{xy} zwischen X und Y . Interpretieren Sie das Ergebnis inhaltlich und statistisch exakt.

Es gilt $s_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y}) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}$, also

$$\begin{aligned} s_{xy} &= \frac{1}{11} \cdot (110 \cdot 1,0 + 130 \cdot 1,2 + 158 \cdot 2,0 + 185 \cdot 3,5 + 166 \cdot 2,5 + 180 \cdot 5,5 \\ &\quad + 175 \cdot 3,5 + 175 \cdot 4,4 + 140 \cdot 1,5 + 178 \cdot 6,0 + 150 \cdot 2,0) - 158,8182 \cdot 3,0091 \\ &= \frac{1}{11} \cdot 5595 - 158,8182 \cdot 3,0091 \approx 30,7365 \text{ (Schläge/min)} \cdot \text{(mmol/l)} \end{aligned}$$

☞ Auf Basis der Messungen besteht zwischen der Herzfrequenz X und der Laktatkonzentration Y gemäß der empirischen Kovarianz ein *gleichsinniger/positiver linearer Zusammenhang*, d.h. höhere Werte in X (höhere Herzfrequenz) gehen mit höheren Werten in Y (höhere Laktatkonzentration) einher.

Fortsetzung auf nächster Seite.

💬 *Begründung:* positiv, da $s_{xy} > 0$

⚠️ *Vorsicht!*


Keine Aussage über die *Stärke* des Zusammenhangs möglich!

Zusatz: empirische Kovarianz s_{xy}

Die empirische Kovarianz misst, wie stark zwei Merkmale X und Y gemeinsam linear variieren. Der Punkt $(\bar{x}, \bar{y})$ ist der Schwerpunkt, also der Schnittpunkt der beiden Schwerlinien. Der Term $(x_i - \bar{x})(y_i - \bar{y})$ entspricht der Rechteckfläche, die von der Realisierung (x_i, y_i) und dem Schwerpunkt aufgespannt wird. Die Einheit entspricht dem *Produkt der Einheiten* von X und Y . Die Flächeninhalte der Rechtecke im Quadranten I und III sind positiv, im Quadranten II und IV negativ. Die Kovarianz

$$s_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

ist die Summe aller Rechteckflächen (welche positiv oder negativ in die Summe eingehen können) geteilt durch den Stichprobenumfang n . Sie kann damit als die „durchschnittliche“ Rechteckfläche interpretiert werden. Überwiegen die positiven Flächen, ist $s_{xy} > 0$ (positiver linearer Zusammenhang); überwiegen die negativen Flächen, ist $s_{xy} < 0$ (negativer linearer Zusammenhang); bei $s_{xy} = 0$ gibt es keine Richtungstendenz. Da Rechteckflächen unbegrenzt sein können, ist s_{xy} ein *nicht-normiertes, skalenabhängiges* Maß.



Quelle: Stocker, T. C., & Steinke, I. (2022). Statistik: Grundlagen und Methodik (2., korrigierte Auflage). De Gruyter Oldenbourg. S. 146-147

Zusatz: Verschiebungsformel für die empirische Kovarianz s_{xy}

Für die empirische Kovarianz gilt:

$$\begin{aligned}
 s_{xy} &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\
 &= \frac{1}{n} \sum_{i=1}^n [x_i y_i - x_i \bar{y} - y_i \bar{x} + \bar{x} \bar{y}] \\
 &= \frac{1}{n} \left(\sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \bar{y} - \sum_{i=1}^n y_i \bar{x} + \sum_{i=1}^n \bar{x} \bar{y} \right) \\
 &= \frac{1}{n} \left(\sum_{i=1}^n x_i y_i - \bar{y} \underbrace{\sum_{i=1}^n x_i}_{=n\bar{x}} - \bar{x} \underbrace{\sum_{i=1}^n y_i}_{=n\bar{y}} + n \cdot \bar{x} \bar{y} \right) \\
 &= \frac{1}{n} \left(\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} - n\bar{x}\bar{y} + n\bar{x}\bar{y} \right) \\
 &= \frac{1}{n} \left(\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} \right) = \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x}\bar{y}
 \end{aligned}$$

- c) Berechnen Sie den *Korrelationskoeffizienten nach Bravais-Pearson* r . Interpretieren Sie das Ergebnis statistisch exakt.

$$r := \frac{s_{xy}}{\sqrt{s_x^2 \cdot s_y^2}}, \quad \text{also} \quad r = \frac{30,7366}{\sqrt{520,3306 \cdot 2,6772}} \approx 0,8235$$

 *Interpretation:*

Auf Basis der Messungen besteht zwischen der Herzfrequenz X und der Laktatkonzentration Y gemäß des Korrelationskoeffizienten nach Bravais-Pearson ein *starker gleichsinniger/positiver linearer Zusammenhang*.

 *Begründung:*

- stark, da $|r| \geq 0,8$
- gleichsinnig, da $r > 0$

Stärke eines linearen Zusammenhangs auf Basis von r

Numerische Skala für die Stärke einer Korrelation nach Bravais-Pearson:

schwache Korrelation: $|r| < 0,5$

mittlere Korrelation: $0,5 \leq |r| < 0,8$

starke Korrelation: $0,8 \leq |r|$

Quelle: Ludwig Fahrmeir, Christian Heumann, Rita Künster, Iris Pigeot, Gerhard Tutz (2016): Statistik. Der Weg zur Datenanalyse. 8. Auflage. Springer, Berlin/Heidelberg. S. 130

- d) Welches der beiden Maßzahlen s_{xy} und r eignet sich besser, um die Stärke eines möglichen linearen Zusammenhangs zwischen X und Y zu beurteilen? Begründen Sie Ihre Antwort.

Der Korrelationskoeffizient nach Bravais-Pearson r eignet sich besser, da er skalenunabhängig, dimensionslos und auf $[-1, 1]$ normiert ist.

 *Begründung:*

r eignet sich besser, um die Stärke eines möglichen linearen Zusammenhangs zwischen X und Y zu beurteilen. Im Gegensatz zu der *empirischen Kovarianz* s_{xy} ist er unabhängig von den Einheiten von X und Y (skalenunabhängig, dimensionslos), auf den Wertebereich $[-1, 1]$ normiert und liefert damit eine interpretierbare Maßzahl für die Stärke der *möglichen linearen* Beziehung.

- e) Bestimmen Sie den *korrigierten Rangkorrelationskoeffizienten nach Kendall* τ^* . Interpretieren Sie das Ergebnis statistisch exakt.

$$\text{Es gilt } \tau^* := \frac{P - Q}{\sqrt{\frac{n(n-1)}{2} - \tau_x} \cdot \sqrt{\frac{n(n-1)}{2} - \tau_y}}$$

$$\text{mit } \tau_x = \sum_{i=1}^k \binom{g_i}{2} = \frac{1}{2} \sum_{i=1}^k g_i \cdot (g_i - 1), \quad \text{und} \quad \tau_y = \sum_{j=1}^l \binom{h_j}{2} = \frac{1}{2} \sum_{j=1}^l h_j \cdot (h_j - 1).$$

 *Notation:*

- $\binom{n}{2} = \frac{n(n-1)}{2}$ gibt die Anzahl aller möglichen Paarvergleiche an.
- P gibt die Anzahl der gleichsinnigen Paarvergleiche („Übereinstimmungen“) an.
- Q gibt die Anzahl der gegensinnigen Paarvergleiche („Nicht- Übereinstimmungen“) an.

- g_i gibt die Anzahl der Datenpunkte (x, y) an für die gilt $x = x_i$.
- h_j gibt die Anzahl der Datenpunkte (x, y) an für die gilt $y_j = y$.
- τ_x gibt die Anzahl der Paarvergleiche an, die durch Bindungen („Ties“) in X weder einen gleichsinnigen, noch gegensinnigen Zusammenhang liefern („0“).
- τ_y analog zu τ_x .

☞ Die Werte für P , Q , g_i und h_j können mittels einer Hilfstabelle oder mittels des abgebildeten Streudiagramms ermittelt werden.

Mittels Hilfstabelle:

Die Messungen können nach X oder Y sortiert werden, um das Vergleichen der Paare zu erleichtern. In diesem Fall wurden sie nach X sortiert.

Messung	1	2	9	11	3	5	7	8	10	6	4
X	110	130	140	150	158	166	175	175	178	180	185
Y	1,0	1,2	1,5	2,0	2,0	2,5	3,5	4,4	6,0	5,5	3,5
		+	+	+	+	+	+	+	+	+	+
			+	+	+	+	+	+	+	+	+
				+	+	+	+	+	+	+	+
					0	+	+	+	+	+	+
						+	+	+	+	+	+
							+	+	+	+	+
								0	+	+	0
									+	+	-
										-	-
											-


Also $P = 48$, $Q = 4$, $g_1 = 2$, $h_1 = 2$, $h_2 = 2$ und damit gilt

$$\tau_x = \sum_{i=1}^k \binom{g_i}{2} = \frac{1}{2} \sum_{i=1}^k g_i \cdot (g_i - 1), \quad \text{also} \quad \tau_x = \binom{2}{2} = \frac{1}{2} \cdot (2 \cdot 1) = 1$$


$$\tau_y = \sum_{j=1}^l \binom{h_j}{2} = \frac{1}{2} \sum_{j=1}^l h_j \cdot (h_j - 1), \quad \text{also} \quad \tau_y = \binom{2}{2} + \binom{2}{2} = \frac{1}{2} \cdot (2 \cdot 1 + 2 \cdot 1) = 2$$

$$\tau^* := \frac{P - Q}{\sqrt{\frac{n(n-1)}{2} - \tau_x} \cdot \sqrt{\frac{n(n-1)}{2} - \tau_y}}, \quad \text{also} \quad \tau^* = \frac{48 - 4}{\sqrt{55 - 1} \cdot \sqrt{55 - 2}} \approx 0,8225$$


Mittels des abgebildeten Streudiagramms:




$P_1 = 10, Q_1 = 0$




$P_2 = 9, Q_2 = 0$




$P_3 = 8, Q_3 = 0$




$P_4 = 6, Q_4 = 0$




$P_5 = 6, Q_5 = 0$




$P_6 = 5, Q_6 = 0$




$P_7 = 2, Q_7 = 0$




$P_8 = 2, Q_8 = 1$



$P_9 = 0, Q_9 = 2$



$P_{10} = 0, Q_{10} = 1$



$P_{11} = 0, Q_{11} = 0$

Für jeden Datenpunkt (x_i, y_i) $i = 1, \dots, n$ gilt:

- P_i entspricht der Anzahl an Datenpunkten (x_j, y_j) $j \neq i$, für welche gilt:

$$x_i < x_j \text{ und } y_i < y_j$$



→ **Anzahl der Punkte im 1. Quadranten (rechts oben);**

- Q_i entspricht der Anzahl an Datenpunkten (x_j, y_j) $j \neq i$, für welche gilt:

$$x_i < x_j \text{ und } y_i > y_j$$

→ **Anzahl der Punkte im 4. Quadranten (rechts unten)**

$$\Rightarrow P = \sum_{i=1}^{11} P_i = 10 + 9 + 8 + 6 + 6 + 5 + 2 + 2 = 48 \text{ und } Q = \sum_{i=1}^{11} Q_i = 1 + 2 + 1 = 4$$



- g_i entspricht der Anzahl an Datenpunkten (x_j, y_j) $j \neq i$, für welche gilt:

$$x_i = x_j \rightarrow \text{Anzahl der Punkte auf senkrechter Linie};$$

- h_i entspricht der Anzahl an Datenpunkten (x_j, y_j) $j \neq i$, für welche gilt:

$$y_i = y_j \rightarrow \text{Anzahl der Punkte auf waagrechter Linie}$$

$$\Rightarrow \tau_x = \sum_{i=1}^1 \binom{g_i}{2} = \binom{2}{2} = 1 \text{ und } \tau_y = \sum_{j=1}^2 \binom{h_j}{2} = \binom{2}{2} + \binom{2}{2} = 2$$

🧩 *Interpretation:*

Auf Basis der Messungen besteht zwischen der Herzfrequenz X und der Laktatkonzentration Y gemäß des korrigierten Rangkorrelationskoeffizienten nach Kendall ein *gleichsinniger/positiver monotoner* Zusammenhang. Die Stärke des Zusammenhangs liegt mit einem Wert von 0,8225 im oberen Bereich des Wertebereichs $[-1, 1]$.

☺ *Begründung:* gleichsinnig, da $\tau^* > 0$

Hinweis:

Eine eindeutige Skala, welche Werte von τ^* für einen starken, mittleren oder schwachen monotonen Zusammenhang sprechen, ist in der Literatur nicht allgemeingültig definiert.

- f) Warum müssen wir in e) die korrigierte Version des *Rangkorrelationskoeffizienten nach Kendall* berechnen?

Der *Rangkorrelationskoeffizient nach Kendall* muss in e) korrigiert werden, da Bindungen in X und Y vorliegen. Das Vorhandensein von Bindungen reduziert die Anzahl der effektiv möglichen Paarvergleiche und verzerrt damit das Ergebnis.

- g) Welches der beiden Zusammenhangsmaße r und τ eignet sich Ihrer Meinung nach besser zur Beschreibung des Zusammenhangs von X und Y in diesen beobachteten Daten? Begründen Sie Ihre Wahl unter Bezugnahme auf das Streudiagramm.

Da das Streudiagramm einen exponentiellen Zusammenhang zeigt, ist der Rangkorrelationskoeffizienten nach Kendall τ besser geeignet als der Korrelationskoeffizienten nach Bravais-Pearson r . τ erfasst *monotone Zusammenhänge*, unabhängig von deren Form (also auch nicht-lineare), während r nur *lineare Zusammenhänge* misst.

Teil B

Zusätzlich wird im Labor zu jeder in Teil A aufgeführte Messung *die auf dem Fahrradergometer erbrachte Leistung W in Watt* dokumentiert.

Messung	1	2	3	4	5	6	7	8	9	10	11
W	75	100	125	185	140	165	150	160	90	175	120

Der Rangkorrelationskoeffizienten nach Kendall τ zwischen X und W sowie zwischen Y und W wurde bereits ermittelt:

$$\tau_{xw} = 0,9175 \quad \text{und} \quad \tau_{yw} = 0,8335$$

- h) Berechnen sie den *partiellen Rangkorrelationskoeffizient nach Kendall* $\tau_{xy^\circ w}$. Interpretieren Sie das Ergebnis statistisch exakt.

$$\tau_{xy} := \tau^* = 0,8225 \quad (\text{aus Teilaufg. e)})$$

$$\tau_{xy^\circ w} := \frac{\tau_{xy} - \tau_{xw} \cdot \tau_{yw}}{\sqrt{(1 - \tau_{xw}^2) \cdot (1 - \tau_{yw}^2)}}, \quad \text{also}$$

$$\tau_{xy^\circ w} = \frac{0,8225 - 0,9175 \cdot 0,8335}{\sqrt{(1 - 0,9175^2) \cdot (1 - 0,8335^2)}} \approx 0,2629$$

 Interpretation:

Eine höhere Leistung W (schnelleres Treten auf Fahrradergometer) geht mit

- einer höheren Herzfrequenz X (höherer Puls); vgl. $\tau_{xw} = 0,9175$),
- als auch mit einer höheren Laktatkonzentration Y (vgl. $\tau_{yw} = 0,8335$) einher. Kontrolliert man für diese beiden Zusammenhänge, weisen Herzfrequenz und Laktatkonzentration einen *schwächeren positiven monotonen Zusammenhang* auf ($\tau_{xy^\circ w} \leq \tau_{xy}$).

Hinweis:

Der *partielle Korrelationskoeffizient nach Bravais-Pearson* lässt sich analog berechnen.

Teil C

Die Fitnessuhr schätzt nun anhand der während des Trainings gemessenen Herzfrequenz den Laktatwert und zeigt darauf basierend die erreichte Trainingszone an. Für einen Hobbyläufer wurden nach dem Joggen die *durchschnittliche Herzfrequenz* $\bar{X}$ (Schläge/min) sowie die *erreichte Trainingszone* Z auf einer Skala von 1 (sehr leichte sportliche Belastung) bis 5 (maximale sportliche Belastung) an fünf Tagen gemessen.

Tag	1	2	3	4	5
$\bar{X}$	170	140	135	165	120
Z	5	4	2	3	1

- i) Berechnen Sie den *Korrelationskoeffizienten nach Spearman* r_{sp} zwischen $\bar{X}$ und Z . Interpretieren Sie das Ergebnis statistisch exakt.

Hilfstabelle: ($R_{\bar{x}}$ basierend auf aufsteigender Sortierung von $\bar{X}$.)

Tag	5	3	2	4	1
$R_{\bar{x}}$	1	2	3	4	5
R_z	1	2	4	3	5
$R_{\bar{x}} - R_z$	0	0	-1	1	0
$(R_{\bar{x}} - R_z)^2$	0	0	1	1	0

$$r_{sp} := 1 - \frac{6 \sum_{i=1}^n (R_{\bar{x}_i} - R_{z_i})^2}{(n-1) \cdot n \cdot (n+1)}, \quad \text{also} \quad r_{sp} := 1 - \frac{6 \cdot 2}{(5-1) \cdot 5 \cdot (5+1)} = 0,9$$

 Vorsicht!

Die hier genutzte Formel für r_{sp} ist die vereinfachte Formel, die nur **ohne** Bindungen in X und Y gilt.

 Interpretation:

Auf Basis der Untersuchung liegt zwischen den Merkmalen $\bar{X}$ und Z ein *gleichsinniger (positiver) monotoner* Zusammenhang vor.

 Begründung:

- gleichsinnig, da $r_{sp} > 0$

Hinweis:

Eine eindeutige Skala, welche Werte von r_{sp} für einen starken, mittleren oder schwachen monotonen Zusammenhang sprechen, ist in der Literatur nicht allgemeingültig definiert.

- j) Berechnen Sie den *Korrelationskoeffizienten nach Kendall* τ zwischen $\bar{X}$ und Z . Interpretieren Sie das Ergebnis statistisch exakt.

Hilfstabelle: ($R_{\bar{x}}$ basierend auf aufsteigender Sortierung von $\bar{X}$.)

Tag	5	3	2	4	1
$\bar{X}$	120	135	140	165	170
Z	1	2	4	3	5
		+	+	+	+
			+	+	+
				-	+
					+

$$\tau := \frac{P - Q}{\frac{n(n-1)}{2}} \quad \text{mit} \quad P = 9, \quad Q = 1, \quad \frac{5(5-1)}{2} = 10, \quad \text{also} \quad \tau = \frac{9-1}{10} = 0,8$$

 Interpretation:

Auf Basis der Untersuchung liegt zwischen den Merkmalen $\bar{X}$ und Z ein *gleichsinniger (positiver) monotoner* Zusammenhang vor.

 Begründung:

- gleichsinnig, da $r > 0$

Hinweis:

Eine eindeutige Skala, welche Werte von τ für einen starken, mittleren oder schwachen monotonen Zusammenhang sprechen, ist in der Literatur nicht allgemeingültig definiert.

Kendall vs. Spearman

In der Fachliteratur wird der Rangkorrelationskoeffizient nach Kendall im Allgemeinen als *robuster gegenüber Ausreißern* eingestuft⁽¹⁾. Während er im Worst-Case eine höhere Laufzeit als der Spearman-Koeffizient aufweist ($\mathcal{O}(n^2)$ gegenüber $\mathcal{O}(n \log n)$), lässt er sich durch optimierte Algorithmen (wie Merge-Sort) ebenfalls in $\mathcal{O}(n \log n)$ berechnen.

⁽¹⁾ Croux, Christophe & Dehon, Catherine (2010). Influence functions of the Spearman and Kendall correlation measures. Statistical Methods & Applications, 19(4), 497–515. <https://doi.org/10.1007/s10260-010-0142-z>

2 Wahrscheinlichkeitstheorie

2.1 Kombinatorische Grundlagen

Aufgabe 12

In einer Urne befinden sich sechs von 1 bis 6 nummerierte Kugeln unterschiedlicher Farbe: Zwei blaue Kugeln, eine weiße Kugel und drei schwarze Kugeln.

Teil A

Sie ziehen **alle** Kugeln.

- a) Wie viele Möglichkeiten gibt es, die Kugeln *ihrer Nummer nach* anzuordnen?
- b) Wie viele Möglichkeiten gibt es, die Kugeln *ihrer Farbe nach* anzuordnen?

Teil B

Sie ziehen **4** Kugeln **mit Zurücklegen**.

- c) Wie viele Möglichkeiten gibt es, die Kugeln auszuwählen, wenn die Reihenfolge der gezogenen Nummern
 - i) keine Rolle spielt.
 - ii) eine Rolle spielt.

Teil C

Sie ziehen **4** Kugeln **ohne Zurücklegen**.

- d) Wie viele Möglichkeiten gibt es, die Kugeln auszuwählen, wenn die Reihenfolge der gezogenen Nummern
 - i) keine Rolle spielt.
 - ii) eine Rolle spielt.
- e) Wie viele Möglichkeiten gibt es,
 - i) **4** Kugeln auszuwählen und *ihrer Farbe nach* anzuordnen,
(*Hinweis:* Überlegen Sie sich, welche Farbkonstellationen in d) i) möglich sind und wie oft jede davon realisiert werden kann.)
 - ii) **4** Kugeln auszuwählen und *ihrer Nummer nach* anzuordnen?

Aufgabe 13

- a) Sie besitzen zwei Bücher zur *Empirie*, drei Bücher zur *Kombinatorik* und vier Buch zur *Wahrscheinlichkeitstheorie*. Die Titel der Bücher sind klar lesbar. Wie viele Möglichkeiten gibt es, die Bücher in ein Regal zu stellen, wenn Sie die Bücher
- i) *wahllos* einräumen,
 - ii) *ihren Themenblöcken nach* einräumen,
 - iii) *ihren Themenblöcken nach* einräumen, wobei ein bestimmter Themenblock in der Mitte stehen soll, und in jedem Themenblock ein bestimmtes Buch ganz links stehen soll?
- b) Sie haben den vierstelligen Code Ihres Handys vergessen. Sie erinnern sich nur noch daran, dass zwei Ziffern gleich sind und die Ziffern 3, 5 und 7 irgendwo im Passwort vorkommen. Wie viele mögliche Passwörter müssen Sie ausprobieren, um Ihr Handy zu entsperren?
- c) Sie möchten ein achtstelliges Passwort für ein Nutzerkonto erstellen. Das Passwort soll genau ein Sonderzeichen aus einer Menge von 30 Sonderzeichen sowie genau einen Großbuchstaben aus 26 möglichen Großbuchstaben enthalten. Die verbleibenden sechs Zeichen dürfen aus den 10 Ziffern oder den 26 Kleinbuchstaben gewählt werden. Wie viele Möglichkeiten gibt es für die Erstellung des Passworts, wenn
- i) Ziffern und Buchstaben beliebig oft wiederholt werden dürfen.
 - ii) Ziffern und Buchstaben jeweils nur einmal vorkommen dürfen.
- d) Sie erstellen eine Playlist auf der Musik-App Ihrer Wahl. Aus 50 als Favorit markierten Songs möchten Sie 9 Songs für Ihre neue Playlist auswählen, wobei die Reihenfolge keine Rolle spielen soll. Ein Song kann mehrfach in die Playlist aufgenommen werden. Wie viele unterschiedliche Playlists aus 9 Songs können Sie erstellen?

Aufgabe 14

- a) Zeigen Sie mit einem formalen Rechengang, dass folgende Gleichungen allgemein gelten und verbalisieren Sie ihr Ergebnis.

$$\text{i) } P^W(n; \underbrace{1, \dots, 1}_{n\text{-mal}}) = P(n) \qquad \text{ii) } K(n; n-1) = V(n; 1)$$

- b) Zeigen Sie mit einem formalen Rechengang, dass die folgenden Ungleichungen für $r > 1$ gelten und verbalisieren Sie ihr Ergebnis.

$$\text{i) } V(n; r) < V^W(n; r) \qquad \text{ii) } K(n; r) < V(n; r)$$

- c) Erklären Sie, wie sich die Formel der Kombination ohne Wiederholung aus der Permutation mit Wiederholung ergibt.

Motivation

Bevor wir uns der *Kombinatorik* zuwenden, lohnt es sich, zu reflektieren, warum wir dies überhaupt tun sollten. Wir begannen damit, ein statistisches Merkmal X , das als Funktion der Menge aller statistischen Einheiten Ω in die Menge aller möglichen Ausprägungen, nun bezeichnet mit W , aufgefasst wird, also

$$X : \Omega \rightarrow W,$$

zu betrachten, und insbesondere die *Kardinalität bzw. Mächtigkeit (Größe) des Wertebereichs W von X* . Dabei haben wir festgestellt, dass ein statistisches Merkmal X stetig ist, wenn W überabzählbar viele Elemente enthält, und diskret, wenn W abzählbar viele Elemente umfasst.

Mit diesem Verständnis sind wir in die **deskriptive Statistik** eingestiegen: Wir haben Realisierungen von X beobachtet, Häufigkeitsverteilungen gebildet, diese durch Lagemaße und Streuungsmaße beschrieben, die Konzentration eines Merkmals untersucht und uns schließlich auch dem bivariaten Fall zugewandt.

Nun kehren wir einen Schritt zurück und betrachten die *Kardinalität/ Mächtigkeit („Größe“) des Definitionsbereichs Ω von X* selbst. Hier kommt die Kombinatorik ins Spiel: Sie liefert uns „Hilfsregeln“, um die Anzahl der Elemente in Ω zu „zählen“ (falls die Mächtigkeit von Ω endlich ist). Dieses Wissen wird uns bei der Bestimmung von bestimmten Wahrscheinlichkeiten ($\rightarrow$ Laplace-Wahrscheinlichkeiten) im Rahmen der **Wahrscheinlichkeitstheorie** helfen.

Übersicht für Permutation, Variation und Kombination

ohne Wiederholung

- Wie viele Möglichkeiten der **Anordnung** ($\hat{=}$ n aus n Kugel werden gezogen) gibt es, wenn man aus einer Urne mit
- n unterscheidbaren ($\hat{=}$ ohne Wiederholung) Kugeln
 - n Kugeln
 - mit Beachtung der Reihenfolge zieht?

*Permutation**mit Wiederholung*

- Wie viele Möglichkeiten der **Anordnung** ($\hat{=}$ n aus n Kugel werden gezogen) gibt es, wenn man aus einer Urne mit
- n teils identischen, d.h. nicht-unterscheidbaren Kugeln,
 - wovon es K unterscheidbare Gruppen mit *jeweils*
 - p bzw. q bzw. $r \dots$ (mit $n = p + q + r + \dots$) identischen, d.h. nicht-unterscheidbaren ($\hat{=}$ mit Wiederholung) Kugeln gibt,
 - n Kugeln
 - mit Beachtung der Reihenfolge zieht?

✎ Notation: $P^W(n; p, q, r, \dots) = \frac{n!}{p! \cdot q! \cdot r! \cdot \dots}$

- Wie viele Möglichkeiten der **Auswahl** ($\hat{=}$ r aus n Kugeln werden gezogen) gibt es, wenn man aus einer Urne mit
- n unterscheidbaren Kugeln
 - r ($r \in (0, n]$) Kugeln
 - ohne Zurücklegen ($\hat{=}$ ohne Wiederholung)
 - mit Beachtung der Reihenfolge zieht?

Variation

✎ Notation: $V(n; r) = \frac{n!}{(n-r)!}$

- Wie viele Möglichkeiten der **Auswahl** ($\hat{=}$ r aus n Kugeln werden gezogen) gibt es, wenn man aus einer Urne mit
- n unterscheidbaren Kugeln
 - r ($r \in (0, n]$) Kugeln
 - ohne Zurücklegen ($\hat{=}$ ohne Wiederholung)
 - ohne Beachtung der Reihenfolge zieht?

Kombination

✎ Notation: $K(n; r) = \binom{n}{r} = \frac{n!}{r! \cdot (n-r)!}$

✎ Notation: $V^W(n; r) = n^r$

- Wie viele Möglichkeiten der **Auswahl** ($\hat{=}$ r aus n Kugeln werden gezogen) gibt es, wenn man aus einer Urne mit
- n unterscheidbaren Kugeln
 - r ($r > 0$) Kugeln
 - mit Zurücklegen ($\hat{=}$ mit Wiederholung)
 - ohne Beachtung der Reihenfolge zieht?

✎ Notation: $K^W(n; r) = \binom{n+r-1}{r}$

Aufgabe 12 Lösungen

In einer Urne befinden sich sechs von 1 bis 6 nummerierte Kugeln unterschiedlicher Farbe: Zwei blaue Kugeln, eine weiße Kugel und drei schwarze Kugeln.

Teil A

Sie ziehen **alle** Kugeln.

- a) Wie viele Möglichkeiten gibt es, die Kugeln *ihrer Nummer nach* anzuordnen?

$$P(6) = 6! = 720$$

- b) Wie viele Möglichkeiten gibt es, die Kugeln *ihrer Farbe nach* anzuordnen?

$$P^W(6; 2, 1, 3) = \frac{6!}{2! \cdot 1! \cdot 3!} = 60$$

Teil B

Sie ziehen **4** Kugeln **mit Zurücklegen**.

- c) Wie viele Möglichkeiten gibt es, die Kugeln auszuwählen, wenn die Reihenfolge der gezogenen Nummern

i) keine Rolle spielt.

ii) eine Rolle spielt.

$$\text{i) } K^W(6; 4) = \binom{6+4-1}{4} = 126$$

$$\text{ii) } V^W(6; 4) = 6^4 = 1296$$

Teil C

Sie ziehen **4** Kugeln **ohne Zurücklegen**.

- d) Wie viele Möglichkeiten gibt es, die Kugeln auszuwählen, wenn die Reihenfolge der gezogenen Nummern

i) keine Rolle spielt.

ii) eine Rolle spielt.

$$\text{i) } K(6; 4) = \binom{6}{4} = \frac{6!}{4!(6-4)!} = \frac{720}{24 \cdot 2} = 15$$

$$\text{ii) } V(6; 4) = \frac{6!}{(6-4)!} = 6 \cdot 5 \cdot 4 \cdot 3 = 360$$

e) Wie viele Möglichkeiten gibt es,

- i) 4 Kugeln auszuwählen und *ihrer Farbe nach* anzuordnen,
(*Hinweis*: Überlegen Sie sich, welche Farbkonstellationen in d) i) möglich sind und wie oft jede davon realisiert werden kann.)
- ii) 4 Kugeln auszuwählen und *ihrer Nummer nach* anzuordnen?

- 1 weiße, 2 blaue, 1 schwarze Kugel(n):

Auswahlmöglichkeiten

$$\binom{1}{1} \cdot \binom{2}{2} \cdot \binom{3}{1} = 3$$

Anordnungsmöglichkeiten

$$\text{i) } P^W(4; 1, 2, 1) = \frac{4!}{1! \cdot 2! \cdot 1!} = 12$$

- 1 weiße, 1 blaue, 2 schwarze Kugel(n):

Auswahlmöglichkeiten

$$\binom{1}{1} \cdot \binom{2}{1} \cdot \binom{3}{2} = 2 \cdot 3 = 6$$

Anordnungsmöglichkeiten

$$\text{i) } P^W(4; 1, 1, 2) = \frac{4!}{1! \cdot 1! \cdot 2!} = 12$$

- 2 blaue, 2 schwarze Kugel(n):

Auswahlmöglichkeiten

$$\binom{2}{2} \cdot \binom{3}{2} = 3$$

Anordnungsmöglichkeiten

$$\text{i) } P^W(4; 2, 2) = \frac{4!}{2! \cdot 2!} = \frac{12}{2} = 6$$

- 1 blaue, 3 schwarze Kugel(n):

Auswahlmöglichkeiten

$$\binom{2}{1} \cdot \binom{3}{3} = 2$$

Anordnungsmöglichkeiten

$$\text{i) } P^W(4; 1, 3) = \frac{4!}{1! \cdot 3!} = 4$$

- 1 weiße, 3 schwarze Kugel(n):

Auswahlmöglichkeiten

$$\binom{1}{1} \cdot \binom{3}{3} = 1$$

Anordnungsmöglichkeiten

$$\text{i) } P^W(4; 1, 3) = \frac{4!}{1! \cdot 3!} = 4$$

i) Es gibt insgesamt $3 \cdot 12 + 6 \cdot 12 + 3 \cdot 6 + 2 \cdot 4 + 1 \cdot 4 = 138$ Möglichkeiten.

ii) Es gibt insgesamt $(3 + 6 + 3 + 2 + 1) \cdot P(4) = 15 \cdot 4! = 360$ Möglichkeiten.

$$\text{Alternativ: } V(6; 4) = \frac{6!}{(6-4)!} = 6 \cdot 5 \cdot 4 \cdot 3 = 360$$

🔗 *Intuition*: Die Anordnung *nach Nummern* „überschreibt“ die Anordnung *nach Farben*.

Aufgabe 13 Lösungen

- a) Sie besitzen zwei Bücher zur *Empirie*, drei Bücher zur *Kombinatorik* und vier Bücher zur *Wahrscheinlichkeitstheorie*. Die Titel der Bücher sind klar lesbar. Wie viele Möglichkeiten gibt es, die Bücher in ein Regal zu stellen, wenn Sie die Bücher
- wahllos* einräumen,
 - ihren Themenblöcken nach* einräumen,
 - ihren Themenblöcken nach* einräumen, wobei ein bestimmter Themenblock in der Mitte stehen soll, und in jedem Themenblock ein bestimmtes Buch ganz links stehen soll?

i) $P(9) = 9! = 362.880$

ii) $\underbrace{2! \cdot 3! \cdot 4!}_{\text{Permutation in Blöcken}} \cdot \underbrace{3!}_{\text{Permutation der Blöcke}} = 288 \cdot 6 = 1.728$

iii) $\underbrace{(2-1)! \cdot (3-1)! \cdot (4-1)!}_{\text{Permutation in den Blöcken}} \cdot \underbrace{(3-1)!}_{\text{Permutation der Blöcke}} = 24$

- b) Sie haben den vierstelligen Code Ihres Handys vergessen. Sie erinnern sich nur noch daran, dass zwei Ziffern gleich sind und die Ziffern 3, 5 und 7 irgendwo im Passwort vorkommen. Wie viele mögliche Passwörter müssen Sie ausprobieren, um Ihr Handy zu entsperren?

$\underbrace{P^W(4; 2, 1, 1)}_{\substack{\text{4-stelliges} \\ \text{Passwort} \\ \text{mit einer} \\ \text{doppelten Ziffer}}} \cdot \underbrace{3}_{\substack{\text{3 verschiedene} \\ \text{doppelte} \\ \text{Ziffern möglich}}} = \frac{4!}{2!} \cdot 3 = 36$

- c) Sie möchten ein achtstelliges Passwort für ein Nutzerkonto erstellen. Das Passwort soll genau ein Sonderzeichen aus einer Menge von 30 Sonderzeichen sowie genau einen Großbuchstaben aus 26 möglichen Großbuchstaben enthalten. Die verbleibenden sechs Zeichen dürfen aus den 10 Ziffern oder den 26 Kleinbuchstaben gewählt werden. Wie viele Möglichkeiten gibt es für die Erstellung des Passworts, wenn
- Ziffern und Buchstaben beliebig oft wiederholt werden dürfen.
 - Ziffern und Buchstaben jeweils nur einmal vorkommen dürfen.

$$\text{i) } \underbrace{\binom{30}{1} \cdot \binom{26}{1} \cdot 36^6}_{\text{Auswahlmöglichkeiten der Zeichen}} \cdot \underbrace{8 \cdot 7}_{\substack{\text{Anordnungs-} \\ \text{möglichkeiten} \\ \text{der Zeichen}}} \approx 9,51 \cdot 10^{13}$$

$$\text{ii) } \underbrace{\binom{30}{1} \cdot \binom{26}{1} \cdot \binom{36}{6}}_{\text{Auswahlmöglichkeiten der Zeichen}} \cdot \underbrace{P(8)}_{\substack{\text{Anordnungs-} \\ \text{möglichkeiten} \\ \text{der Zeichen}}} = 30 \cdot 26 \cdot \binom{36}{6} \cdot 8! \approx 6,13 \cdot 10^{13}$$

- d) Sie erstellen eine Playlist auf der Musik-App Ihrer Wahl. Aus 50 als Favorit markierten Songs möchten Sie 9 Songs für Ihre neue Playlist auswählen, wobei die Reihenfolge keine Rolle spielen soll. Ein Song kann mehrfach in die Playlist aufgenommen werden. Wie viele unterschiedliche Playlists aus 9 Songs können Sie erstellen?

$$K^W(50; 9) = \binom{50+9-1}{9} \approx 1,0649 \cdot 10^{10}$$

Aufgabe 14 Lösungen

- a) Zeigen Sie mit einem formalen Rechengang, dass folgende Gleichungen allgemein gelten und verbalisieren Sie ihr Ergebnis.

$$\text{i) } P^W(n; \underbrace{1, \dots, 1}_{n\text{-mal}}) = P(n) \qquad \text{ii) } K(n; n-1) = V(n; 1)$$

$$\text{i) } P^W(n; \underbrace{1, \dots, 1}_{n\text{-mal}}) = \frac{n!}{1! \cdot \dots \cdot 1!} = \frac{n!}{(1!)^n} = n! = P(n)$$

☞ Wenn wir n Elemente in n unterscheidbare Gruppen mit jeweils genau *einem* Element aufteilen (können), so sind alle Elemente paarweise unterscheidbar, und die Formel für Permutationen mit Wiederholungen reduziert sich auf die Formel für Permutationen ohne Wiederholung.

$$\text{ii) } K(n; n-1) = \binom{n}{n-1} = \frac{n!}{(n-1)!(n-(n-1))!} = \frac{n!}{(n-1)!(n-n+1)!} = \frac{n!}{(n-1)! \cdot 1!} = V(n; 1) = n$$

☞ Bei der Kombination wählen wir aus n Elementen genau $n-1$ aus. Das ist äquivalent dazu festzulegen, welches *eine Element im letzten Zug nicht ausgewählt* wird. Dafür gibt es offensichtlich n Möglichkeiten.

Bei der Variation *wählen* wir aus n Elementen genau *ein Element im ersten Zug* aus. Hierfür gibt es auch n Möglichkeiten.

- b) Zeigen Sie mit einem formalen Rechengang, dass die folgenden Ungleichungen für $r > 1$ gelten und verbalisieren Sie ihr Ergebnis.

i) $V(n; r) < V^W(n; r)$

ii) $K(n; r) < V(n; r)$

i) Für $r > 1$ gilt:

$$\begin{aligned} V(n; r) &= \frac{n!}{(n-r)!} = \prod_{k=1}^r (n-k+1) \\ &= \underbrace{n \cdot (n-1) \cdot \dots \cdot (n-r+1)}_{r\text{-mal}} \\ &< \underbrace{n \cdot n \cdot \dots \cdot n}_{r\text{-mal}} = n^r = V^W(n; r) \end{aligned}$$

☞ Wird mehr als einmal ($r > 1$) aus einer Urne gezogen und die Reihenfolge der Ziehungen berücksichtigt (**Variation**), so unterscheidet sich die Anzahl der Auswahlmöglichkeiten je nachdem, ob mit oder ohne Zurücklegen gezogen wird.

Beim Ziehen **ohne Zurücklegen** (d.h. ohne Wiederholung) stehen beim ersten Zug n Elemente zur Auswahl, beim zweiten $n-1$, beim dritten $n-2$, usw.. Beim letzten Zug stehen $(n-r+1)$ Elemente zur Auswahl. Die Anzahl der Auswahlmöglichkeiten nimmt also mit jedem Zug ab.

Wird dagegen **mit Zurücklegen** (d.h. mit Wiederholung) gezogen, so stehen bei jedem Zug n Elemente zur Auswahl. Die Anzahl der Auswahlmöglichkeiten bleibt daher in jedem Zug gleich. Die Anzahl der Auswahlmöglichkeiten ist also beim Ziehen mit Zurücklegen größer.

ii) Für $r > 1$ gilt:

$$K(n; r) = \binom{n}{r} = \frac{n!}{r!(n-r)!} < \frac{n!}{(n-r)!} = V(n; r)$$

☞ Wird mehr als einmal ($r > 1$) aus einer Urne *ohne Zurücklegen* (d.h. ohne Wiederholung) gezogen, so unterscheidet sich die Anzahl der Auswahlmöglichkeiten je nachdem, ob die Reihenfolge der Ziehungen berücksichtigt (Variation) oder nicht berücksichtigt (Kombination) wird.

Wählt man r unterscheidbare Elemente aus n Elementen aus, so lassen sich diese r Elemente auf $r!$ verschiedene Arten *anordnen* (Permutation).

Bei der **Variation ohne Wiederholung** werden dieselben $r!$ Anordnungen als $r!$ *verschiedene (geordnete) Auswahlen* (Variation) gezählt.

Bei der **Kombination ohne Wiederholung** werden die $r!$ möglichen Anordnungen von r ausgewählten Elementen zu *einer einzigen (ungeordneten) Auswahl* (Kombination) zusammengefasst; in der Formel muss man also durch $r!$ teilen. Das bedeutet, jede Kombination entspricht genau $r!$ verschiedenen Variationen, weshalb die Anzahl der Auswahlmöglichkeiten bei Kombinationen kleiner ist.

💬 *Begründung:*

Beispielsweise würden wir bei einer Ziehung von $r = 3$ Elementen aus der in Teil A genannten Urne die Ereignisse $\{w, b, s\}$, $\{w, s, b\}$, $\{b, w, s\}$, $\{b, s, w\}$, $\{s, w, b\}$, $\{s, b, w\}$ nicht unterscheiden, wenn die Reihenfolge keine Rolle spielt (Kombination). Daher müssen wir die $r! = 3! = 6$ verschiedenen möglichen Anordnungen der gleichen Elemente aus der Zählung „herausrechnen“.

✚ *Zusatz:*

– Es kann ebenso gezeigt werden, dass für $r > 1$ die folgenden Ungleichungen gelten:

$$K(n; r) < K^W(n; r) \quad \text{und} \quad K^W(n; r) < V^W(n; r)$$

– Ziehen wir nur einmal ($r = 1$) macht es keinen Unterschied, ob wir *mit/ohne Zurücklegen* ($\hat{=}$ mit/ohne Wiederholung) und *mit/ohne Beachtung der Reihenfolge* (also als Variation/Kombination) ziehen.

Hinweis:

An dieser Stelle bietet es sich an zu überprüfen, wie sich die Aussagen i) und ii) für den Grenzfalle $r = 1$ verändern ($\leq$). Zudem empfiehlt es sich, die Lösung der Ungleichungen unter Berücksichtigung dieses Zusatzes vollumfänglich zu validieren.

- c) Erklären Sie, wie sich die Formel der Kombination ohne Wiederholung aus der Permutation mit Wiederholung ergibt.

Bei einer **Kombination ohne Wiederholung** werden r Elemente aus n unterscheidbaren Elementen ausgewählt, ohne die Reihenfolge zu beachten und ohne Zurücklegen (d.h. ohne Wiederholung). Zunächst betrachtet man alle möglichen Anordnungen der n unterscheidbaren Elemente, was $n!$ Anordnungsmöglichkeiten ergibt (Permutation).

Da nur r Elemente ausgewählt werden, werden die übrigen $(n - r)$ Elemente nicht berücksichtigt; dies wird durch Division durch $(n - r)!$ korrigiert. Außerdem spielt die Reihenfolge der r ausgewählten Elemente keine Rolle, weshalb man zusätzlich durch $r!$ teilt.

$$K(n; r) = \frac{n!}{r! \cdot (n - r)!}$$

Da die Reihenfolge der r ausgewählten und der $(n - r)$ nicht-ausgewählten Elemente keine Rolle spielt, können die Elemente innerhalb jeder Gruppe als *nicht unterscheidbar* betrachtet werden. Auf diese Weise entsteht eine Einteilung der n Elemente in *zwei unterscheidbare Gruppen*:

- die r ausgewählten Elemente,
- die $n - r$ nicht ausgewählten Elemente.

Dies entspricht genau der Definition einer **Permutation mit Wiederholung** für zwei Gruppen:

$$P^W(n; \underbrace{p, q}_{2 \text{ Gruppen}}) = \frac{n!}{p! \cdot q!} \quad \text{mit } p := r \quad \text{und} \quad q := n - r.$$

2.2 Diskrete Zufallsvariablen

Aufgabe 15

Teil A

Betrachtet wird das folgende Zufallsexperiment: Eine faire Münze wird **einmal** geworfen. Fällt Zahl, so erhalten Sie 1,5 Euro; fällt Kopf so erhalten Sie 0 Euro.

- Definieren Sie eine geeignete Zufallsvariable X , die den Auszahlungsbetrag in Euro beschreibt. Geben Sie den Definitions- und Wertebereich von X an. Ist X eine diskrete oder stetige Zufallsvariable? Begründen Sie.
- Skizzieren Sie die Wahrscheinlichkeitsfunktion von X . Wie ist X verteilt?
- Berechnen Sie den Erwartungswert und die Varianz von X und interpretieren Sie diese Kennzahlen im Kontext der Aufgabe.
- Das beschriebene Zufallsexperiment wird nun unabhängig 10-mal wiederholt. Sie beobachten 4-mal Kopf und 6-mal Zahl. Skizzieren Sie die empirische relative Häufigkeitsfunktion von X unter der beobachteten Stichprobe in einem Stabdiagramm. Bestimmen Sie das arithmetische Mittel und die empirische Varianz.
- Wie vermuten Sie, verändern sich die in d) berechneten empirischen Kennzahlen bei einem unendlich-fachen Münzwurf. Wie würde die empirische relative Häufigkeitsfunktion von X nun aussehen?

Teil B

Sei nun das Zufallsexperiment eines **dreifachen** Wurfs einer fairen Münze gegeben. Es werden zwei unterschiedliche Auszahlungsregeln betrachtet:

Regel 1 Der Auszahlungsbetrag entspricht der Anzahl der geworfenen Ergebnisse „Kopf“.

Regel 2 Es wird ausschließlich das Ergebnis des ersten Wurfs berücksichtigt:

- Zeigt der erste Wurf „Kopf“, so erhalten Sie 0 Euro.
- Zeigt der erste Wurf „Zahl“, so erhalten Sie 3 Euro.

Sei Q der Auszahlungsbetrag nach Regel 1 und R der Auszahlungsbetrag nach Regel 2.

- Geben Sie die Ergebnismenge Ω dieses Zufallsexperiments (3-facher Münzwurf) an und berechnen Sie $|\Omega|$. Liegt ein Laplace-Experiment vor?
- Geben Sie die Wahrscheinlichkeitsfunktion von Q tabellarisch an. Berechnen Sie den Erwartungswert und die Varianz von Q .

- h) Erläutern Sie, dass die Gesamtheit der Wahrscheinlichkeiten aller Realisierungen von Q eine Wahrscheinlichkeitsverteilung bildet.
- i) Geben Sie die Wahrscheinlichkeitsfunktion von R tabellarisch an. Berechnen Sie den Erwartungswert und die Varianz von R .
- j) Entscheiden Sie, welche Regel Sie theoretisch bevorzugen würden. Diskutieren Sie, welche Rolle die Varianz für Ihre Entscheidung spielen könnte.

Teil C

Nun werden beide Regeln **gleichzeitig** auf das Ergebnis des dreifachen Münzwurfs angewendet. Sei $M := Q \cdot R$ die Zufallsvariable, die dem Zufallsexperiment zugrunde liegt, bei dem Regel 1 den Basisauszahlungsbetrag bestimmt und Regel 2 diesen vervielfachen kann.

- k) Skizzieren Sie die Wahrscheinlichkeitsfunktion von M . Berechnen Sie den Erwartungswert und die Varianz von M .
- l) Berechnen Sie die Wahrscheinlichkeiten des Ereignisses $\{M \geq 3\}$ und visualisieren sie diese in der Wahrscheinlichkeitsfunktion von M .
- m) Berechnen Sie die Kovarianz zwischen Q und R und interpretieren Sie das Ergebnis im Kontext der Aufgabe.
- n) Sind Q und R stochastisch unabhängig?

Darüber hinaus sei eine weitere Zufallsvariable $S := Q + R$ definiert.

- o) Definieren Sie S inhaltlich.
- p) Berechnen Sie den Erwartungswert und die Varianz von S .

Teil D

Zur Analyse des Zusammenhangs zwischen den beiden Regeln wird nun die gemeinsame Verteilung der Zufallsvariablen Q und R betrachtet.

- q) Geben Sie die gemeinsame Wahrscheinlichkeitsfunktion von (Q, R) tabellarisch an.
- r) Berechnen Sie die Wahrscheinlichkeit des Ereignisses $\{Q > 1\} \cap \{R = 3\}$.
- s) Prüfen Sie anhand der gemeinsamen Wahrscheinlichkeitsfunktion, ob Q und R stochastisch unabhängig sind.
- t) Ermitteln und skizzieren Sie die bedingte Wahrscheinlichkeitsfunktion von Q , falls $R = 0$.

Übersicht: Wahrscheinlichkeitstheorie vs. deskriptive Statistik

In der **Wahrscheinlichkeitstheorie (WT)** (auch *Stochastik* genannt) ist der *Zufall/Zufallsprozess/Zufallsexperiment* bekannt und wird mittels Wahrscheinlichkeiten beschrieben. Für diskrete Zufallsvariablen wird dieser Zufall also in der *Wahrscheinlichkeitsfunktion* „gespeichert“.

⚠ In der WT werden (noch) keine Daten beobachtet!

☞ Die WT studiert die theoretischen Eigenschaften/das Verhalten des Zufalls, z.B. Erwartungswert, Varianz und Wahrscheinlichkeitsfunktion, und hilft dadurch die zukünftigen Daten, die aus diesem Zufallsexperiment stammen, besser zu verstehen, sobald wir diese beobachten.

✍ X ist eine Zufallsvariable.

In der deskriptiven **Statistik** sind die Daten bekannt/beobachtet und werden mittels Häufigkeiten (Häufigkeitsverteilungen) beschrieben.

⚠ Der zugrunde liegende „wahre“ Zufall ist unbekannt!

☞ Die Statistik studiert die Eigenschaften der Daten, z.B. arithmetisches Mittel, empirische Varianz und Häufigkeitsfunktion, und dient dem Rückschluss auf den zugrunde liegenden wahren Zufall, der „in den Daten steckt“.

✍ X ist ein statistisches Merkmal.

Übersicht: Erwartungswert vs. arithmetisches Mittel

Der **Erwartungswert** einer Zufallsvariable X , $\mathbb{E}(X)$, ist ein (theoretisches) Maß der WT, welches den durchschnittlichen Wert der Zufallsvariable X angibt, den man erwartet, wenn man das zugrunde liegenden Zufallsexperiments unendlich oft wiederholt. Für **diskrete** Zufallsvariablen kann er als ein „mit Wahrscheinlichkeiten gewichtetes arithmetisches Mittel“ verstanden werden:

$$\mathbb{E}(X) = \sum_x x \mathbb{P}(X = x),$$

wobei die Summe über die Menge aller möglichen Realisierungen x von X läuft.

Das **arithmetische Mittel** ist ein (empirisches) Maß der Statistik, welches den durchschnittlichen Wert des statistischen Merkmals X in einer beobachteten Stichprobe angibt. Er beschreibt den „Schwerpunkt“ der Daten *in dieser einen Stichprobe*:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{bzw.} \quad \bar{x} = \sum_j a_j \cdot f(a_j)$$

Aufgabe 15 Lösungen

Teil A

Betrachtet wird das folgende Zufallsexperiment: Eine faire Münze wird **einmal** geworfen. Fällt Zahl, so erhalten Sie 1,5 Euro; fällt Kopf so erhalten Sie 0 Euro.

- a) Definieren Sie eine geeignete Zufallsvariable X , die den Auszahlungsbetrag in Euro beschreibt. Geben Sie den Definitions- und Wertebereich von X an. Ist X eine diskrete oder stetige Zufallsvariable? Begründen Sie.

Eine geeignete Zufallsvariable $X: \Omega \rightarrow A$ ist definiert durch

$$X := \begin{cases} 1,5, & \text{falls Zahl,} \\ 0, & \text{falls Kopf.} \end{cases}$$


mit dem Definitionsbereich $\Omega = \{\text{Kopf}, \text{Zahl}\} = \{K, Z\}$ und dem Wertebereich $A = \{1,5; 0\}$. Die Zufallsvariable X ist *diskret*, da sie nur endlich viele Werte annimmt.

🔗 *Synonyme:*

- Definitionsbereich einer Zufallsvariable: Ergebnismenge Ω
- Wertebereich einer Zufallsvariable: alle (möglichen) Realisierungen

- b) Skizzieren Sie die Wahrscheinlichkeitsfunktion von X . Wie ist X verteilt?

Wahrscheinlichkeitsfunktion von X :



$$\mathbb{P}(X = x) = \begin{cases} \frac{1}{2}, & x = 0, \\ \frac{1}{2}, & x = 1,5, \\ 0, & \text{sonst.} \end{cases}$$

Die Zufallsvariable X ist *diskret gleichverteilt auf $\{0; 1,5\}$* , da alle Realisierungen die gleiche Eintrittswahrscheinlichkeit aufweisen.

Fortsetzung:

 *Notation* alternativer Darstellungsweisen der W'fkt. für $X \in \{0; 1,5\}$

– punktweise: $\mathbb{P}(X = 0) = \mathbb{P}(X = 1,5) = \frac{1}{2}$

– tabellarisch:

x	0	$1,5$
$\mathbb{P}(X = x)$	$\frac{1}{2}$	$\frac{1}{2}$

Definition: Diskrete Gleichverteilung

Eine diskrete Zufallsvariable X heißt *diskret gleichverteilt auf* $\{x_1, x_2, \dots, x_k\}$, falls

$$\mathbb{P}(X = x_i) = \frac{1}{k} \quad \text{für alle } i = 1, \dots, k$$

gilt, d.h. alle Realisierungen die gleiche Eintrittswahrscheinlichkeit besitzen. Für die diskrete Gleichverteilung ist der Verteilungsparameter die Menge aller Realisierungen, also $\{x_1, \dots, x_k\}$.⁽¹⁾ Diese Menge bestimmt die Verteilung vollständig.

In der Literatur⁽²⁾ sind unter anderem folgende Kurzschreibweisen gebräuchlich:

$$X \sim U(\{x_1, \dots, x_k\})$$

$$\text{oder } X \sim Unif(\{x_1, \dots, x_k\})$$

$$\text{oder } X \sim Uniform(\{x_1, \dots, x_k\})$$

$$\text{oder } X \sim DiscreteUniform(\{x_1, \dots, x_k\})$$

Quellen:

⁽¹⁾ Ludwig Fahrmeir, Christian Heumann, Rita Künstler, Iris Pigeot, Gerhard Tutz (2016): Statistik. Der Weg zur Datenanalyse. 8. Auflage. Springer, Berlin/Heidelberg. S. 219

⁽²⁾ z.B. Mathias Trabs, Moritz Jirak, Konstantin Krenz, Markus Reiß (2021): Statistik und maschinelles Lernen. Eine mathematische Einführung in klassische und moderne Methoden. Springer Spektrum, Berlin/Heidelberg. S. 252, Def. A.44

- c) Berechnen Sie den Erwartungswert und die Varianz von X und interpretieren Sie diese Kennzahlen im Kontext der Aufgabe.

Der Erwartungswert von X ist

$$\mathbb{E}(X) = \sum_{x \in \{0, 1, 5\}} x \cdot \mathbb{P}(X = x) = 0 \cdot \mathbb{P}(X = 0) + 1,5 \cdot \mathbb{P}(X = 1,5) = 0 \cdot \frac{1}{2} + 1,5 \cdot \frac{1}{2} = 0,75,$$

🧩 *Interpretation:*

Wird das Zufallsexperiment (einfacher Münzwurf) *unendlich oft wiederholt*, so ist ein *durchschnittlicher* Auszahlungsbetrag von 0,75 Euro pro Wurf *zu erwarten*.

Die Varianz von X ist

$$\text{Var}(X) = \sum_{x \in \{0, 1, 5\}} (x - \mathbb{E}(X))^2 \cdot \mathbb{P}(X = x) = (0 - 0,75)^2 \cdot \frac{1}{2} + (1,5 - 0,75)^2 \cdot \frac{1}{2} = \frac{9}{16}.$$

Alternativ mittels $\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$:

$$\text{Es gilt } \mathbb{E}(X^2) = \sum_{x \in \{0, 1, 5\}} x^2 \cdot \mathbb{P}(X = x) = 0^2 \cdot \frac{1}{2} + 1,5^2 \cdot \frac{1}{2} = 1,125.$$


$$\text{Also } \text{Var}(X) = 1,125 - 0,75^2 = \frac{9}{16}$$

🧩 *Interpretation:*

Die theoretische, zu erwartende quadratische Abweichung des Auszahlungsbetrags vom Erwartungswert beträgt $\frac{9}{16} = 0,5625$ Euro².

- d) Das beschriebene Zufallsexperiment wird nun unabhängig 10-mal wiederholt. Sie beobachten 4-mal Kopf und 6-mal Zahl. Skizzieren Sie die empirische relative Häufigkeitsfunktion von X unter der beobachteten Stichprobe in einem Stabdiagramm. Bestimmen Sie das arithmetische Mittel und die empirische Varianz.

Empirische relative Häufigkeitsfunktion von X :



$$f(a) = \begin{cases} \frac{4}{10}, & a = 0, \\ \frac{6}{10}, & a = 1,5, \\ 0, & \text{sonst.} \end{cases}$$

Fortsetzung:

Arithmetisches Mittel: $\bar{x} = \sum_{j=1}^2 a_j \cdot f(a_j) = 0 \cdot \frac{4}{10} + 1,5 \cdot \frac{6}{10} = 0,9$

 *Interpretation:*

In der vorliegenden Stichprobe des Umfangs $n = 10$ (also bei einer 10-fachen Werfens einer Münze) beträgt der beobachtete durchschnittliche Auszahlungsbetrag 0,9 Euro pro Wurf.

Empirische Varianz: $s^2 = \sum_{j=1}^2 (a_j - \bar{x})^2 \cdot f(a_j) = (0 - 0,9)^2 \cdot \frac{4}{10} + (1,5 - 0,9)^2 \cdot \frac{6}{10} = 0,54$

 *Interpretation:*

In der vorliegenden Stichprobe des Umfangs $n = 10$ (also bei einer 10-fachen Werfens einer Münze) beträgt die durchschnittliche quadratische Abweichung des Auszahlungsbetrag vom arithmetischen Mittel 0,54 Euro².

- e) Wie vermuten Sie, verändern sich die in d) berechneten empirischen Kennzahlen bei einem unendlich-fachen Münzwurf. Wie würde die empirische relative Häufigkeitsfunktion von X nun aussehen?

Für $n \rightarrow \infty$ konvergieren die in d) berechneten empirischen Kennzahlen gegen ihre theoretischen Werte, sodass

$$\bar{x} \approx \mathbb{E}(X) \quad \text{und} \quad s^2 \approx \text{Var}(X)$$

gilt. Die empirische relative Häufigkeitsfunktion $f(a_j)$ stimmt mit wachsendem Stichprobenumfang „immer besser“ mit der theoretischen Wahrscheinlichkeitsfunktion der Zufallsvariable X , $\mathbb{P}(X = x)$, überein.

 *Begründung:*

Bei endlich vielen Beobachtungen können empirische Kennzahlen noch von den theoretischen Werten abweichen, da zufällige Schwankungen in der Stichprobe auftreten. Mit zunehmender Stichprobengröße werden diese Schwankungen jedoch immer kleiner und verschwinden im Grenzfall.

Man sagt auch, dass sich empirischen Kennzahlen und die relative Häufigkeitsfunktion *asymptotisch* den theoretischen Werten nähern.

Das *Gesetz der Großen Zahlen* formalisiert dies für das arithmetische Mittel und den Erwartungswert.

Teil B

Sei nun das Zufallsexperiment eines **dreifachen** Wurfs einer fairen Münze gegeben. Es werden zwei unterschiedliche Auszahlungsregeln betrachtet:

Regel 1 Der Auszahlungsbetrag entspricht der Anzahl der geworfenen Ergebnisse „Kopf“.

Regel 2 Es wird ausschließlich das Ergebnis des ersten Wurfs berücksichtigt:

- Zeigt der erste Wurf „Kopf“, so erhalten Sie 0 Euro.
- Zeigt der erste Wurf „Zahl“, so erhalten Sie 3 Euro.

Sei Q der Auszahlungsbetrag nach Regel 1 und R der Auszahlungsbetrag nach Regel 2.

- f) Geben Sie die Ergebnismenge Ω dieses Zufallsexperiments (3-facher Münzwurf) an und berechnen Sie $|\Omega|$. Liegt ein Laplace-Experiment vor?

$$\Omega = \{(KKK); (KKZ); (KZK); (ZKK); (KZZ); (ZKZ); (ZZK); (ZZZ)\}$$

$$|\Omega| = 8 \text{ oder } |\Omega| = V^W(2; 3) = 2^3 = 8 \text{ (Variation mit Wiederholung)}$$

Es handelt sich um ein Laplace-Experiment, da alle *Elementarereignisse* $\omega \in \Omega$ (auch *Ergebnisse* genannt) gleich wahrscheinlich sind.

Es gilt hier also für alle $\omega_j \in \Omega$ mit $j = 1, \dots, 8$: $\mathbb{P}(\omega_j) = \frac{1}{|\Omega|} = \frac{1}{8}$.

- g) Geben Sie die Wahrscheinlichkeitsfunktion von Q tabellarisch an. Berechnen Sie den Erwartungswert und die Varianz von Q .

Wahrscheinlichkeitsfunktion für $Q \in \{0, 1, 2, 3\}$:

q	0	1	2	3
$\mathbb{P}(Q = q)$	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{3}{8}$	$\frac{1}{8}$

Für den Erwartungswert und die Varianz gilt:

$$\mathbb{E}(Q) = 0 \cdot \frac{1}{8} + 1 \cdot \frac{3}{8} + 2 \cdot \frac{3}{8} + 3 \cdot \frac{1}{8} = 1,5$$

$$\text{Var}(Q) = \mathbb{E}(Q^2) - [\mathbb{E}(Q)]^2 = 3 - 1,5^2 = 0,75,$$

$$\text{wobei } \mathbb{E}(Q^2) = 0^2 \cdot \frac{1}{8} + 1^2 \cdot \frac{3}{8} + 2^2 \cdot \frac{3}{8} + 3^2 \cdot \frac{1}{8} = 3$$

- h) Erläutern Sie, dass die Gesamtheit der Wahrscheinlichkeiten aller Realisierungen von Q eine Wahrscheinlichkeitsverteilung bildet.

$(\mathbb{P}(Q = 0), \mathbb{P}(Q = 1), \mathbb{P}(Q = 2), \mathbb{P}(Q = 3)) = (\frac{1}{8}, \frac{3}{8}, \frac{3}{8}, \frac{1}{8})$ ist die Wahrscheinlichkeitsverteilung von Q , da **(i)** die Wahrscheinlichkeit jedes *Einzelereignisses* (auch *Punkt ereignis* genannt) jeweils größer oder gleich null ist und **(ii)** sich alle zusammen zu 1 aufsummieren (vgl. Begründung zu Aufgabe 9 Teil B d)).

- i) Geben Sie die Wahrscheinlichkeitsfunktion von R tabellarisch an. Berechnen Sie den Erwartungswert und die Varianz von R .

Wahrscheinlichkeitsfunktion für $R \in \{0, 3\}$:

r	0	3
$\mathbb{P}(R = r)$	$\frac{1}{2}$	$\frac{1}{2}$

Für den Erwartungswert und die Varianz gilt:

$$\mathbb{E}(R) = 0 \cdot \frac{1}{2} + 3 \cdot \frac{1}{2} = 1,5$$

$$\text{Var}(R) = \mathbb{E}(R^2) - [\mathbb{E}(R)]^2 = 4,5 - 1,5^2 = 2,25,$$

$$\text{wobei } \mathbb{E}(R^2) = 0^2 \cdot \frac{1}{2} + 3^2 \cdot \frac{1}{2} = 4,5$$

Alternativ: Wir erkennen, dass $R = 2X$ eine *Funktion von* X ist. Das bedeutet, dass jede Realisierung von R durch die entsprechende Realisierung von X bestimmt wird. Folglich gilt für die möglichen Werte: $R \in \{2 \cdot 0, 2 \cdot 1,5\} = \{0, 3\}$. Da R eine eindeutige Funktion von X ist, gibt es keine neuen Zufallsereignisse, die von X unabhängig sind, die Wahrscheinlichkeiten der Realisierungen ändern sich also nicht, nur die Werte werden transformiert: Es gilt $\mathbb{P}(R = r) = \mathbb{P}(X = x)$ für $r = 2x$.

$$\text{Weiter gilt } \mathbb{E}(R) = \mathbb{E}(2X) = 2 \cdot \mathbb{E}(X) \stackrel{c)}{=} 2 \cdot 0,75 = 1,5$$

$$\text{und } \text{Var}(R) = \text{Var}(2X) = 2^2 \cdot \text{Var}(X) \stackrel{c)}{=} 4 \cdot \frac{9}{16} = 2,25$$

- j) Entscheiden Sie, welche Regel Sie theoretisch bevorzugen würden. Diskutieren Sie, welche Rolle die Varianz für Ihre Entscheidung spielen könnte.


Da $\mathbb{E}(Q) = \mathbb{E}(R) = 1,5$ gilt, sind beide Regeln hinsichtlich des Erwartungswertes gleichwertig. Für die Entscheidung kann daher die Varianz als Maß der Unsicherheit herangezogen werden. Da $\text{Var}(Q) = 0,75 < 2,25 = \text{Var}(R)$ gilt, ist Regel 1 für risikoaverse Personen zu bevorzugen, während Regel 2 für risikofreudige Personen attraktiver ist.

Teil C

Nun werden beide Regeln **gleichzeitig** auf das Ergebnis des dreifachen Münzwurfs angewendet. Sei $M := Q \cdot R$ die Zufallsvariable, die dem Zufallsexperiment zugrunde liegt, bei dem Regel 1 den Basisauszahlungsbetrag bestimmt und Regel 2 diesen vervielfachen kann.

- k) Skizzieren Sie die Wahrscheinlichkeitsfunktion von M . Berechnen Sie den Erwartungswert und die Varianz von M .

Wahrscheinlichkeitsfunktion für $M \in \{0, 3, 6, 9\}$:



☺ *Begründung:*

Wir überlegen zunächst welche Werte M annehmen kann. Es ist $M = Q \cdot R$ mit $Q \in \{0, 1, 2, 3\}$, $R \in \{0, 3\}$. Also $M \in \{0 \cdot 0, 0 \cdot 3, 1 \cdot 0, 1 \cdot 3, 2 \cdot 0, 2 \cdot 3, 3 \cdot 0, 3 \cdot 3\} = \{0, 3, 6, 9\}$. Da $M: \Omega \rightarrow \{0, 3, 6, 9\}$ gilt

$$\begin{aligned} M(KKK) &= M(KKZ) = M(KZK) = M(KZZ) = M(ZZZ) = 0, \\ M(ZKZ) &= M(ZZK) = 3, \\ M(ZKK) &= 6. \end{aligned}$$

Wir beobachten, dass das Ereignis $\{M = 9\}$ mit Wahrscheinlichkeit null eintritt, es sich also hierbei um ein *unmögliches Ereignis* (auch *Nullereignis* genannt) handelt. Das Ereignis gehört jedoch formal zum Wertebereich von M dazu, da der Wert 9 rechnerisch aus der Definition $M := Q \cdot R$ folgt, auch wenn es in *diesem* zugrundeliegenden Wahrscheinlichkeitsmodell kein Elementarereignis $\omega \in \Omega$ gibt, für das $M(\omega) = 9$ gilt.

Fortsetzung zu k):

Für den Erwartungswert und die Varianz gilt:


$$\mathbb{E}(M) = 0 \cdot \frac{5}{8} + 3 \cdot \frac{2}{8} + 6 \cdot \frac{1}{8} + 9 \cdot 0 = 1,5$$

$$\text{Var}(M) = \mathbb{E}(M^2) - [\mathbb{E}(M)]^2 = 6,75 - 1,5^2 = 4,5,$$

$$\text{wobei } \mathbb{E}(M^2) = 0^2 \cdot \frac{5}{8} + 3^2 \cdot \frac{2}{8} + 6^2 \cdot \frac{1}{8} + 9^2 \cdot 0 = 6,75$$

- l) Berechnen Sie die Wahrscheinlichkeiten des Ereignisses $\{M \geq 3\}$ und visualisieren sie diese in der Wahrscheinlichkeitsfunktion von M .

$\mathbb{P}(M \geq 3) = \mathbb{P}(M = 3) + \mathbb{P}(M = 6) + \mathbb{P}(M = 9) = \frac{2}{8} + \frac{1}{8} + 0 = \frac{3}{8}$ oder über das Gegenereignis $\mathbb{P}(M \geq 3) = 1 - \mathbb{P}(M < 3) = 1 - \mathbb{P}(M = 0) = 1 - \frac{5}{8} = \frac{3}{8}$



👉 Graphischer Zusammenhang: Die Einzelwahrscheinlichkeiten (auch Punktwahrscheinlichkeiten genannt; hier visualisiert durch „Stäbe“) werden aufsummiert.

✍ Notation:

Für die Wahrscheinlichkeit eines Ereignis $A \subseteq \Omega$, hier: $A := \{M \geq 3\}$, schreibt man oft einfach $\mathbb{P}(M \geq 3)$ anstatt $\mathbb{P}(\{M \geq 3\})$. Beide Schreibweisen sind korrekt.

- m) Berechnen Sie die Kovarianz zwischen Q und R und interpretieren Sie das Ergebnis im Kontext der Aufgabe.

$$\text{Cov}(Q, R) = \underbrace{\mathbb{E}(Q \cdot R)}_{=\mathbb{E}(M)} - \mathbb{E}(Q) \cdot \mathbb{E}(R) = 1,5 - 1,5 \cdot 1,5 = -0,75$$

 *Interpretation:*

Zwischen den beiden Auszahlungsregeln liegt ein negativer linearer Zusammenhang vor, d.h. dies bedeutet, dass hohe Auszahlungen nach Regel 1 tendenziell mit niedrigen Auszahlungen nach Regel 2 einhergehen und umgekehrt.

- n) Sind Q und R stochastisch unabhängig?

Aus $\text{Cov}(Q, R) \stackrel{m)}{=} -0,75 \neq 0$ folgt, dass Q und R stochastisch abhängig sind.

 *Begründung:*

Zwischen der Kovarianz und stochastischer Unabhängigkeit zweier Zufallsvariablen gilt der folgende Zusammenhang:

$$\begin{aligned} \text{Cov}(X, Y) \neq 0 &\implies X \text{ und } Y \text{ sind stochastisch abhängig,} \\ X \text{ und } Y \text{ sind stochastisch \underline{un}abhängig} &\implies \text{Cov}(X, Y) = 0. \end{aligned}$$

In Worten: Ist die Kovarianz von X und Y ungleich null, so besteht ein linearer Zusammenhang zwischen den beiden Zufallsvariablen und diese sind somit voneinander stochastisch abhängig. Sind X und Y dagegen stochastisch unabhängig, dann ist ihre Kovarianz gleich null.

Die Umkehrungen dieser Aussagen gelten im Allgemeinen nicht!

Darüber hinaus sei eine weitere Zufallsvariable $S := Q + R$ definiert.

- o) Definieren Sie S inhaltlich.

S : „Gemeinsamer Auszahlungsbetrag nach Regel 1 und Regel 2“

- p) Berechnen Sie den Erwartungswert und die Varianz von S .

$$\mathbb{E}(S) = \mathbb{E}(Q + R) = \mathbb{E}(Q) + \mathbb{E}(R) = 1,5 + 1,5 = 3$$

$$\begin{aligned} \text{Var}(S) &= \text{Var}(Q + R) = \text{Var}(Q) + \text{Var}(R) + 2 \cdot \text{Cov}(Q, R) \\ &= 0,75 + 2,25 + 2 \cdot (-0,75) = 1,5 \end{aligned}$$

Teil D

Zur Analyse des Zusammenhangs zwischen den beiden Regeln wird nun die gemeinsame Verteilung der Zufallsvariablen Q und R betrachtet.

q) Geben Sie die gemeinsame Wahrscheinlichkeitsfunktion von (Q, R) tabellarisch an.

$R \backslash Q$	0	1	2	3	Σ
0	0	$\frac{1}{8}$	$\frac{2}{8}$	$\frac{1}{8}$	$\frac{1}{2}$
3	$\frac{1}{8}$	$\frac{2}{8}$	$\frac{1}{8}$	0	$\frac{1}{2}$
Σ	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{3}{8}$	$\frac{1}{8}$	1

☺ *Begründung:*

Einige Wahrscheinlichkeiten lassen sich direkt aus der Aufgabenstellung erkennen: So ist $\mathbb{P}(Q = 0, R = 0) = \mathbb{P}(Q = 3, R = 3) = 0$, da es unmöglich ist, nach beiden Regeln gleichzeitig den minimalen oder maximalen Auszahlungsbetrag zu erhalten. Weiter gilt beispielsweise

$$\mathbb{P}(Q = 2, R = 0) = \mathbb{P}(\{KZK\} \cup \{KKZ\}) = \mathbb{P}(\{KZK\}) + \mathbb{P}(\{KKZ\}) = \frac{1}{8} + \frac{1}{8} = \frac{2}{8}.$$

Die restlichen Wahrscheinlichkeiten der gemeinsamen Wahrscheinlichkeitsfunktion von (Q, R) ergeben sich über die Normierung der Randverteilungen, d.h.:

$$\mathbb{P}(R = r) = \sum_{q \in \{0,1,2,3\}} \mathbb{P}(Q = q, R = r) \text{ für alle } r \in \{0, 3\}$$

$$\mathbb{P}(Q = q) = \sum_{r \in \{0,3\}} \mathbb{P}(Q = q, R = r) \text{ für alle } q \in \{0, 1, 2, 3\}$$

✍ *Notation:*

Die Wahrscheinlichkeit, dass $Q = q$ und $R = r$ gleichzeitig auftreten, entspricht der Wahrscheinlichkeit des Schnittes der beiden Ereignisse:

$$\mathbb{P}(Q = q, R = r) = \mathbb{P}(\{Q = q\} \cap \{R = r\}).$$

r) Berechnen Sie die Wahrscheinlichkeit des Ereignisses $\{Q > 1\} \cap \{R = 3\}$.

$$\begin{aligned}
 & \mathbb{P}(\{Q > 1\} \cap \{R = 3\}) \\
 &= \mathbb{P}((\{Q = 2\} \cup \{Q = 3\}) \cap \{R = 3\}) \\
 &= \mathbb{P}((\{Q = 2\} \cap \{R = 3\}) \cup (\{Q = 3\} \cap \{R = 3\})), \quad (\text{Distributivgesetz}) \\
 &= \mathbb{P}(\{Q = 2\} \cap \{R = 3\}) + \mathbb{P}(\{Q = 3\} \cap \{R = 3\}), \quad (\text{Additivität von } \mathbb{P} \text{ (3.Axiom)}) \\
 &= \mathbb{P}(Q = 2, R = 3) + \mathbb{P}(Q = 3, R = 3) \\
 &= \frac{1}{8} + 0 = \frac{1}{8}
 \end{aligned}$$

s) Prüfen Sie anhand der gemeinsamen Wahrscheinlichkeitsfunktion, ob Q und R stochastisch unabhängig sind.

$$\begin{aligned}
 \text{z.B. } & \mathbb{P}(Q = 0, R = 0) = 0 \neq \frac{1}{16} = \frac{1}{2} \cdot \frac{1}{8} = \mathbb{P}(Q = 0) \cdot \mathbb{P}(R = 0) \\
 & \Rightarrow Q \text{ und } R \text{ sind stochastisch abhängig.}
 \end{aligned}$$

Zusatz: Stochastische Unabhängigkeit

 Definition der stochastische Unabhängigkeit von **Ereignissen**:

Zwei Ereignisse A und B heißen *stochastisch unabhängig*, wenn

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B).$$


 Definition der stochastische Unabhängigkeit von **zwei Zufallsvariablen**:

Zwei Zufallsvariablen X und Y heißen *stochastisch unabhängig*, wenn für alle möglichen Realisierungen x und y gilt

$$\mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x) \cdot \mathbb{P}(Y = y),$$

das heißt, die stochastische Unabhängigkeit von X und Y impliziert die stochastische Unabhängigkeit *aller* durch X und Y erzeugten Ereignisse.

- t) Ermitteln und skizzieren Sie die bedingte Wahrscheinlichkeitsfunktion von Q , falls $R = 0$.

 $\mathbb{P}(Q = q | R = 0)$ 

$$\mathbb{P}(Q = q | R = 0) = \frac{\mathbb{P}(Q = q, R = 0)}{\mathbb{P}(R = 0)}$$

$$= \begin{cases} \frac{2}{8}, & \text{falls } q = 1, \\ \frac{4}{8}, & \text{falls } q = 2, \\ \frac{2}{8}, & \text{falls } q = 3, \\ 0, & \text{sonst.} \end{cases}$$

2.3 Ereignisse und Mengen

Aufgabe 16

Sei Ω die Grundmenge. Betrachten Sie die beiden Ereignisse A und B mit $A, B \subseteq \Omega$. Nehmen Sie an, die beiden Ereignisse A und B sind nicht disjunkt, also $A \cap B \neq \emptyset$.

- a) Stellen Sie die folgenden Ereignisse als Mengenoperation dar und markieren Sie diese in einem Venn-Diagramm.
- i) A tritt ein, B jedoch nicht.
 - ii) A und B treten gleichzeitig ein.
 - iii) Weder A noch B treten ein.
 - iv) Höchstens eins der beiden Ereignisse tritt ein.
 - v) Genau eins der beiden Ereignisse tritt ein.

A tritt mit einer Wahrscheinlichkeit von 0,6 und B mit einer Wahrscheinlichkeit von 0,7 ein. Mit einer Wahrscheinlichkeit von 0,2 tritt keins der beiden Ereignisse ein.

- b) Mit welcher Wahrscheinlichkeit
- i) tritt A nicht ein?
 - ii) treten A und B gleichzeitig ein?
 - iii) tritt A ein, wenn B eingetreten ist?
 - iv) tritt A nicht ein, wenn B eingetreten ist?
 - v) tritt A ein, wenn B nicht eingetreten ist?

Geben Sie eine jeweils eine kurze Begründung.

Nehmen Sie nun an, die Ereignisse A und B seien disjunkt, also $A \cap B = \emptyset$.

- c) Begründen Sie, warum A und B nun stochastisch abhängig voneinander sind.

Aufgabe 17

Die Berliner S- und U-Bahnen sind immer wieder von wetterbedingten Ausfällen betroffen, insbesondere bei Unwetter. Beide Umstände treten, bedingt auf die Wetterlage (Unwetter oder kein Unwetter), unabhängig voneinander auf. Die Ausfallwahrscheinlichkeit der S-Bahn beträgt bei Unwetter 30%, die der U-Bahn 10%. Die U-Bahn fällt mit einer Wahrscheinlichkeit von 5% aus, wenn kein Unwetter herrscht. Zudem ist bekannt, dass die Wahrscheinlichkeit, dass die S-Bahn nicht ausfällt und gleichzeitig kein Unwetter vorliegt, 64% beträgt. Wir nehmen an, dass die Wahrscheinlichkeit für ein Unwetter über das Jahr hinweg konstant ist und 20% beträgt. Es seien die folgenden Ereignisse definiert:

$$W := \text{„Es gibt ein Unwetter.“}$$
$$S := \text{„Die S-Bahn fällt aus.“}$$
$$U := \text{„Die U-Bahn fällt aus.“}$$

- a) Formulieren Sie mithilfe der Ereignisse W , S , U die oben genannten Wahrscheinlichkeitsaussagen.
- b) Mit welcher Wahrscheinlichkeit muss man in Berlin an einem zufällig ausgewählten Tag mit dem Ausfall
 - i) der S-Bahn, bei keinem Unwetter rechnen?
 - ii) der S-Bahn rechnen?
 - iii) der U-Bahn rechnen?
 - iv) beider Bahnen rechnen?
 - v) der S-Bahn rechnen, wenn die U-Bahn ausgefallen ist?
 - vi) mindestens einer der Bahnen rechnen?
 - vii) nur der U-Bahn rechnen?
- c) Sind S und U stochastisch unabhängig?

Aufgabe 18

Es werden zwei faire Würfel gleichzeitig geworfen, ein weißer und ein roter. Es seien die folgenden Ereignisse definiert:

$A :=$ „Die geworfene Augenzahl des weißen Würfels ist gerade.“

$B :=$ „Die geworfene Augenzahl des roten Würfels ist ungerade.“

$C :=$ „Die Summe der geworfenen Augenzahlen ist gerade.“

Teil A

- a) Wieso handelt es sich um ein Zufallsexperiment? Was ist zufällig?
- b) Bestimmen Sie die Wahrscheinlichkeiten der Ereignisse A , B , C .

Teil B

Es seien die folgenden Ereignissen definiert:

$E := A \cap B = \{(2, 1); (2, 3); (2, 5); (4, 1); (4, 3); (4, 5); (6, 1); (6, 3); (6, 5)\}$

$F := A \cap C = \{(2, 2); (2, 4); (2, 6); (4, 2); (4, 4); (4, 6); (6, 2); (6, 4); (6, 6)\}$

$G := B \cap C = \{(1, 1); (1, 3); (1, 5); (3, 1); (3, 3); (3, 5); (5, 1); (5, 3); (5, 5)\}$

$H := A \cap B \cap C$

- c) Aus welchen Elementen von Ω setzt sich das Ereignis H zusammen?
- d) Bestimmen Sie die Wahrscheinlichkeiten der Ereignisse E , F , G , H .
- e) Definieren Sie das Komplementäreignis

i) $\bar{E}$ mithilfe von $\bar{A}$ und $\bar{B}$

ii) $\bar{H}$ mithilfe von $\bar{F}$ und $\bar{G}$

als Mengenoperation.

- f) Sind die Ereignisse A , B , C

i) paarweise

ii) vollständig


stochastisch unabhängig? Begründen Sie Ihre jeweilige Antwort mit Hilfe eines formalen Rechenganges.

Aufgabe 16 Lösungen


Sei Ω die Grundmenge. Betrachten Sie die beiden Ereignisse A und B mit $A, B \subseteq \Omega$. Nehmen Sie an, die beiden Ereignisse A und B sind nicht disjunkt, also $A \cap B \neq \emptyset$.

- a) Stellen Sie die folgenden Ereignisse als Mengenoperation dar und markieren Sie diese in einem Venn-Diagramm.
- i) A tritt ein, B jedoch nicht.
 - ii) A und B gleichzeitig treten ein.
 - iii) Weder A noch B treten ein.
 - iv) Höchstens eins der beiden Ereignisse tritt ein.
 - v) Genau eins der beiden Ereignisse tritt ein.


i) $(A \cap \overline{B}) = (A \setminus B)$




ii) $(A \cap B)$




iii) $(\overline{A \cap B}) = (\overline{A \cup B})$



iv) $(\overline{A \cap B})$



v) $((A \cap \overline{B}) \cup (\overline{A} \cap B))$



A tritt mit einer Wahrscheinlichkeit von 0,6 und B mit einer Wahrscheinlichkeit von 0,7 ein. Mit einer Wahrscheinlichkeit von 0,2 tritt keins der beiden Ereignisse ein.

b) Mit welcher Wahrscheinlichkeit

- i) tritt A nicht ein?
- ii) treten A und B gleichzeitig ein?
- iii) tritt A ein, wenn B eingetreten ist?
- iv) tritt A nicht ein, wenn B eingetreten ist?
- v) tritt A ein, wenn B nicht eingetreten ist?

Geben Sie eine jeweils eine kurze Begründung.

i) Mit der *Normiertheit* und der *Additivität* von $\mathbb{P}$ (vgl. 2. Axiom und 3. Axiom von Kolmogorov) gilt:

$$\Rightarrow \mathbb{P}(\bar{A}) = 1 - \mathbb{P}(A) = 1 - 0,6 = 0,4$$

ii) Mit dem *Allgemeinen Additionssatz* gilt:

$$\Rightarrow \mathbb{P}(A \cap B) = \mathbb{P}(A) + \mathbb{P}(B) - \underbrace{\mathbb{P}(A \cup B)}_{\stackrel{!}{=} 1 - \mathbb{P}(\overline{A \cup B})} = 0,6 + 0,7 - (1 - 0,2) = 0,5$$

iii) Mit dem *Satz von Bayes* gilt:

$$\Rightarrow \mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{0,5}{0,7} = \frac{5}{7}$$

iv) Mit den Regeln für die *Komplementbildung unter bedingten Wahrscheinlichkeiten* gilt:

$$\mathbb{P}(\bar{A}|B) = 1 - \mathbb{P}(A|B) = 1 - \frac{5}{7} = \frac{2}{7}$$

v) Mit dem *Satz von Bayes*, dem *Venn-Diagramm in a) i)* ($\rightarrow$ siehe auch Fußnote) und der *Normiertheit* und der *Additivität* von $\mathbb{P}$ gilt:

$$\mathbb{P}(A|\bar{B}) = \frac{\mathbb{P}(A \cap \bar{B})}{\mathbb{P}(\bar{B})} = \frac{\mathbb{P}(A) - \mathbb{P}(A \cap B)}{1 - \mathbb{P}(B)} = \frac{0,6 - 0,5}{1 - 0,7} = \frac{1}{3}$$

Hinweis:

zu v): Mit dem *Distributivgesetz* (des Schnittes über Vereinigungen) gilt

$A = (A \cap \Omega) = (A \cap (B \dot{\cup} \bar{B})) = (A \cap B) \dot{\cup} (A \cap \bar{B})$. Mit der *Additivität* von $\mathbb{P}$ folgt

$\mathbb{P}(A) = \mathbb{P}(A \cap B) + \mathbb{P}(A \cap \bar{B})$, umgestellt ergibt sich $\Rightarrow \mathbb{P}(A \cap \bar{B}) = \mathbb{P}(A) - \mathbb{P}(A \cap B) = 0,6 - 0,5$

zu iv): $\mathbb{P}(\bar{A}|B) = \frac{\mathbb{P}(\bar{A} \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B) - \mathbb{P}(B \cap A)}{\mathbb{P}(B)} = 1 - \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(B)} = 1 - \mathbb{P}(A|B)$

Nehmen Sie nun an, die Ereignisse A und B seien disjunkt, also $A \cap B = \emptyset$.

c) Begründen Sie, warum A und B nun stochastisch abhängig voneinander sind.

Zwei Ereignisse A und B heißen *disjunkt*, wenn $A \cap B = \emptyset$. Für nichttriviale Ereignisse (d.h. $\mathbb{P}(A) > 0$ und $\mathbb{P}(B) > 0$) gilt in diesem Fall, dass sie nicht gleichzeitig eintreten können, d.h. sie schließen sich gegenseitig aus. Tritt ein Ereignis ein, kann das andere nicht eintreten. In anderen Worten, das Wissen über das Eintreten des einen Ereignisses liefert Informationen über das Nicht-Eintreten des anderen Ereignisses, weshalb disjunkte Ereignisse *stochastisch abhängig* sind.

☺ *Begründung:*

Formal: Für disjunkte Ereignisse A und B mit $\mathbb{P}(A), \mathbb{P}(B) > 0$ gilt:

$$\mathbb{P}(A \cap B) = \mathbb{P}(\emptyset) = 0 \neq \mathbb{P}(A) \cdot \mathbb{P}(B) > 0,$$

also sind A und B stochastisch abhängig (vgl. Multiplikationssatz).

In der Aufgabe gilt konkret $\mathbb{P}(A \cap B) = 0 \neq 0,42 = 0,6 \cdot 0,7 = \mathbb{P}(A) \cdot \mathbb{P}(B)$

Aufgabe 17 Lösungen

Die Berliner S- und U-Bahnen sind immer wieder von wetterbedingten Ausfällen betroffen, insbesondere bei Unwetter. Beide Umstände treten, bedingt auf die Wetterlage (Unwetter oder kein Unwetter), unabhängig voneinander auf. Die Ausfallwahrscheinlichkeit der S-Bahn beträgt bei Unwetter 30%, die der U-Bahn 10%. Die U-Bahn fällt mit einer Wahrscheinlichkeit von 5% aus, wenn kein Unwetter herrscht. Zudem ist bekannt, dass die Wahrscheinlichkeit, dass die S-Bahn nicht ausfällt und gleichzeitig kein Unwetter vorliegt, 64% beträgt. Wir nehmen an, dass die Wahrscheinlichkeit für ein Unwetter über das Jahr hinweg konstant ist und 20% beträgt. Es seien die folgenden Ereignisse definiert:

$W :=$ „Es gibt ein Unwetter.“

$S :=$ „Die S-Bahn fällt aus.“

$U :=$ „Die U-Bahn fällt aus.“

- a) Formulieren Sie mithilfe der Ereignisse W , S , U die oben genannten Wahrscheinlichkeitsaussagen.

$$\begin{aligned}\mathbb{P}(W) &= 0,2 & \Rightarrow & \mathbb{P}(\overline{W}) = 0,8 \\ \mathbb{P}(S|W) &= 0,3 & \Rightarrow & \mathbb{P}(\overline{S}|W) = 0,7 \\ \mathbb{P}(U|W) &= 0,1 & \Rightarrow & \mathbb{P}(\overline{U}|W) = 0,9 \\ \mathbb{P}(U|\overline{W}) &= 0,05 & \Rightarrow & \mathbb{P}(\overline{U}|\overline{W}) = 0,95 \\ \mathbb{P}(\overline{S} \cap \overline{W}) &= 0,64\end{aligned}$$

- b) Mit welcher Wahrscheinlichkeit muss man in Berlin an einem zufällig ausgewählten Tag mit dem Ausfall
- i) der S-Bahn, bei keinem Unwetter rechnen?
 - ii) der S-Bahn rechnen?
 - iii) der U-Bahn rechnen?
 - iv) beider Bahnen rechnen?
 - v) der S-Bahn rechnen, wenn die U-Bahn ausgefallen ist?
 - vi) mindestens einer der Bahnen rechnen?
 - vii) nur der U-Bahn rechnen?

$$\begin{aligned}\text{i)} \quad \mathbb{P}(S|\overline{W}) &= 1 - \mathbb{P}(\overline{S}|\overline{W}) \stackrel{\text{Bayes}}{=} 1 - \frac{\mathbb{P}(\overline{S} \cap \overline{W})}{\mathbb{P}(\overline{W})} = 1 - \frac{0,64}{0,8} = 0,2 \\ \text{ii)} \quad \mathbb{P}(S) &\stackrel{\text{TW}}{=} \mathbb{P}(S|W) \cdot \mathbb{P}(W) + \mathbb{P}(S|\overline{W}) \cdot \mathbb{P}(\overline{W}) = 0,3 \cdot 0,2 + 0,2 \cdot 0,8 = 0,22 \\ \text{iii)} \quad \mathbb{P}(U) &\stackrel{\text{TW}}{=} \mathbb{P}(U|W) \cdot \mathbb{P}(W) + \mathbb{P}(U|\overline{W}) \cdot \mathbb{P}(\overline{W}) = 0,1 \cdot 0,2 + 0,05 \cdot 0,8 = 0,06 \\ \text{iv)} \quad \mathbb{P}(S \cap U) &\stackrel{\text{TW}}{=} \mathbb{P}(S \cap U|W) \cdot \mathbb{P}(W) + \mathbb{P}(S \cap U|\overline{W}) \cdot \mathbb{P}(\overline{W}) \\ &\stackrel{\text{MS}}{=} \mathbb{P}(S|W) \cdot \mathbb{P}(U|W) \cdot \mathbb{P}(W) + \mathbb{P}(S|\overline{W}) \cdot \mathbb{P}(U|\overline{W}) \cdot \mathbb{P}(\overline{W}) \\ &= 0,3 \cdot 0,1 \cdot 0,2 + 0,2 \cdot 0,05 \cdot 0,8 = 0,014 \\ \text{v)} \quad \mathbb{P}(S|U) &\stackrel{\text{Bayes}}{=} \frac{\mathbb{P}(S \cap U)}{\mathbb{P}(U)} = \frac{0,014}{0,06} \approx 0,233 \\ \text{vi)} \quad \mathbb{P}(S \cup U) &\stackrel{\text{AS}}{=} \mathbb{P}(S) + \mathbb{P}(U) - \mathbb{P}(S \cap U) = 0,22 + 0,06 - 0,014 = 0,266 \\ \text{vii)} \quad \mathbb{P}(U \cap \overline{S}) &= \mathbb{P}(U) - \mathbb{P}(S \cap U) = 0,06 - 0,014 = 0,046\end{aligned}$$

Hinweis:

Notation: TW = Satz der Totalen Wahrscheinlichkeit; MS = Multiplikationssatz; AS = Allgemeiner Additionssatz; $Bayes$ = Satz von Bayes

c) Sind S und U stochastisch unabhängig?

$$\mathbb{P}(S|U) \approx 0,233 \neq 0,22 = \mathbb{P}(S)$$

$$\text{Alternativ: } \mathbb{P}(S \cap U) = 0,014 \neq 0,0132 = \mathbb{P}(S) \cdot \mathbb{P}(U)$$

☞ Das Eintreten von S ändert die Wahrscheinlichkeit des Eintretens von U . Die Ereignisse sind daher stochastisch abhängig.

Aufgabe 18 Lösungen

Es werden zwei faire Würfel gleichzeitig geworfen, ein weißer und ein roter. Es seien die folgenden Ereignisse definiert:

$A :=$ „Die geworfene Augenzahl des weißen Würfels ist gerade.“

$B :=$ „Die geworfene Augenzahl des roten Würfels ist ungerade.“

$C :=$ „Die Summe der geworfenen Augenzahlen ist gerade.“

Teil A

a) Wieso handelt es sich um ein Zufallsexperiment? Was ist zufällig?

Es handelt sich um ein Zufallsexperiment, da die physikalischen Einflussgrößen des Wurfs nicht vollständig kontrollierbar sind, sodass der *Ausgang* (die Augenzahlen der beiden Würfel) nicht deterministisch vorhergesagt werden kann und als *zufällig* gilt.

☺ *Begründung:*

Da wir die vielen Parameter, die den Wurfausgang bestimmen, nicht vollständig kontrollieren oder genau kennen und sie oft auch nicht messen können lässt sich der konkrete Ausgang des Wurfs (also die Augenzahlen des weißen und roten Würfels) nicht deterministisch (d.h. ohne Unsicherheit; ohne Wahrscheinlichkeitsangabe) vorhersagen.

Zu diesen Parametern könnten z.B. physikalische Einflussgrößen wie Handhaltung, Abwurfhöhe, Drehimpuls, Luftwiderstand, Auftreffwinkel oder Reibung zählen. Sie sind zwar real vorhanden, aber wir kennen ihr Zusammenspiel nicht und haben keine Funktion, in die wir feste Werte für sie einsetzen könnten, um ein deterministisches Ergebnis zu erhalten. Genau deshalb betrachten wir den Ausgang des Experiments als *zufällig*.

Würde der Wurf hingegen durch eine idealisierte Maschine erfolgen, die unter identischen Bedingungen stets dieselbe Augenzahl erzeugt (z. B. immer eine 1 oder immer eine 4), läge kein Zufallsexperiment vor^(*), da der Ausgang dann deterministisch feststünde.

(*) Während der Zufall klassisch durch eine perfekte Maschine eliminiert werden könnte (Determinismus), bleibt der Wurf auf atomarer Ebene wegen des Quantenzufalls (siehe *Doppelspaltexperiment*) immer fundamental zufällig.

b) Bestimmen Sie die Wahrscheinlichkeiten der Ereignisse A , B , C .

- Bei dem Zufallsexperiment „Wurf des weißen Würfels“ gibt es 6 mögliche Versuchsausgänge (Ergebnisse). Es ist $\Omega_w = \{1, 2, 3, 4, 5, 6\}$ und $A = \{2, 4, 6\}$. Nach Laplace gilt: $\mathbb{P}(A) = \frac{|A|}{|\Omega_w|} = \frac{3}{6} = 0,5$.

- Bei dem Zufallsexperiment „Wurf des roten Würfels“ gibt es 6 mögliche Versuchsausgänge (Ergebnisse). Es ist $\Omega_r = \{1, 2, 3, 4, 5, 6\}$ und $A = \{1, 3, 5\}$. Nach Laplace gilt: $\mathbb{P}(B) = \frac{|B|}{|\Omega_r|} = \frac{3}{6} = 0,5$.

- Zu $|\Omega|$: Bei dem Zufallsexperiment „gleichzeitiger Wurf eines weißen und eines roten Würfels“ gibt es 36 mögliche Versuchsausgänge (Ergebnisse). ($\rightarrow$ mehr dazu in Begründung). Es ist $\Omega = \Omega_r \times \Omega_w = \{1, 2, 3, 4, 5, 6\} \times \{1, 2, 3, 4, 5, 6\} = \{1, 2, 3, 4, 5, 6\}^2$.

Zu $|C|$: Die Summe zweier Augenzahlen ist genau dann gerade, wenn

- beide Augenzahlen gerade sind oder
- beide Augenzahlen ungerade sind.

Auf jedem Würfel gibt es drei gerade Zahlen $\{2, 4, 6\}$ und drei ungerade Zahlen $\{1, 3, 5\}$. Damit ergeben sich $3 \cdot 3 = 9$ Ergebnisse mit zwei geraden Augenzahlen und ebenso $3 \cdot 3 = 9$ Ergebnisse mit zwei ungeraden Augenzahlen. Insgesamt ist die Mächtigkeit des Ereignisses $C = \{\text{Summe der Augenzahlen ist gerade}\}$ also $|C| = 9 + 9 = 18$.

Nach Laplace gilt: $\mathbb{P}(C) = \frac{|C|}{|\Omega|} = \frac{18}{36} = 0,5$.

☞ *Begründung:*

Da die Würfel unterscheidbar sind (weiß, rot), wird jedes Ergebnis als *geordnetes* Paar

$$(w, r) \quad \text{mit} \quad w, r \in \{1, 2, 3, 4, 5, 6\}$$

beschrieben.

Kombinatorisch entspricht dies einer Auswahl von $r = 2$ Augenzahlen aus $n = 6$ unterscheidbaren Augenzahlen mit Beachtung der Reihenfolge mit Zurücklegen (d.h. mit Wiederholung), also einer Variation mit Wiederholung: $V^W(n; r) = n^r$.

Teil B

Es sein die folgenden Ereignissen definiert:

$$E := A \cap B = \{(2, 1); (2, 3); (2, 5); (4, 1); (4, 3); (4, 5); (6, 1); (6, 3); (6, 5)\}$$

$$F := A \cap C = \{(2, 2); (2, 4); (2, 6); (4, 2); (4, 4); (4, 6); (6, 2); (6, 4); (6, 6)\}$$

$$G := B \cap C = \{(1, 1); (1, 3); (1, 5); (3, 1); (3, 3); (3, 5); (5, 1); (5, 3); (5, 5)\}$$

$$H := A \cap B \cap C$$

c) Aus welchen Elementen von Ω setzt sich das Ereignis H zusammen?

$$H = E \cap C = \{\} = \emptyset$$

d) Bestimmen Sie die Wahrscheinlichkeiten der Ereignisse E , F , G , H .

$$\mathbb{P}(E) = \frac{|E|}{|\Omega|} = \frac{9}{36}, \quad \mathbb{P}(F) = \frac{|F|}{|\Omega|} = \frac{9}{36}, \quad \mathbb{P}(G) = \frac{|G|}{|\Omega|} = \frac{9}{36} \quad \text{und} \quad \mathbb{P}(H) = \frac{|H|}{|\Omega|} = 0$$

e) Definieren Sie das Komplementärereignis

i) $\bar{E}$ mithilfe von $\bar{A}$ und $\bar{B}$

ii) $\bar{H}$ mithilfe von $\bar{F}$ und $\bar{G}$

als Mengenoperation.

$$\text{i) } \bar{E} = \overline{A \cap B} \stackrel{\text{De Morgan}}{\downarrow} \bar{A} \cup \bar{B}$$

$$\begin{aligned} \text{ii) } \bar{H} &= \overline{A \cap B \cap C} \stackrel{C \cap C = C}{\downarrow} \overline{A \cap B \cap C \cap C} \stackrel{\text{kommunikativ}}{\downarrow} \overline{A \cap C \cap B \cap C} \\ &\stackrel{\text{assoziativ}}{\downarrow} \overline{(A \cap C) \cap (B \cap C)} \stackrel{\text{De Morgan}}{\downarrow} \bar{F} \cup \bar{G} \end{aligned}$$

+ *Zusatz: Verbalisierung der Ergebnisse*

i) Die Augenzahl des weißen Würfels ist ungerade *oder* die des roten Würfels ist gerade *oder beides*.

ii) Entweder ist die Augenzahl des weißen Würfels ungerade, *oder* die Augenzahl des roten Würfels gerade, *oder* die Summe der beiden Augenzahlen ist ungerade *oder mehrere dieser Fälle gleichzeitig*.

☺ Begründung zu e) ii):

- Der Schnitt einer Menge mit sich selbst ergibt wieder dieselbe Menge, man nennt diese Eigenschaft *Idempotenz des Schnittes*. (Analog für Vereinigungen).
- Für Schnitte gilt das *Kommutativ-* und das *Assoziativgesetz*.

f) Sind die Ereignisse A, B, C

i) paarweise

ii) vollständig

stochastisch unabhängig? Begründen Sie Ihre jeweilige Antwort mit Hilfe eines formalen Rechenganges.

i) Die Ereignisse A, B, C sind **paarweise** stochastisch unabhängig, da gilt:

- A und B sind stochastisch unabhängig, da

$$\mathbb{P}(E) = \mathbb{P}(A \cap B) = \frac{9}{36} = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A) \cdot \mathbb{P}(B)$$

- A und C sind stochastisch unabhängig, da

$$\mathbb{P}(F) = \mathbb{P}(A \cap C) = \frac{9}{36} = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A) \cdot \mathbb{P}(C)$$

- B und C sind stochastisch unabhängig, da

$$\mathbb{P}(G) = \mathbb{P}(B \cap C) = \frac{9}{36} = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(B) \cdot \mathbb{P}(C)$$

ii) Die Ereignisse A, B, C sind **nicht vollständig** stochastisch unabhängig, da gilt: $\mathbb{P}(H) = \mathbb{P}(A \cap B \cap C) = 0 \neq \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A) \cdot \mathbb{P}(B) \cdot \mathbb{P}(C)$

☺ Begründung:

Paarweise stochastische Unabhängigkeit von A und B bedeutet, dass das Ergebnis des weißen Würfels keinen Einfluss auf das Ergebnis des roten Würfels hat und umgekehrt; das Wissen über A liefert also keine Information über B .

Eine vollständige gemeinsame Unabhängigkeit der Ereignisse A, B und C liegt hingegen nicht vor, da aus dem gleichzeitigen Eintreten von A (weiß gerade) und B (rot ungerade) zwingend folgt, dass die Summe der Augenzahlen ungerade ist und das Ereignis C („Summe ist gerade“) damit ausgeschlossen ist.

2.4 Diskrete Verteilungen

2.4.1 Bernoulli- und Binomialverteilung

Aufgabe 19

Ein Streamingdienst entwirft einen neuen Algorithmus zur Serienempfehlung. Für eine zufällig ausgewählte Nutzerin bzw. einen zufällig ausgewählten Nutzer gilt: Mit einer Wahrscheinlichkeit von 0,3 klickt die Person nach dem Einloggen mindestens eine empfohlene Serie an. Der Streamingdienst betrachtet 30 zufällig ausgewählte Nutzerinnen und Nutzer. Es wird angenommen, dass das Klickverhalten einer Person keinen Einfluss auf das Klickverhalten anderer Personen hat. Seien

X_i : „Die i -te Person klickt mindestens eine empfohlene Serie an“ und

Y : „Anzahl der Personen, die mindestens eine empfohlene Serie anklicken“.

- a) Definieren Sie die Zufallsvariable X_i . Wie ist diese verteilt (Verteilungstyp und -parameter)?
- b) Was bedeutet es, wenn man davon spricht, dass die Zufallsvariablen $X_1, X_2, \dots, X_{30}$ „iid“ sind? Ist diese Annahme laut Aufgabenstellung erfüllt?
- c) Definieren Sie die Zufallsvariable Y als Funktion der Zufallsvariablen $X_1, \dots, X_{30}$. Wie ist die Zufallsvariable Y verteilt (Verteilungstyp und -parameter)?
- d) Berechnen Sie die Wahrscheinlichkeit, dass
 - i) genau 5 Personen mindestens eine empfohlene Serie anklicken,
 - ii) höchstens 18 Personen mindestens eine empfohlene Serie anklicken,
 - iii) mindestens 9 Personen mindestens eine empfohlene Serie anklicken,
 - iv) mehr als 10, aber weniger als 25 Personen mindestens eine empfohlene Serie anklicken.

Aufgabe 20**Teil A**

Erfahrungsgemäß erscheinen 10% der Fluggäste mit gültigem Ticket nicht zum Abflug, wobei das (Nicht-)Erscheinen einer Personen keinen Einfluss auf das (Nicht-)Erscheinen anderer Personen hat. Auf Basis dieser Information verkauft die Fluggesellschaft 29 Flugtickets für 26 verfügbare Sitzplätze eines Flugs von Mannheim nach Berlin. Sei

X : „Anzahl der erscheinenden Passagiere für Flug von Mannheim nach Berlin“.

- a) Wie ist die Zufallsvariable X verteilt (Verteilungstyp und -parameter)? Wieso ist die Annahme „*Das (Nicht-)Erscheinen einer Personen hat keinen Einfluss auf das (Nicht-)Erscheinen anderer Personen.*“ hier wichtig?
- b) Bestimmen Sie die Wahrscheinlichkeit, dass alle erscheinenden Fluggäste einen Sitzplatz erhalten.
- c) Die Fluggesellschaft bietet zusätzlich einen Flug von Mannheim nach Sylt an, bei dem 30 Tickets für 26 Plätze verkauft wurden. Ob die Passagiere für den Flug von Mannheim nach Berlin erscheinen oder nicht, hat keinen Einfluss auf das (Nicht-)Erscheinen der Passagiere des Flugs von Mannheim nach Sylt. Bestimmen Sie die Verteilung (Verteilungstyp und -parameter) der Zufallsvariable

G : „Anzahl erscheinender Passagiere beider Flüge“.

Teil B

Für die Fluggesellschaft ist nun ausschließlich relevant, ob es zu einer Überbuchung auf dem Flug nach Berlin kommt oder nicht.

- d) Definieren Sie auf Basis der Zufallsvariable X eine geeignete Zufallsvariable D , die das Auftreten einer Überbuchung modelliert. Wie ist die Zufallsvariable D verteilt (Verteilungstyp und -parameter)?
- e) Berechnen Sie den Erwartungswert von D und interpretieren Sie diesen im Kontext der Aufgabe.

2.4.2 Geometrische Verteilung

Aufgabe 21

Klickt ein Kunde in der App eines Lieferservices auf „Bestellung abschicken“, schlägt manchmal die Zahlung fehl, sodass der Zahlungsvorgang wiederholt werden muss. Die Wahrscheinlichkeit, dass ein einzelner Zahlungsveruch erfolgreich ist, beträgt 0,8. Die Ausgänge der Zahlungsveruche sind unabhängig voneinander. Sei

X : „Anzahl der Zahlungsveruche bis zur ersten erfolgreichen Zahlung“.

- a) Wie ist die Zufallsvariable X verteilt (Verteilungstyp und -parameter)?
- b) Berechnen Sie die Wahrscheinlichkeit, dass
 - i) die erste Zahlung bereits beim ersten Versuch erfolgreich ist,
 - ii) mindestens zwei Fehlversuche auftreten, bevor die Zahlung erfolgreich ist.
- c) Bestimmen Sie den Erwartungswert von X und interpretieren Sie diesen im Kontext der Aufgabe.
- d) Zeigen Sie durch einen formalen Rechenschritt, dass $\lim_{x \rightarrow \infty} F(x) = 1$, gilt, wobei F die Verteilungsfunktion von X beschreibt.

2.4.3 Hypergeometrische Verteilung

Aufgabe 22

Eine Person erhält einen Katalog mit 10 Prüfungsfragen, von denen 6 so schwer sind, dass sie von niemandem gelöst werden können. Die Person darf nun zufällig 3 Fragen aus diesem Katalog auswählen. Die Auswahl erfolgt ohne Zurücklegen, d. h. jede Frage kann höchstens einmal ausgewählt werden.

- a) Wie ist die Zufallsvariable X verteilt (Verteilungstyp und -parameter)?
- b) Skizzieren Sie die Wahrscheinlichkeitsfunktion und die Verteilungsfunktion von X .
- c) Berechnen Sie die Wahrscheinlichkeit, dass
 - i) die Person alle 3 Fragen richtig lösen kann,
 - ii) die Person genau 3 lösbare Fragen auswählt,
 - iii) die Person mindestens eine lösbare Frage auswählt,
 - iv) die zweite von der Person ausgewählte Frage lösbar ist.

2.4.4 Poissonverteilung

Aufgabe 23

Sie machen einen Morgenspaziergang durch den Grunewald mit der Hoffnung Rehe zu sehen. Rehsichtungen treten räumlich zufällig und unabhängig voneinander auf. Sie durchstreifen eine Fläche von 1000 Ar ($1 Ar = 100m^2$). Seien

X : „Anzahl der Rehsichtungen auf der durchstreiften Fläche“,

Y : „Anzahl der Rehsichtungen auf 500 Ar “.

Teil A

Gehen Sie davon aus, dass es im Grunewald pro 1000 Ar durchschnittlich 6 Rehsichtungen gibt.

- a) Wie sind die Zufallsvariablen X und Y jeweils verteilt (Verteilungstyp und -parameter)?
- b) Berechnen Sie die Wahrscheinlichkeit, dass Sie
 - i) genau zwei Rehsichtungen,
 - ii) höchstens vier Rehsichtungen,
 - iii) mindestens drei, aber weniger als sieben Rehsichtungen,machen, wenn Sie eine Fläche von 1000 Ar durchstreifen.

Teil B

Gehen Sie nun davon aus, dass man auf jedem Ar Wald mit Wahrscheinlichkeit 0,006 eine Rehsichtung macht.

- c) Wie ist die Zufallsvariable X
 - i) exakt,
 - ii) approximativverteilt (Verteilungstyp und -parameter)? Prüfen Sie die Approximationskriterien.

2.4.5 Negative Binomialverteilung

Aufgabe 24

Ein schwedisches Unternehmen vertreibt Smart-Home Glühbirnen. Es ist bekannt, dass sich eine Glühbirne mit Wahrscheinlichkeit 0,4 nicht mit dem Smart-Home System verbinden lässt und somit als *fehlerhaft* gilt. Die Glühbirnen werden einzeln verpackt und versendet. Sei für $r \in \mathbb{N} \setminus \{0\}$

Y_r : „Anzahl der versendeten Pakete bis zur r-ten fehlerhaften Glühbirne“.

- a) Wie ist die Zufallsvariable Y_r in Abhängigkeit von r verteilt (Verteilungstyp und -parameter)?
- b) Mit welcher Wahrscheinlichkeit befindet sich im zehnten Versandpaket die dritte fehlerhafte Glühbirne?
- c) Zeigen Sie formal, dass die Wahrscheinlichkeit in b) auch mithilfe der Zufallsvariable Z : „Anzahl der fehlerhaften Pakete bei neun versendeten Paketen“ berechnet werden kann. Beschreiben Sie diesen Zusammenhang inhaltlich. Sie dürfen folgende Identität für alle $n, k \in \mathbb{N}_0$, $k \leq n$ verwenden:

$$\binom{n}{k} = \binom{n}{n-k}$$

- d) Bestimmen Sie den Erwartungswert der Anzahl der versendeten Glühbirnen bis zum Auftreten der dritten fehlerhaften Glühbirne.
- e) Mit welcher Wahrscheinlichkeit befindet sich im fünften Versandpaket die erste fehlerhafte Glühbirne?
- f) Welcher Verteilung folgt Y_1 noch? Begründen Sie.
- g) Mit welcher Wahrscheinlichkeit befinden sich in fünf Paketen mindestens drei fehlerhafte Glühbirnen?

2.4.6 Multinomialverteilung


Aufgabe 25

In einer (unendlich) großen Kiste befinden sich (unendlich) viele Schrauben von drei verschiedenen Schraubentypen: Schrauben mit 1 mm, 2 mm und 3 mm Durchmesser.

Für die Zufallsvariable

D : „Durchmesser einer zufällig ausgewählten Schraube in der Kiste (in mm)“

sei die Wahrscheinlichkeitsverteilung gegeben durch:



- a) Definieren Sie aus der Zufallsvariable D drei dichotome Zufallsvariablen E, F, G mit jeweils dem Wertebereich $\{0, 1\}$. Geben Sie jeweils die Verteilung (Verteilungstyp und -parameter) an.

Es werden drei Schrauben zufällig gezogen. Seien

S_k : „Anzahl der gezogenen Schrauben mit Durchmesser k “ für $k \in \{1, 2, 3\}$.

- b) Wie sind die Zufallsvariablen S_1, S_2 und S_3 **jeweils** und **zusammen** verteilt (Verteilungstyp und -parameter)?
- c) Stellen Sie alle möglichen Realisierungen $s = (s_1, s_2, s_3)$ auf.
- d) Berechnen Sie die Wahrscheinlichkeit, dass man
- nur 3 mm Schrauben erhält.
 - zwei 1 mm und eine 3 mm Schraube erhält.
 - drei Schraubentypen erhält.
- e) Berechnen Sie die Korrelation zwischen S_2 und S_3 . Begründen Sie, wieso die beiden Zufallsvariablen stochastisch abhängig sind.
- f) Sei Z : „Anzahl der gezogenen unterschiedlichen Schraubentypen“. Skizzieren Sie die Wahrscheinlichkeitsverteilung von Z .

Motivation

Wie Sie bisher gesehen haben, wird der Zufall einer *diskreten Zufallsvariable* vollständig durch ihre *Wahrscheinlichkeitsfunktion* beschrieben. Im diskreten Fall *entspricht* diese Wahrscheinlichkeitsfunktion genau der *Wahrscheinlichkeitsverteilung* der Zufallsvariable. Einige Wahrscheinlichkeitsverteilungen folgen einer *charakteristischen Form* und werden daher mit einem eigenen Namen bezeichnet, etwa der Bernoulli- oder der Binomialverteilung. In anderen Worten: **Der Name einer Verteilung gibt Ihnen Aufschluss darüber, welche Wahrscheinlichkeitsfunktion die diskrete Zufallsvariable besitzt.**

Zu den in diesem Werk behandelten diskreten Wahrscheinlichkeitsverteilungen gehören:

- Diskrete Gleichverteilung
- Bernoulliverteilung
- Binomialverteilung
- Geometrische Verteilung
- Hypergeometrische Verteilung
- Poissonverteilung
- Negative Binomialverteilung
- Multinomialverteilung

Notation von Verteilungen

Hat die Verteilung einer Zufallsvariable X einen etablierten Namen (z.B. Bernoulli-, Binomialverteilung etc.), notiert man dies üblicherweise als



$X \sim \text{Verteilung}(\text{eingesetzter Parameter})$

oder

$X \sim \text{Verteilung}(\text{allgemeiner Parameter})$

mit *allgemeiner Parameter* = *eingesetzter Parameter*

Z.B. schreibt man für eine binomialverteilte Zufallsvariable mit den Parameter n und π :

$$X \sim B(12; 0,5) \quad \text{oder} \quad X \sim B(n; \pi) \quad \text{mit } n = 12, \pi = 0,5$$

Hierbei steht „ $\sim$ “ für „ist verteilt nach“.

Aufgabe 19 Lösungen

Ein Streamingdienst entwirft einen neuen Algorithmus zur Serienempfehlung. Für eine zufällig ausgewählte Nutzerin bzw. einen zufällig ausgewählten Nutzer gilt: Mit einer Wahrscheinlichkeit von 0,3 klickt die Person nach dem Einloggen mindestens eine empfohlene Serie an. Der Streamingdienst betrachtet 30 zufällig ausgewählte Nutzerinnen und Nutzer. Es wird angenommen, dass das Klickverhalten einer Person keinen Einfluss auf das Klickverhalten anderer Personen hat. Seien

X_i : „Die i -te Person klickt mindestens eine empfohlene Serie an“ und

Y : „Anzahl der Personen, die mindestens eine empfohlene Serie anklicken“.

- a) Definieren Sie die Zufallsvariable X_i . Wie ist diese verteilt (Verteilungstyp und -parameter)?

Es sei

$$X_i := \begin{cases} 1, & \text{falls die } i\text{-te Person mindestens eine empfohlene Serie anklickt,} \\ 0, & \text{sonst.} \end{cases}$$

Die Zufallsvariable X_i modelliert ein Ereignis mit zwei Ausgängen (Klick/kein Klick) und ist daher bernoulliverteilt mit Parameter $\pi = 0,3$. Man schreibt $X_i \sim \text{Bernoulli}(0,3)$.

Definition: Bernoulliverteilung


Die Zufallsvariable X , die die Werte 0 oder 1 annimmt und deren Wahrscheinlichkeitsfunktion durch

$$\mathbb{P}(X = 1) = \pi \quad \text{und} \quad \mathbb{P}(X = 0) = 1 - \pi$$

für ein $\pi \in [0, 1]$ gegeben ist, heißt *bernoulliverteilt* mit Parameter (Erfolgswahrscheinlichkeit) π . Die Zufallsvariable X modelliert also zwei möglichen Ausgängen (= binäres Ereignis), die als „Erfolg“ ($X = 1$) und „Misserfolg“ ($X = 0$) interpretiert werden, wobei die Wahrscheinlichkeit des „Erfolgs“ genau $\mathbb{P}(X = 1) = \pi$ ist.

 *Kurzschreibweise:* $X \sim \text{Bernoulli}(\pi)$.

Zum Beispiel:



- b) Was bedeutet es, wenn man davon spricht, dass die Zufallsvariablen $X_1, X_2, \dots, X_{30}$ „iid“ sind? Ist diese Annahme laut Aufgabenstellung erfüllt?

Die Bezeichnung *iid* steht für *independent and identically distributed*. Das bedeutet, dass die Zufallsvariablen $X_1, \dots, X_{30}$ *stochastisch unabhängig* sind und *alle dieselbe Wahrscheinlichkeitsverteilung* besitzen. Im Kontext der Aufgabe ist dies erfüllt, denn jede zufällig ausgewählte Person klickt unabhängig von den anderen mit derselben Wahrscheinlichkeit $\pi = 0,3$ mindestens eine empfohlene Serie an.

 *Notation:*

Man schreibt in diesem Fall kompakt „ $X_i \stackrel{iid}{\sim} \text{Bernoulli}(0,3)$ für $i = 1, \dots, 30$,“ anstatt

$$X_1 \sim \text{Bernoulli}(0,3), \quad X_2 \sim \text{Bernoulli}(0,3), \quad \dots, \quad X_{30} \sim \text{Bernoulli}(0,3) \quad \text{mit}$$

$X_1, X_2, \dots, X_{30}$ stochastisch unabhängig voneinander.

- c) Definieren Sie die Zufallsvariable Y als Funktion der Zufallsvariablen $X_1, \dots, X_{30}$. Wie ist die Zufallsvariable Y verteilt (Verteilungstyp und -parameter)?

Da jede Zufallsvariable X_i den Wert 1 annimmt, falls die i -te Person mindestens eine empfohlene Serie anklickt, und den Wert 0 sonst, zählt die Summe $\sum_{i=1}^{30} X_i$ genau die Anzahl der Personen, die mindestens eine empfohlene Serie anklicken. Wir definieren also

$$Y := \sum_{i=1}^{30} X_i.$$

Weiter gilt, dass die Summe von n unabhängigen und identisch bernoulliverteilten Zufallsvariablen binomialverteilt ist, wobei die Erfolgswahrscheinlichkeit $\pi = 0,3$ „vererbt“ wird. Somit ist

$$Y \sim \text{Bin}(30; 0,3).$$

Definition: Binomialverteilung

Die Zufallsvariable X , die die Werte $x \in \{0, 1, \dots, n\}$ annimmt und deren Wahrscheinlichkeitsfunktion durch

$$\mathbb{P}(X = x) = \binom{n}{x} \cdot \pi^x \cdot (1 - \pi)^{n-x}$$

für ein $\pi \in [0, 1]$ gegeben ist, heißt *binominalverteilt* mit den Parametern $n \in \mathbb{N}$ und $\pi \in [0, 1]$.




 *Kurzschreibweise:* $X \sim \text{Bin}(n; \pi)$

 *Merke:* Es kann gezeigt werden, dass die Summe von n unabhängigen, identisch Bernoulli-verteilten Zufallsvariablen mit Erfolgswahrscheinlichkeit π wieder eine Zufallsvariable ist, die binomialverteilt ist mit den Parametern n und π . Also

$$X := \sum_{i=1}^n X_i, \quad \text{wobei } X_i \stackrel{iid}{\sim} \text{Bernoulli}(\pi) \text{ für } i = 1, \dots, n \quad \implies \quad X \sim \text{Bin}(n; \pi).$$

Fortsetzung:

Zum Beispiel:



d) Berechnen Sie die Wahrscheinlichkeit, dass

- i) genau 5 Personen mindestens eine empfohlene Serie anklicken,
- ii) höchstens 18 Personen mindestens eine empfohlene Serie anklicken,
- iii) mindestens 9 Personen mindestens eine empfohlene Serie anklicken,
- iv) mehr als 10, aber weniger als 25 Personen mindestens eine empfohlene Serie anklicken.

$$\text{i) } \mathbb{P}(Y = 5) = \binom{30}{5} \cdot 0,3^5 \cdot (1 - 0,3)^{30-5} = 0,0464$$

$$\text{ii) } \mathbb{P}(Y \leq 18) \stackrel{\text{Def. } F}{=} F(18) \stackrel{\text{Tabelle}}{=} 0,9998$$

$$\begin{aligned} \text{iii) } \mathbb{P}(Y \geq 9) &= 1 - \mathbb{P}(Y < 9) \stackrel{(*)}{=} 1 - \mathbb{P}(Y \leq 8) \stackrel{\text{Def. } F}{=} 1 - F(8) \\ &\stackrel{\text{Tabelle}}{=} 1 - 0,4315 = 0,5685 \end{aligned}$$

$$\begin{aligned} \text{iv) } \mathbb{P}(10 < Y < 25) &= \mathbb{P}(Y < 25) - \mathbb{P}(Y \leq 10) \stackrel{(*)}{=} \mathbb{P}(Y \leq 24) - \mathbb{P}(Y \leq 10) \\ &\stackrel{\text{Def. } F}{=} F(24) - F(10) \stackrel{\text{Tabelle}}{=} 1 - 0,7304 = 0,2696 \end{aligned}$$

☺ *Begründung:*

(*) Für eine diskrete Zufallsvariable Y gilt für jede ganze Zahl $y \in \mathbb{Z}$:

$$\mathbb{P}(Y < y) = \mathbb{P}(Y \leq y - 1) \quad \text{und} \quad \mathbb{P}(Y > y) = \mathbb{P}(Y \geq y + 1)$$

In Worten: Bei diskreten Zufallsvariablen liegt die gesamte Wahrscheinlichkeit auf einzelnen Punkten. Daher ist $\mathbb{P}(Y < y)$ gleich der Summe der Punktwahrscheinlichkeiten bis $y - 1$ und damit gleich $\mathbb{P}(Y \leq y - 1)$.

Analog für $\mathbb{P}(Y > y) = \mathbb{P}(Y \geq y + 1)$.

Aufgabe 20 Lösungen

Teil A

Erfahrungsgemäß erscheinen 10% der Fluggäste mit gültigem Ticket nicht zum Abflug, wobei das (Nicht-)Erscheinen einer Personen keinen Einfluss auf das (Nicht-)Erscheinen anderer Personen hat. Auf Basis dieser Information verkauft die Fluggesellschaft 29 Flugtickets für 26 verfügbare Sitzplätze eines Flugs von Mannheim nach Berlin. Sei

X : „Anzahl der erscheinenden Passagiere für Flug von Mannheim nach Berlin“.

- a) Wie ist die Zufallsvariable X verteilt (Verteilungstyp und -parameter)? Wieso ist die Annahme „*Das (Nicht-)Erscheinen einer Personen hat keinen Einfluss auf das (Nicht-)Erscheinen anderer Personen.*“ hier wichtig?

Nur unter dieser Annahme können wir die Bernoulli-Zufallsvariablen, die das Erscheinen jeder einzelnen Person mit Erfolgswahrscheinlichkeit 0,9 modellieren, als *unabhängig* betrachten. Daraus folgt dann

$$X \sim \text{Bin}(29; 0,9).$$

+ *Zusatz:*

Ohne diese Annahme wäre die Anzahl der erscheinenden Passagiere im Allgemeinen nicht binomialverteilt, da Abhängigkeiten zwischen den Personen (z. B. gemeinsames Reisen mit Familie) die Verteilung verändern würden.

- b) Bestimmen Sie die Wahrscheinlichkeit, dass alle erscheinenden Fluggäste einen Sitzplatz erhalten.

Damit alle einen Sitzplatz erhalten, dürfen höchstens 26 Passagiere erscheinen. Gesucht ist also $\mathbb{P}(X \leq 26) = F_X(26)$. Die Binomialverteilung ist jedoch für $\pi = 0,9$ häufig nicht tabellarisiert in Lehrbüchern zu finden. Aus diesem Grund definieren wir die „Hilfs-Zufallsvariable“

H : „Anzahl der *nicht* erscheinenden Passagiere für Flug von Mannheim nach Berlin“

mit $H := 29 - X$. Mit der *Symmetrieeigenschaft* der Binomialverteilung gilt nun $H \sim \text{Bin}(29; 0,1)$. Wir berechnen nun

$$\begin{aligned}\mathbb{P}(X \leq 26) &= \mathbb{P}(29 - H \leq 26), \quad \text{weil } H := 29 - X \Leftrightarrow X = 29 - H \\ &= \mathbb{P}(29 - H - 29 \leq 26 - 29), \quad (\text{Äquivalenzumformung}) \\ &= \mathbb{P}(-H \leq -3) = \mathbb{P}(H \geq 3) \\ &= 1 - \mathbb{P}(H < 3) = 1 - \mathbb{P}(H \leq 2) = 1 - F_H(2) \stackrel{\text{Tabelle}}{=} 1 - 0,435 = 0,565,\end{aligned}$$

wobei F_X die Verteilungsfunktion von X und F_H die Verteilungsfunktion von H bezeichne.

- c) Die Fluggesellschaft bietet zusätzlich einen Flug von Mannheim nach Sylt an, bei dem 30 Tickets für 26 Plätze verkauft wurden. Ob die Passagiere für den Flug von Mannheim nach Berlin erscheinen oder nicht, hat keinen Einfluss auf das (Nicht-) Erscheinen der Passagiere des Flugs von Mannheim nach Sylt. Bestimmen Sie die Verteilung (Verteilungstyp und -parameter) der Zufallsvariable

G : „Anzahl erscheinender Passagiere beider Flüge“.

Sei $\tilde{X}$: „Anzahl der erscheinenden Passagiere für Flug von Mannheim nach Sylt“ mit $\tilde{X} \sim \text{Bin}(30; 0,9)$. Per Annahme gilt, dass $\tilde{X}$ und X stochastisch unabhängig sind. Mit der *Additionseigenschaft (Reproduktionseigenschaft)* der Binomialverteilung folgt

$$\tilde{X} + X = G \sim \text{Bin}(29 + 30; 0,9).$$

Teil B

Für die Fluggesellschaft ist nun ausschließlich relevant, ob es zu einer Überbuchung auf dem Flug nach Berlin kommt oder nicht.

- d) Definieren Sie auf Basis der Zufallsvariable X eine geeignete Zufallsvariable D , die das Auftreten einer Überbuchung modelliert. Wie ist die Zufallsvariable D verteilt (Verteilungstyp und -parameter)?

Wir definieren

$$D := \begin{cases} 1, & \text{falls } X > 26 \text{ (Überbuchung)}, \\ 0, & \text{falls } X \leq 26 \text{ (keine Überbuchung)}. \end{cases}$$

Damit ist D eine Bernoulli-verteilte Zufallsvariable mit Erfolgswahrscheinlichkeit

$$\mathbb{P}(D = 1) = \mathbb{P}(X > 26) = 1 - \mathbb{P}(X \leq 26) \stackrel{b)}{=} 0,4350,$$

also

$$D \sim \text{Bernoulli}(0,4350).$$

- e) Berechnen Sie den Erwartungswert von D und interpretieren Sie diesen im Kontext der Aufgabe.

$$\mathbb{E}(D) = 0 \cdot \mathbb{P}(D = 0) + 1 \cdot \mathbb{P}(D = 1) = 0,4350$$

 *Interpretation:*

Wendet die Fluggesellschaft diese Buchungspolitik (für 26 Sitzplätze 29 verkaufte Tickets) auf eine sehr große Anzahl von Flügen von Mannheim nach Berlin an, so ist im Mittel bei etwa 43,5% der Flüge eine Überbuchung zu erwarten.

Aufgabe 21 Lösungen

Klickt ein Kunde in der App eines Lieferservices auf „Bestellung abschicken“, schlägt manchmal die Zahlung fehl, sodass der Zahlungsvorgang wiederholt werden muss. Die Wahrscheinlichkeit, dass ein einzelner Zahlungsveruch erfolgreich ist, beträgt 0,8. Die Ausgänge der Zahlungsveruche sind unabhängig. Sei

X : „Anzahl der Zahlungsveruche bis zur ersten erfolgreichen Zahlung“.

a) Wie ist die Zufallsvariable X verteilt (Verteilungstyp und -parameter)?

$$X \sim G(\pi) \quad \text{mit} \quad \pi = 0,8$$

Definition: Geometrische Verteilung


Die Zufallsvariable X , die Werte in $x \in \mathbb{N} \setminus \{0\}$ annimmt und deren Wahrscheinlichkeitsfunktion durch

$$\mathbb{P}(X = x) = \pi \cdot (1 - \pi)^{x-1}$$

für ein $\pi \in (0, 1)$ gegeben ist, heißt *geometrisch verteilt* mit Parameter $\pi \in (0, 1)$. Hierbei steht x für die Anzahl der Versuche *bis zum ersten „Erfolg“*, d.h. bis zum Eintreten eines kontextbestimmten Ereignisses. Die Versuche sind stochastisch unabhängig voneinander und die Erfolgswahrscheinlichkeit eines einzelnen Versuchs beträgt π . Die Wahrscheinlichkeit, dass der erste Erfolg nach x Versuchen eintritt, ist $\mathbb{P}(X = x) = (1 - \pi)^{x-1} \cdot \pi$.

 *Kurzschreibweise:* $X \sim G(\pi)$

Zum Beispiel:



b) Berechnen Sie die Wahrscheinlichkeit, dass

- i) die erste Zahlung bereits beim ersten Versuch erfolgreich ist,
- ii) mindestens zwei Fehlversuche auftreten, bevor die Zahlung erfolgreich ist.

$$\text{i) } \mathbb{P}(X = 1) = (1 - 0,8)^{1-1} \cdot 0,8^1 = 0,8.$$

$$\begin{aligned} \text{ii) } \mathbb{P}(X \geq 3) &= 1 - \mathbb{P}(X \leq 2) \\ &= 1 - (\mathbb{P}(X = 1) + \mathbb{P}(X = 2)) \\ &= 1 - (0,8 + (1 - 0,8) \cdot 0,8) = 0,04 \end{aligned}$$

c) Bestimmen Sie den Erwartungswert von X und interpretieren Sie diesen im Kontext der Aufgabe.

$$\mathbb{E}(X) = \frac{1}{0,8} = 1,25$$



Interpretation:

Wird der Zahlungsprozess unendlich oft wiederholt, so sind im Mittel mit 1,25 fehlgeschlagenen Zahlungsversuchen pro Bestellung zu rechnen, bevor die Zahlung erfolgreich abgeschlossen wird.

d) Zeigen Sie durch einen formalen Rechenschritt, dass $\lim_{x \rightarrow \infty} F(x) = 1$, gilt, wobei F die Verteilungsfunktion von X beschreibt.

$$\begin{aligned} \lim_{x \rightarrow \infty} F(x) &\stackrel{\text{Def. } F}{=} \lim_{x \rightarrow \infty} \mathbb{P}(X \leq x) \stackrel{X \text{ diskret}}{=} \lim_{x \rightarrow \infty} \sum_{k=1}^x \mathbb{P}(X = k) = \sum_{k=1}^{\infty} \mathbb{P}(X = k) \\ &\stackrel{X \sim G(0,8)}{=} \sum_{k=1}^{\infty} (1 - 0,8)^{k-1} \cdot 0,8 = 0,8 \cdot \sum_{k=1}^{\infty} 0,2^{k-1} = 0,8 \cdot \sum_{k=0}^{\infty} 0,2^k \\ &\stackrel{\text{Geom. Reihe}}{=} 0,8 \cdot \frac{1}{1 - 0,2} = 1 \end{aligned}$$

Aufgabe 22 Lösungen

Eine Person erhält einen Katalog mit 10 Prüfungsfragen, von denen 6 so schwer sind, dass sie von niemandem gelöst werden können. Die Person darf nun zufällig 3 Fragen aus diesem Katalog auswählen. Die Auswahl erfolgt ohne Zurücklegen, d. h. jede Frage kann höchstens einmal ausgewählt werden. Sei

X : „Anzahl der ausgewählten lösbaren Fragen“.

a) Wie ist die Zufallsvariable X verteilt (Verteilungstyp und -parameter)?

Es liegt eine $n = 3$ -fache Ziehung ohne Zurücklegen aus einer endlichen Grundgesamtheit mit $N = 10$ Fragen, von denen $M = 4$ Fragen eine gewünschte Eigenschaft (hier: lösbar) innehaben. Folglich ist

$$X \sim H(n; N; M) \quad \text{mit} \quad n = 3, N = 10, M = 4.$$

Definition: Hypergeometrische Verteilung

Die Zufallsvariable X , die Werte in $x \in \{\max\{0, n - (N - M)\}, \min\{n, M\}\}$ annimmt und deren Wahrscheinlichkeitsfunktion durch

$$\mathbb{P}(X = x) = \frac{\binom{M}{x} \cdot \binom{N-M}{n-x}}{\binom{N}{n}}$$


gegeben ist, heißt *hypergeometrisch verteilt* mit den Parametern $(n; N; M)$.

Die hypergeometrische Verteilung beschreibt Zufallsexperimente *ohne* Zurücklegen. Die einzelnen Ziehungen sind daher *stochastisch abhängig*. Aus einer endlichen Grundgesamtheit der Größe N , die aus M „Erfolgen“ und $N - M$ „Misserfolgen“ besteht, werden zufällig n Elemente gezogen. Die Zufallsvariable X zählt dabei die Anzahl der Erfolge in der Ziehung. Der Nenner $\binom{N}{n}$ erfasst alle möglichen Ziehungen von Umfang n . Der Zähler $\binom{M}{x} \binom{N-M}{n-x}$ erfasst die Anzahl der Ziehungen, die aus x Erfolgen und $n - x$ Misserfolgen bestehen. Die Wahrscheinlichkeit ergibt sich somit als Verhältnis „günstiger“ zu allen möglichen Ziehungen.

 *Kurzschreibweise:* $X \sim H(n; N; M)$.

Fortsetzung:

Zum Beispiel:



b) Skizzieren Sie die Wahrscheinlichkeitsfunktion und die Verteilungsfunktion von X .


$X \sim H(3; 10; 4)$ bedeutet, dass X die folgende Wahrscheinlichkeitsfunktion besitzt

$$\mathbb{P}(X = x) = \frac{\binom{4}{x} \cdot \binom{10-4}{3-x}}{\binom{10}{3}} \quad \text{für alle } x \in \{0, 1, 2, 3\},$$


also

$$\begin{aligned} \mathbb{P}(X = 0) &= \frac{\binom{4}{0} \cdot \binom{10-4}{3-0}}{\binom{10}{3}} = \frac{1}{6} \approx 0,167 & \mathbb{P}(X = 1) &= \frac{\binom{4}{1} \cdot \binom{10-4}{3-1}}{\binom{10}{3}} = \frac{1}{2} = 0,5 \\ \mathbb{P}(X = 2) &= \frac{\binom{4}{2} \cdot \binom{10-4}{3-2}}{\binom{10}{3}} = \frac{3}{10} = 0,3 & \mathbb{P}(X = 3) &= 1 - \left(\frac{1}{6} + \frac{1}{2} + \frac{3}{10}\right) = \frac{1}{30} \approx 0,033 \end{aligned}$$

Wahrscheinlichkeitsfunktion von X



Verteilungsfunktion von X



- c) Berechnen Sie die Wahrscheinlichkeit, dass
- i) die Person alle 3 Fragen richtig lösen kann,
 - ii) die Person genau 3 lösbare Fragen auswählt,
 - iii) die Person mindestens eine lösbare Frage auswählt,
 - iv) die zweite von der Person ausgewählte Frage lösbar ist.

i) Es ist keine Aussage möglich.

ii) Mithilfe der Skizze oder Rechnung in b) ist bekannt $\mathbb{P}(X = 3) = \frac{1}{30} \approx 0,033$

iii) $\mathbb{P}(X \geq 1) = 1 - \mathbb{P}(X < 1) = 1 - \mathbb{P}(X = 0)$, da X diskret

$$= 1 - F(0) = 1 - \frac{1}{6} = \frac{5}{6}$$

iv) Wir definieren das Ereignis

$$B := \text{„Die zweite Frage ist lösbar.“}$$

Da die Wahrscheinlichkeit beim zweiten Zug eine lösbare Frage zu ziehen vom Ergebnis des ersten Zugs abhängt (da Ziehen *ohne* Zurücklegen), teilen wir das Ereignis B in zwei disjunkte Ereignisse, je nachdem was beim ersten Zug gezogen wurde. Sei hierfür

$A := \text{„Die erste Frage ist lösbar“}$ und $\bar{A} := \text{„Die erste Frage ist nicht lösbar“}$.

Es gilt

$$B = (B \cap A) \dot{\cup} (B \cap \bar{A}),$$

$$\begin{aligned} \text{also } \mathbb{P}(B) &= \mathbb{P}((B \cap A) \dot{\cup} (B \cap \bar{A})) \\ &= \mathbb{P}(B \cap A) + \mathbb{P}(B \cap \bar{A}), \quad \text{mit der Additivität von } \mathbb{P} \text{ (3. Axiom)} \\ &= \mathbb{P}(A) \cdot \mathbb{P}(B|A) + \mathbb{P}(\bar{A}) \cdot \mathbb{P}(B|\bar{A}), \quad \text{mit Satz von Bayes} \\ &= \frac{4}{10} \cdot \frac{3}{9} + \frac{6}{10} \cdot \frac{4}{9} = 0,4 \end{aligned}$$

Alternativ kann man direkt den *Satz der Totalen Wahrscheinlichkeit* nutzen:

$$\mathbb{P}(B) = \mathbb{P}(A) \cdot \mathbb{P}(B|A) + \mathbb{P}(\bar{A}) \cdot \mathbb{P}(B|\bar{A}) = \frac{4}{10} \cdot \frac{3}{9} + \frac{6}{10} \cdot \frac{4}{9} = 0,4$$

Aufgabe 23 Lösungen

Sie machen einen Morgenspaziergang durch den Grunewald mit der Hoffnung Rehe zu sehen. Rehsichtungen treten räumlich zufällig und unabhängig voneinander auf. Sie durchstreifen eine Fläche von 1000 Ar (1 $Ar = 100m^2$). Seien

X : „Anzahl der Rehsichtungen auf der durchstreiften Fläche“,

Y : „Anzahl der Rehsichtungen auf 500 Ar “.

Teil A

Gehen Sie davon aus, dass es im Grunewald pro 1000 Ar durchschnittlich 6 Rehsichtungen gibt.

- a) Wie sind die Zufallsvariablen X und Y jeweils verteilt (Verteilungstyp und -parameter)?

Es gilt nun $X \sim \text{Poi}(6)$. Da $\lambda = 6$ proportional zur betrachteten Fläche von 1000 Ar ist, ergibt sich für eine halb so große Fläche von 500 Ar entsprechend $Y \sim \text{Poi}(3)$.

- b) Berechnen Sie die Wahrscheinlichkeit, dass Sie

- i) genau zwei Rehsichtungen,
 - ii) höchstens vier Rehsichtungen,
 - iii) mindestens drei, aber weniger als sieben Rehsichtungen,
- machen, wenn Sie eine Fläche von 1000 Ar durchstreifen.

- i) $\mathbb{P}(X = 2) = \frac{6^2}{2!} \cdot e^{-6} \approx 0,0446$
- ii) $\mathbb{P}(X \leq 4) \stackrel{\text{Def. F}}{=} F(4) \stackrel{\text{Tabelle}}{=} 0,2851$
- iii) $\mathbb{P}(3 \leq X < 7) = \mathbb{P}(X < 7) - \mathbb{P}(X < 3) \stackrel{X \text{ diskret}}{=} \mathbb{P}(X \leq 6) - \mathbb{P}(X \leq 2)$
 $\stackrel{\text{Def. F}}{=} F(6) - F(2) \stackrel{\text{Tabelle}}{=} 0,6063 - 0,0620 = 0,5443$

Definition: Poissonverteilung


Die Zufallsvariable X , die Werte in $x \in \mathbb{N}_0$ annimmt und deren Wahrscheinlichkeitsfunktion durch

$$\mathbb{P}(X = x) = \frac{\lambda^x}{x!} e^{-\lambda}$$

für ein $\lambda > 0$ gegeben ist, heißt *poissonverteilt* mit Parameter $\lambda > 0$. Hierbei steht x für die Anzahl von Ereignissen, welche unabhängig voneinander und mit einer *konstanten durchschnittlichen Rate* λ (auch *Intensität* genannt) innerhalb eines *vorgegebenen kontinuierlichen Intervalls* (z.B. Zeit, Strecke, Fläche) eintreten. Man spricht auch von der *Verteilung seltener Ereignisse*.

 *Kurzschreibweise:* $X \sim \text{Poi}(\lambda)$

Zum Beispiel:

**Teil B**

Gehen Sie nun davon aus, dass man auf jedem *Ar* Wald mit Wahrscheinlichkeit 0,006 eine Rehsichtung macht.

c) Wie ist die Zufallsvariable X

- i) exakt,
- ii) approximativ

verteilt (Verteilungstyp und -parameter)? Prüfen Sie die Approximationskriterien.


- i) Exakt gilt $X \sim \text{Bin}(n, \pi)$ mit $n = 1000$ und $\pi = 0,006$.
- ii) Approximativ gilt $X \stackrel{\text{appr.}}{\sim} \text{Poi}(\lambda)$, mit $\lambda = n \cdot \pi = 1000 \cdot 0,006 = 6$. Die Poisson-Approximation ist zulässig, da $n = 1000 > 30$ und $\pi = 0,006 \leq 0,05$ ist.

Binomialverteilung vs. Poissonverteilung


❓ Im *Binomialmodell* wird die Anzahl von Erfolgen in einer festen Anzahl unabhängiger Bernoulli-Versuche modelliert. Im Kontext der Aufgabe bedeutet dies: Die betrachtete Fläche wird in 1000 Ar unterteilt. Jedes Ar stellt eine Bernoulli-Zufallsvariable dar, die angibt, ob ein Reh gesichtet wird (1) oder nicht (0). Die Wahrscheinlichkeit einer Rehsichtung beträgt für jedes Ar $\pi = 0,006$, und die Versuche werden als unabhängig angenommen. Die Zufallsvariable beschreibt somit die Anzahl der Rehsichtungen (Erfolge) in 1000 Bernoulli-Einzelversuchen.

❓ Im *Poissonmodell* wird dagegen die Anzahl zufällig auftretender Ereignisse in einem kontinuierlichen Intervall mit konstanter mittlerer Intensität modelliert (ohne eine feste Anzahl von Einzelversuchen anzunehmen). Im Kontext der Aufgabe bedeutet dies: Die durchstreiften Fläche wird als zusammenhängende Fläche (kontinuierliches Intervall) betrachtet. Eine Rehsichtung stellt ein zufälliges *Ereignis* dar, das mit gleichbleibender mittlerer Rate zufällig auf der Fläche auftritt. Die erwartete mittlere Anzahl der Ereignisse auf der betrachteten Fläche wird durch den Parameter λ beschrieben, der auch als konstante mittlere Intensität bezeichnet wird. Hier bedeutet dies, dass auf einer Fläche von 1000 Ar im Mittel $\lambda = 6$ Rehsichtungen erwartet werden.

Binomialmodell



Poissonmodell



☞ *Poisson-Approximation:* Der Grundgedanke hinter der Approximation des Binomialmodells durch das Poissonmodell ist folgender: Für großes n wird die betrachtete Fläche in immer kleinere Teilflächen zerlegt. Die Erfolgswahrscheinlichkeit π einer Rehsichtung in einer einzelnen Teilfläche wird dabei mit wachsendem n immer kleiner, während die mittlere Gesamtzahl der Sichtungen auf der betrachteten Fläche konstant $n \cdot \pi$ bleibt. Im Grenzfall verschwindet die feste "Rasterstruktur" der Fläche. Es verbleibt eine zusammenhängende Fläche, auf der Ereignisse zufällig und mit dieser konstanten mittleren Rate $\lambda = n \cdot \pi$ auftreten. Die Anzahl der auftretenden Ereignisse wird dann durch eine Poissonverteilung beschrieben.

Poisson-Approximation

Eine $\text{Bin}(n, \pi)$ - verteilte Zufallsvariable X_n ist für „kleines“ π und „großes“ n approximativ $\text{Poi}(\lambda)$ -verteilt mit $\lambda = n \cdot \pi$. Es gilt dann also:

$$P(X_n = x) = \binom{n}{x} \pi^x \cdot (1 - \pi)^{n-x} \approx \frac{\lambda^x}{x!} e^{-\lambda}.$$

Die Approximation ist für $\pi < 0,05$ und $n \geq 30$ hinreichend gut.

Quelle: Stocker, T. C., & Steinke, I. (2022). Statistik: Grundlagen und Methodik (2., korrigierte Auflage). De Gruyter Oldenbourg. S. 392.

Aufgabe 24 Lösungen

Ein schwedisches Unternehmen vertreibt Smart-Home Glühbirnen. Es ist bekannt, dass sich eine Glühbirne mit Wahrscheinlichkeit 0,4 nicht mit dem Smart-Home System verbinden lässt und somit als *fehlerhaft* gilt. Die Glühbirnen werden einzeln verpackt und versendet. Sei für $r \in \mathbb{N} \setminus \{0\}$

Y_r : „Anzahl der versendeten Pakete bis zur r -ten fehlerhaften Glühbirne“.

- a) Wie ist die Zufallsvariable Y_r in Abhängigkeit von r verteilt (Verteilungstyp und -parameter)?

$Y_r \sim \text{NB}(r; \pi)$ mit $r \in \mathbb{N} \setminus \{0\}$ und $\pi = 0,4$

Definition: Negative Binominalverteilung

Eine Zufallsvariable X , die Werte in $x \in \mathbb{N}_0$ annimmt und deren Wahrscheinlichkeitsfunktion durch

$$P(X = x + r) = \binom{x + r - 1}{x} \cdot \pi^r \cdot (1 - \pi)^x$$



für ein $r \in \mathbb{N} \setminus \{0\}$ und $\pi \in (0, 1)$ gegeben ist, heißt negativ binomialverteilt mit den Parametern r und π . Mit der negativen Binomialverteilung lassen sich z.B. *diskret gemessene* Wartezeiten bis zum r -ten Eintreten bestimmter Ereignisse modellieren. Sie stellt eine Verallgemeinerung der geometrischen Verteilung dar.

 *Kurzschreibweise:* $X \sim \text{NB}(r; \pi)$

 Für $r = 1$ ergibt sich die geometrische Verteilung. Die Summe aus r unabhängigen $G(\pi)$ - verteilten Zufallsvariablen ist $\text{NB}(r; \pi)$ - verteilt.

Fortsetzung auf der nächsten Seite.

Zum Beispiel:



Quelle: Stocker, T. C., & Steinke, I. (2022). Statistik: Grundlagen und Methodik (2., korrigierte Auflage). De Gruyter Oldenbourg. S. 440.

- b) Mit welcher Wahrscheinlichkeit befindet sich im zehnten Versandpaket die dritte fehlerhafte Glühbirne?

$$\mathbb{P}(Y_3 = 10 = 7 + 3) = \binom{7+3-1}{7} \cdot 0,4^3 \cdot (1 - 0,4)^7 = \binom{9}{7} \cdot 0,4^3 \cdot 0,6^7 \approx 0,0645$$

- c) Zeigen Sie formal, dass die Wahrscheinlichkeit in b) auch mithilfe der Zufallsvariable Z : „Anzahl der fehlerhaften Pakete bei neun versendeten Paketen“ berechnet werden kann. Beschreiben Sie diesen Zusammenhang inhaltlich. Sie dürfen folgende Identität für alle $n, k \in \mathbb{N}_0$, $k \leq n$ verwenden:

$$\binom{n}{k} = \binom{n}{n-k}$$

Es ist

$$\mathbb{P}(Y_3 = 10) = \binom{9}{7} \cdot 0,4^3 \cdot 0,6^7 = \underbrace{\binom{9}{2} \cdot 0,4^2 \cdot 0,6^7}_{=\mathbb{P}(Z=2) \text{ mit } Z \sim \text{Bin}(9;0,4)} \cdot 0,4 = \mathbb{P}(Z = 2) \cdot 0,4$$

☞ *Begründung:*

Bei einer negativ-binomialverteilten Zufallsvariable ist die Anordnung von Erfolgen und Misserfolgen zum Teil gegeben: der r -te Erfolg findet im y -ten Versuch statt. In dieser Aufgabe berechnen wir die Wahrscheinlichkeit, dass die Anzahl der versendeten Pakete bis zur dritten ($r = 3$) fehlerhaften Glühbirne zehn ($y = 10$) beträgt ($Y_3 = 10$); also wissen wir, dass sich im zehnten Päckchen eine fehlerhafte Glühbirne befinden soll.

Die übrigen zwei ($r - 1$) fehlerhaften Glühbirnen können sich auf die ersten neun Pakete ($y - 1$) verteilen. Das entspricht zwei ($z = 2$) Erfolgen bei neun ($n = 9$) Versuchen mit konstanter Erfolgswahrscheinlichkeit (hier: $\pi = 0,4$) einer binomialverteilten Zufallsvariable Z ; also $\mathbb{P}(Z = 2)$ mit $Z \sim \text{Bin}(9; 0,4)$.

- d) Bestimmen Sie den Erwartungswert der Anzahl der versendeten Glühbirnen bis zum Auftreten der dritten fehlerhaften Glühbirne.

$$\mathbb{E}(Y_3) = \frac{3}{0,4} = 7,5$$

- e) Mit welcher Wahrscheinlichkeit befindet sich im fünften Versandpaket die erste fehlerhafte Glühbirne?

$$\mathbb{P}(Y_1 = 5 = 4 + 1) = \binom{4+1-1}{4} \cdot 0,4^1 \cdot (1 - 0,4)^4 = 0,4 \cdot 0,6^4 \approx 0,0518$$

f) Welcher Verteilung folgt Y_1 noch? Begründen Sie.

Gibt die Zufallsvariable die Anzahl der versendeten Päckchen (*Versuche*) bis zur ersten fehlerhaften Glühbirne (*Erfolg*) an, so ist die Anordnung von nicht-fehlerhaften und fehlerhaften Glühbirnen fest vorgegeben. Der Binomialkoeffizient, welcher die Anzahl der möglichen Anordnungen angibt, ist in diesem Fall 1. Die Berechnungsformel vereinfacht sich zur Formel für geometrisch verteilte Zufallsvariablen.
 $\Rightarrow Y_1 \sim G(0,4)$

g) Mit welcher Wahrscheinlichkeit befinden sich in fünf Paketen mindestens drei fehlerhafte Glühbirnen?

Wir definieren die Zufallsvariable

T : „Anzahl der fehlerhaften Glühbirnen bei fünf versendeten Paketen“

mit $T \sim \text{Bin}(5, 0,4)$. Dann gilt

$$\begin{aligned} \mathbb{P}(T \geq 3) &= 1 - \mathbb{P}(T < 3) \stackrel{T \text{ diskret}}{=} 1 - \mathbb{P}(T \leq 2) \\ &\stackrel{\text{Def. F}}{=} 1 - F(2) \stackrel{\text{Tabelle}}{=} 1 - 0,6826 = 0,3174 \end{aligned}$$


Aufgabe 25 Lösungen

In einer (unendlich) großen Kiste befinden sich (unendlich) viele Schrauben von drei verschiedenen Schraubentypen: Schrauben mit 1 mm, 2 mm und 3 mm Durchmesser.

Für die Zufallsvariable

D : „Durchmesser einer zufällig ausgewählten Schraube in der Kiste (in mm)“

sei die Wahrscheinlichkeitsverteilung gegeben durch:



- a) Definieren Sie aus der Zufallsvariable D drei dichotome Zufallsvariablen E, F, G mit jeweils dem Wertebereich $\{0, 1\}$. Geben Sie jeweils die Verteilung (Verteilungstyp und -parameter) an.

- Wir definieren

$$E := \begin{cases} 1, & \text{falls } D = 1 \text{ (Schraube hat Durchmesser } \mathbf{1} \text{ mm)}, \\ 0, & \text{sonst.} \end{cases}$$

mit Erfolgswahrscheinlichkeit $\pi_E = P(D = 1) = 0,25$; also $E \sim \text{Bernoulli}(0,25)$.

- Wir definieren

$$F := \begin{cases} 1, & \text{falls } D = 2 \text{ (Schraube hat Durchmesser } \mathbf{2} \text{ mm)}, \\ 0, & \text{sonst.} \end{cases}$$

mit Erfolgswahrscheinlichkeit $\pi_F = P(D = 2) = 0,125$; also $F \sim \text{Bernoulli}(0,125)$.

- Wir definieren

$$G := \begin{cases} 1, & \text{falls } D = 3 \text{ (Schraube hat Durchmesser } \mathbf{3} \text{ mm)}, \\ 0, & \text{sonst.} \end{cases}$$

mit Erfolgswahrscheinlichkeit $\pi_G = P(D = 3) = 0,625$; also $G \sim \text{Bernoulli}(0,625)$.

 *Synonyme:*

dichotome Zufallsvariable, binäre Zufallsvariable, Dummy-Variable: Zufallsvariable mit den zwei möglichen Ausprägungen 0 oder 1.

Es werden drei Schrauben zufällig gezogen. Seien

S_k : „Anzahl der gezogenen Schrauben mit Durchmesser k “ für $k \in \{1, 2, 3\}$.

- b) Wie sind die Zufallsvariablen S_1 , S_2 und S_3 **jeweils** und **zusammen** verteilt (Verteilungstyp und -parameter)?

Wir definieren

$$S_1 := \sum_{i=1}^3 E_i, \quad S_2 := \sum_{i=1}^3 F_i, \quad S_3 := \sum_{i=1}^3 G_i.$$

Da E_1, E_2, E_3 bzw. F_1, F_2, F_3 bzw. G_1, G_2, G_3 unabhängige Bernoulli-Zufallsvariablen mit Parameter $\pi_E = 0,25$ bzw. $\pi_F = 0,125$ bzw. $\pi_G = 0,625$ sind, folgt für die Zufallsvariablen S_1 bzw. S_2 bzw. S_3 :

$$S_1 \sim \text{Bin}(3; 0,25), \quad S_2 \sim \text{Bin}(3; 0,125), \quad S_3 \sim \text{Bin}(3; 0,625).$$

Da S_1, S_2, S_3 jeweils binomialverteilt mit dem gleichen Parameter $n = 3$ sind und für deren Erfolgswahrscheinlichkeiten gilt $\pi_1 + \pi_2 + \pi_3 = \pi_E + \pi_F + \pi_G = 1$, folgt für die gemeinsame Verteilung des *Zufallsvektors* $S = (S_1, S_2, S_3)$, dass dieser *multinomialverteilt* ist:

$$S = (S_1, S_2, S_3) \sim M(3; 0,25, 0,125, 0,625)$$

 *Begründung:*

Für S_1 gilt: Die Zufallsvariable E modelliert, ob eine Schraube einen Durchmesser von 1 mm hat, oder nicht. S_1 zählt wie oft E den Wert 1 annimmt, also $S_1 := \sum_{i=1}^3 E_i$. Da die beiden Ausgänge eines Zugs unabhängig von den Ausgängen eines anderen Zugs sind, sind die E_1, E_2, E_3 stochastisch unabhängig. Also folgt $S_1 \sim \text{Bin}(n; \pi_1)$ mit $n = 3$ und $\pi_1 = \pi_E = 0,25$ (Analog für S_2 und S_3).

+ *Zusatz:*

Die Binomialverteilungen der einzelnen S_k entsprechen den Randverteilungen der Multinomialverteilung.

Zusatz: Multinomialverteilung

Der Zufallsvektor $\mathbf{X} = (X_1, \dots, X_k)$, der Werte $(x_1, \dots, x_k) \in \mathbb{N}_0^k$ mit $\sum_{j=1}^k x_j = n$ annimmt und deren Wahrscheinlichkeitsfunktion durch

$$\mathbb{P}(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! \cdots x_k!} \cdot \pi_1^{x_1} \cdots \pi_k^{x_k}$$


für $\pi_1, \dots, \pi_k \in [0, 1]$ mit $\sum_{j=1}^k \pi_j = 1$ gegeben ist, heißt *multinomialverteilt* mit den Parametern $n \in \mathbb{N}$ und $\pi_1, \dots, \pi_k$.

 *Kurzschreibweise:* $\mathbf{X} \sim M(n; \pi_1, \dots, \pi_k)$

▲ Merke: Sind $X_1, \dots, X_k$ Zufallsvariablen mit $X_j \sim \text{Bin}(n; \pi_j)$ für $j = 1, \dots, k$, die aus denselben n Versuchen stammen und die Bedingungen $\sum_{j=1}^k X_j = n$ und $\sum_{j=1}^k \pi_j = 1$ erfüllen, dann bildet der Zufallsvektor $\mathbf{X} = (X_1, \dots, X_k)$ eine multinomialverteilte Zufallsvariable mit Parametern n und $(\pi_1, \dots, \pi_k)$, also $\mathbf{X} \sim M(n; \pi_1, \dots, \pi_k)$.

Zum Beispiel:

$$\mathbf{S} = (S_1, S_2, S_3) \sim M(3; 0,25; 0,125; 0,625)$$



c) Stellen Sie alle möglichen Realisierungen $s = (s_1, s_2, s_3)$ auf.

Es gilt $s = (s_1, s_2, s_3) \in \{(3, 0, 0); (0, 3, 0); (0, 0, 3); (1, 1, 1);$
 $(2, 1, 0); (2, 0, 1); (1, 2, 0); (0, 2, 1); (1, 0, 2); (0, 1, 2)\}$
 Es handelt sich hier also um die Wertemenge des Zufallsvektors $S = (S_1, S_2, S_3)$.

d) Berechnen Sie die Wahrscheinlichkeit, dass man

- i) nur 3 mm Schrauben erhält.
- ii) zwei 1 mm und eine 3 mm Schraube erhält.
- iii) drei Schraubentypen erhält.

$$\text{i) } \mathbb{P}(S = (0, 0, 3)) = \frac{3!}{0! \cdot 0! \cdot 3!} \cdot 0,25^0 \cdot 0,125^0 \cdot 0,625^3 = \frac{125}{512} \approx 0,2441$$


$$\text{ii) } \mathbb{P}(S = (2, 0, 1)) = \frac{3!}{2! \cdot 0! \cdot 1!} \cdot 0,25^2 \cdot 0,125^0 \cdot 0,625^1 = \frac{60}{512} \approx 0,1172$$

$$\text{iii) } \mathbb{P}(S = (1, 1, 1)) = \frac{3!}{1! \cdot 1! \cdot 1!} \cdot 0,25^1 \cdot 0,125^1 \cdot 0,625^1 = \frac{60}{512} \approx 0,1172$$

 *Notation:* Folgende Ausdrücke sind äquivalent: Sei $s \in \mathbb{R}^3, S := (S_1, S_2, S_3)$

$$\begin{aligned} \mathbb{P}((S_1, S_2, S_3) = (s_1, s_2, s_3)) &= \mathbb{P}(S_1 = s_1, S_2 = s_2, S_3 = s_3) \\ &= \mathbb{P}(\{S_1 = s_1\} \cap \{S_2 = s_2\} \cap \{S_3 = s_3\}) \\ &= \mathbb{P}(S = s) = \mathbb{P}(S = (s_1, s_2, s_3)) = \mathbb{P}((S_1, S_2, S_3) = s) \end{aligned}$$

+ *Zusatz:* Visualisierung der Punktwahrscheinlichkeiten



- e) Berechnen Sie die Korrelation zwischen S_2 und S_3 . Begründen Sie, wieso die beiden Zufallsvariablen stochastisch abhängig sind.

Da $S = (S_1, S_2, S_3) \sim M(n; \pi_1, \pi_2, \pi_3)$ mit $n = 3$, $\pi_1 = 0,25$, $\pi_2 = 0,125$ und $\pi_3 = 0,625$ gilt mithilfe der Formel für die (theoretische) Kovarianz von S_2 und S_3 ,

$$\text{Cov}(S_2, S_3) = -n \cdot \pi_2 \cdot \pi_3 = -3 \cdot 0,125 \cdot 0,625 = -\frac{15}{64},$$

und für die (theoretische) Korrelation zwischen S_2 und S_3 ,

$$\rho(S_2, S_3) = \frac{\text{Cov}(S_2, S_3)}{\sqrt{\text{Var}(S_2)} \cdot \sqrt{\text{Var}(S_3)}} = \frac{-\frac{15}{64}}{\sqrt{\frac{21}{64}} \cdot \sqrt{\frac{45}{64}}} = -0,48795,$$

wobei genutzt wurde, dass $S_2 \sim \text{Bin}(3; 0,125)$ und $S_3 \sim \text{Bin}(3; 0,625)$

$$\Rightarrow \text{Var}(S_2) = 3 \cdot 0,125 \cdot (1 - 0,125) = \frac{21}{64}$$

$$\Rightarrow \text{Var}(S_3) = 3 \cdot 0,625 \cdot (1 - 0,625) = \frac{45}{64}$$

Da $\text{Cov}(S_2, S_3) \neq 0$ folgt stochastische Abhängigkeit zwischen S_2 und S_3 .

💡 *Intuition:*

Da jeder Zug einer 2 mm Schraube impliziert, dass keine 3 mm Schraube gezogen wurde, besteht eine stochastische Abhängigkeit zwischen S_2 und S_3 .

- f) Sei Z : „Anzahl der gezogenen unterschiedlichen Schraubentypen“. Skizzieren Sie die Wahrscheinlichkeitsverteilung von Z .

Es ist $Z : \Omega \rightarrow \{1, 2, 3\}$

mit $\Omega = \{(3, 0, 0); (0, 3, 0); (0, 0, 3); (1, 1, 1);$
 $(2, 1, 0); (2, 0, 1); (1, 2, 0); (0, 2, 1); (1, 0, 2); (0, 1, 2)\}$

Es gilt

$$Z(3, 0, 0) = Z(0, 3, 0) = Z(0, 0, 3) = 1 \quad \text{und} \quad Z(1, 1, 1) = 3 \quad \text{und} \\ Z(2, 1, 0) = Z(2, 0, 1) = Z(1, 2, 0) = Z(0, 2, 1) = Z(1, 0, 2) = Z(0, 1, 2) = 2$$


$$\begin{aligned} \mathbb{P}(Z = 1) &= \mathbb{P}(S = (3, 0, 0)) \\ &\quad + \mathbb{P}(S = (0, 3, 0)) \\ &\quad + \mathbb{P}(S = (0, 0, 3)) \\ &= \frac{3!}{3!} \cdot (0,25^3 + 0,125^3 + 0,625^3) = \frac{134}{512} \approx 0,2617 \end{aligned}$$

$$\begin{aligned} \mathbb{P}(Z = 2) &= \mathbb{P}(S = (2, 1, 0)) + \mathbb{P}(S = (2, 0, 1)) \\ &\quad + \mathbb{P}(S = (1, 2, 0)) + \mathbb{P}(S = (0, 2, 1)) \\ &\quad + \mathbb{P}(S = (1, 0, 2)) + \mathbb{P}(S = (0, 1, 2)) \\ &= \frac{3!}{2! \cdot 1!} \left(0,25^2 \cdot 0,125^1 + 0,25^2 \cdot 0,625^1 + 0,25^1 \cdot 0,125^2 + 0,125^2 \cdot 0,625^1 \right. \\ &\quad \left. + 0,25^1 \cdot 0,625^2 + 0,125^1 \cdot 0,625^2 \right) = \frac{318}{512} \approx 0,6211 \end{aligned}$$

$$\mathbb{P}(Z = 3) = \mathbb{P}(S = (1, 1, 1)) = \frac{3!}{1! \cdot 1! \cdot 1!} \cdot 0,25 \cdot 0,125 \cdot 0,625 = \frac{60}{512} \approx 0,1172$$

$$\text{Alternativ: } \mathbb{P}(Z = 3) = 1 - \mathbb{P}(Z = 1) - \mathbb{P}(Z = 2) = 1 - \frac{134}{512} - \frac{318}{512} = \frac{60}{512}$$

Die Wahrscheinlichkeitsfunktion für $Z \in \{1, 2, 3\}$ ist also:



2.5 Stetige Verteilungen

2.5.1 Stetige Gleichverteilung

Aufgabe 26

Teil A

Ein Random-Number-Generator generiert zufällig eine *reelle Zahl* aus dem Intervall $[0, 10]$. Sei

X : „die zufällig generierte Zahl“.

- a) Wie ist die Zufallsvariable X verteilt (Verteilungstyp und -parameter)?
- b) Geben Sie die Dichtefunktion von X an und skizzieren Sie diese.
- c) Prüfen Sie formal, ob es sich bei der Dichtefunktion von X um eine Wahrscheinlichkeitsdichte handelt.
- d) Leiten Sie die Verteilungsfunktion von X formal aus der Dichtefunktion her und skizzieren Sie diese.
- e) Berechnen Sie $F(0)$, $F(10)$ und verbalisieren Sie das Ergebnis im Kontext der Aufgabe.
- f) Berechnen Sie den Erwartungswert und die Varianz von X über die allgemeine *Definition* des Erwartungswertes bzw. der Varianz.
- g) Berechnen Sie die Wahrscheinlichkeit, dass die Zahl
 - i) null ist,
 - ii) mindestens acht ist,
 - iii) mindestens zwei, aber niedriger als neun ist

Markieren Sie die Wahrscheinlichkeiten in der in b) skizzierten Dichtefunktion.

- h) Mit welcher Wahrscheinlichkeit ist die Zahl größer als 8, wenn bekannt ist, dass die Zahl größer als 5 ist.

Teil B

Nehmen sie nun an, dass der Random-Number-Generator eine *ganze Zahl* aus dem Intervall $[0, 10]$ generiert.

- i) Wie ist X nun verteilt (Verteilungstyp und -parameter)? Skizzieren Sie die Wahrscheinlichkeitsfunktion sowie die Verteilungsfunktion von X .

- j) Mit welcher Wahrscheinlichkeit ist die Zahl null? Warum unterscheidet sich dieses Ergebnis von dem in g) i)?

Aufgabe 27

Betrachten Sie die Miethöhe *aller* Berliner Wohnungen mit einer Fläche von 50m². Sei

X : „Miete einer zufällig ausgewählten 50m² Wohnung in Berlin (in EUR)“.

Teil A

Im Folgenden werden zwei verschiedene Szenarien für die Verteilung von X betrachtet: X ist

- i) *stetig gleichverteilt* auf $[800, 2000]$. ii) *einpunktverteilt* auf $x = 1400$.
- a) Ist X eine diskrete oder stetige Zufallsvariable? Skizzieren Sie die Dichte- bzw. Wahrscheinlichkeitsfunktion sowie die Verteilungsfunktion von X für beide Szenarien.
- b) Geben Sie für beide Szenarien das Ereignis A an, für welches $\mathbb{P}(A) = 1$ gilt.

Teil B

Im Folgenden wird die Miethöhe nun in Gruppen eingeteilt. Es ergibt sich folgenden Einteilung:

j	Gruppe j	$\mathbb{P}(X \in \text{Gruppe j})$
1	[800 ; 1000)	0,25
2	[1000 ; 1400)	0,35
3	[1400 ; 1500)	0,20
4	[1500 ; 2000]	0,20

Es werden zwei verschiedene Szenarien für die Verteilung von X *innerhalb einer Gruppe* für alle Gruppen j , $j \in \{1, 2, 3, 4\}$, betrachtet: X ist

- i) *stetig gleichverteilt* innerhalb Gruppe j. ii) *einpunktverteilt* auf der Mitte der Gruppe j.
- c) Skizzieren Sie die neue Dichtefunktion bzw. Wahrscheinlichkeitsfunktion sowie die Verteilungsfunktion von X für beide Szenarien.
- d) Woran erinnert die Form der Dichtefunktion in c)?
- e) Bestimmen Sie den Erwartungswert von X unter der Verteilungsannahme in ii). Interpretieren Sie das Ergebnis im Kontext der Aufgabe.

- f) Es wird eine Stichprobe unter 4000 Berliner Haushalten mit einer Wohnfläche von $50m^2$ erhoben. Die resultierenden relativen Häufigkeiten der Mietpreisklassen können der Tabelle aus *Aufgabe 5 d)* entnommen werden. Erläutern Sie, weshalb diese empirisch ermittelten relativen Häufigkeiten von den in *Teil B* postulierten Gruppenwahrscheinlichkeiten abweichen.


2.5.2 Exponentialverteilung

Aufgabe 28

Auch moderne Server sind von Ausfällen betroffen. Es laufen drei Server gleichzeitig, jedoch ohne sich gegenseitig zu beeinflussen. Server 1 fällt im Durchschnitt alle vier, Server 2 alle acht und Server 3 alle zwanzig Stunden aus. Seien

X_i : „Zeit bis zum Ausfall von Server i (in Std.)“ mit $i \in \{1, 2, 3\}$.

- a) Wie sind die Zufallsvariablen X_1 , X_2 und X_3 verteilt (Verteilungstyp und -parameter)?
 b) Nachstehend sind die Wahrscheinlichkeitsdichten der Zufallsvariablen X_1 , X_2 und X_3 gegeben. Ordnen Sie die Wahrscheinlichkeitsdichten ihrer Zufallsvariable zu.



- c) Zeigen Sie formal, dass es sich bei der Dichtefunktion von X_1 um eine Wahrscheinlichkeitsdichte handelt.
 d) Bestimmen Sie den Erwartungswert und die Varianz von X_1 .
 e) Berechnen Sie die Wahrscheinlichkeit, dass die Zeit bis zum nächsten Ausfall von Server 1
 i) weniger als vier Stunden,
 ii) mehr als sieben Stunden,

- iii) zwischen dreieinhalb und acht Stunden beträgt. Markieren Sie die Wahrscheinlichkeiten in der in b) gegebenen zugehörigen Dichtefunktion.
- f) Mit welcher Wahrscheinlichkeit fällt innerhalb von zehn Stunden mindestens ein Server aus?
- g) Server 1 läuft bereits seit 10 Stunden ohne Ausfall. Mit welcher Wahrscheinlichkeit kommt es innerhalb der nächsten vier Stunden zu einem Ausfall? Vergleichen Sie dieses Ergebnis mit e) i). Auf welche Eigenschaft ist dieser Zusammenhang zurückzuführen?

2.5.3 Normalverteilung

Aufgabe 29

Eine Social-Media-Plattform modelliert die tägliche Screentime ihrer Nutzer, welche in Gruppe 1 und Gruppe 2 unterteilt wurden. Seien


X : „tägliche Screentime eines zufällig ausgewählten Nutzers aus Gruppe 1 (in Std.)“,

Y : „tägliche Screentime eines zufällig ausgewählten Nutzers aus Gruppe 2 (in Std.)“.

Es wird angenommen, dass die Screentime in beiden Gruppen normalverteilt ist. Für beide Gruppen liegt der Erwartungswert der täglichen Nutzungsdauer bei 2,5 Stunden ($\mu_X = \mu_Y$). Die beiden Gruppen unterscheiden sich jedoch in ihrer Streuung σ . Es gelten $\sigma_X = 0,4$ und $\sigma_Y = 0,6$.

Teil A

- a) Geben Sie die Verteilung von X und Y jeweils an (Verteilungstyp und -parameter).
- b) Ordnen Sie die nachstehenden Dichtefunktionen den Zufallsvariablen X und Y zu.



Betrachten Sie nun die folgenden Transformationen der Zufallsvariable X :

$$\text{i) } \tilde{X} := X - \mathbb{E}(X) \qquad \text{ii) } Z := \frac{X - \mathbb{E}(X)}{\sqrt{\text{Var}(X)}}$$

- c) Wie sind die Zufallsvariable $\tilde{X}$ und Z jeweils verteilt (Verteilungstyp- und parameter)? Berechnen Sie hierfür den jeweiligen Erwartungswert und die Varianz. Geben Sie die Dichtefunktion von $\tilde{X}$ und Z explizit an und skizzieren Sie diese in dem Koordinatensystem in b). Wie nennt man diese Transformationen?
- d) Für eine standardnormalverteilte Zufallsvariable Z kann formal gezeigt werden, dass die nachfolgenden Symmetrieeigenschaften gelten:

$$\text{i) } \varphi(z) = \varphi(-z) \quad \text{ii) } \mathbb{P}(Z \leq -z) = \mathbb{P}(Z \geq z) \quad \text{iii) } \Phi(-z) = 1 - \Phi(z)$$

für alle $z \in \mathbb{R}$, wobei φ die Dichtefunktion und Φ die Verteilungsfunktion von Z darstellen. Visualisieren Sie die nachfolgenden Eigenschaften jeweils für den Fall $z = 1$ in den bereitgestellten Skizzen.

- e) Übertragen Sie die in d) gegebenen Symmetrieeigenschaften der Standardnormalverteilung auf eine normalverteilte Zufallsvariablen X . Es ist keine formale Herleitung erforderlich.
- f) Berechnen Sie für einen Nutzer aus Gruppe 1 die Wahrscheinlichkeit, dass die tägliche Screentime
- weniger als 4 Stunden beträgt.
 - mehr als 2 Stunden beträgt.

iii) zwischen 2 und 3 Stunden beträgt.

Veranschaulichen Sie die in iii) berechnete Wahrscheinlichkeit, indem Sie die zugehörige Wahrscheinlichkeitsmasse als Fläche unter der Dichtefunktion von X und Z in b) markieren.

Teil B

Ein Nutzer wird als „Digital Addict“ eingestuft, sofern seine tägliche Screentime das 95te Perzentil der Verteilung X überschreitet. Die Grundgesamtheit setzt sich dabei zu zwei Dritteln aus Nutzern der Gruppe 1 und zu einem Drittel aus Nutzern der Gruppe 2 zusammen.

- g) Berechnen Sie die tägliche Screentime, ab der ein Nutzer als „Digital Addict“ gilt.
- h) Mit welcher Wahrscheinlichkeit gilt ein zufällig ausgewählter Nutzer aus Gruppe 2 als „Digital Addict“?
- i) Mit welcher Wahrscheinlichkeit gilt ein zufällig ausgewählter Nutzer als „Digital Addict“?

Teil C

Es wird angenommen, dass jede studentische Wohngemeinschaft (WG) aus genau drei Personen besteht. Dabei gehören Person 1 und Person 2 der Gruppe 1 an, während Person 3 der Gruppe 2 angehört. Die Mediennutzungsdauer der einzelnen Personen erfolgt unabhängig voneinander. Sei

S : „durchschnittliche tägliche Screentime pro Kopf in einer zufällig ausgewählten WG“.

- j) Wie ist die Zufallsvariable S verteilt (Verteilungstyp und -parameter)?
- k) Mit welcher Wahrscheinlichkeit ist die Screentime von Person 3 größer als die Screentime von Person 1 und 2 zusammen? Definieren Sie hierfür eine neue Zufallsvariable.

Aufgabe 26 Lösungen**Teil A**

Ein Random-Number-Generator generiert zufällig eine *reelle Zahl* aus dem Intervall $[0, 10]$.
Sei


X : „die zufällig generierte Zahl“.

- a) Wie ist die Zufallsvariable X verteilt (Verteilungstyp und -parameter)?

$X \sim \text{Unif}([0; 10])$ wobei $X : \Omega \rightarrow \mathbb{R}$, also ist X eine *stetige* Zufallsvariable.

- b) Geben Sie die Dichtefunktion von X an und skizzieren Sie diese.

Dichtefunktion von X :



$$f(x) = \begin{cases} \frac{1}{10-0} = \frac{1}{10}, & \text{falls } 0 \leq x \leq 10, \\ 0, & \text{sonst.} \end{cases}$$

- c) Prüfen Sie formal, ob es sich bei der Dichtefunktion von X um eine Wahrscheinlichkeitsdichte handelt.

Es gilt zwei Bedingungen zu überprüfen:

i) Nichtnegativität von f , d.h. $f(x) \geq 0$ für alle $x \in \mathbb{R}$.

$\Rightarrow$ Offensichtlich ist i) erfüllt da $f(x) \in \{\frac{1}{10}, 0\}$.

ii) Fläche unter f ist 1, d.h. $\int_{-\infty}^{\infty} f(x) dx = 1$.

$\Rightarrow$ Es gilt $\int_{-\infty}^{\infty} f(x) dx \stackrel{(*)}{=} \int_0^{10} \frac{1}{10} dx = \left[\frac{1}{10}x \right]_0^{10} = \left(\frac{1}{10} \cdot 10 \right) - \left(\frac{1}{10} \cdot 0 \right) = 1$

Damit handelt es sich bei f um eine (Wahrscheinlichkeits-)Dichtefunktion.


💬 *Begründung:*

Der Schritt bei $(*)$ ist erlaubt, da $f(x) = 0$ außerhalb von $[0, 10]$ gilt, sodass sich das Integral über $(-\infty, \infty)$ auf $[0, 10]$ "beschränkt".

- d) Leiten Sie die Verteilungsfunktion von X formal aus der Dichtefunktion her und skizzieren Sie diese.

Verteilungsfunktion von X :

$$F(x) = \begin{cases} 0, & \text{falls } x < 0 \\ \int_0^x \frac{1}{10} dx = \left[\frac{1}{10}x \right]_0^x = \frac{1}{10}x, & \text{falls } 0 \leq x \leq 10, \\ 1, & \text{falls } x > 10 \end{cases}$$



- e) Berechnen Sie $F(0)$, $F(10)$ und verbalisieren Sie das Ergebnis im Kontext der Aufgabe.

$$F(0) \stackrel{(Def.)}{=} \mathbb{P}(X \leq 0) = \frac{1}{10} \cdot 0 = 0 \quad \text{und} \quad F(10) \stackrel{(Def.)}{=} \mathbb{P}(X \leq 10) = \frac{1}{10} \cdot 10 = 1$$

 *Verbalisierung:*

Mit einer Wahrscheinlichkeit von 0 ist die generierte Zahl kleiner gleich 0. Mit einer Wahrscheinlichkeit von 1 ist sie kleiner gleich 10. Daraus folgt, dass die Zahl mit einer Wahrscheinlichkeit von 1 zwischen 0 und 10 liegt.

- f) Berechnen Sie den Erwartungswert und die Varianz von X über die allgemeine *Definition* des Erwartungswertes bzw. der Varianz.

Hier gilt es mit der *Definition* des Erwartungswerts und der Varianz für stetige Zufallsvariablen zu arbeiten.

$$\begin{aligned} \mathbb{E}(X) &= \int_{-\infty}^{\infty} x \cdot f(x) \, dx \stackrel{(*)}{=} \int_0^{10} x \cdot \frac{1}{10} \, dx \\ &= \frac{1}{10} \cdot \int_0^{10} x \, dx = \frac{1}{10} \cdot \left[\frac{1}{2} x^2 \right]_0^{10} = \frac{1}{10} \cdot \left[\left(\frac{1}{2} \cdot 10^2 \right) - \left(\frac{1}{2} \cdot 0^2 \right) \right] = \frac{1}{10} \cdot 50 = 5 \end{aligned}$$

$$\begin{aligned} \text{Var}(X) &= \int_{-\infty}^{\infty} (x - \mathbb{E}(X))^2 \cdot f(x) \, dx \stackrel{(*)}{=} \int_0^{10} (x - \mathbb{E}(X))^2 \cdot \frac{1}{10} \, dx \\ &= \int_0^{10} (x - 5)^2 \cdot \frac{1}{10} \, dx = \frac{1}{10} \int_0^{10} (x^2 - 10x + 25) \, dx \\ &= \frac{1}{10} \cdot \left[\frac{1}{3} x^3 - 5x^2 + 25x \right]_0^{10} \\ &= \frac{1}{10} \left[\left(\frac{1}{3} \cdot 10^3 - 5 \cdot 10^2 + 25 \cdot 10 \right) - \left(\frac{1}{3} \cdot 0^3 - 5 \cdot 0^2 + 25 \cdot 0 \right) \right] = \frac{25}{3} \end{aligned}$$

 *Begründung:*

Der Schritt bei $(*)$ ist erlaubt, da $f(x) = 0$ außerhalb von $[0, 10]$ gilt, sodass sich das Integral über $(-\infty, \infty)$ auf $[0, 10]$ "beschränkt".

g) Berechnen Sie die Wahrscheinlichkeit, dass die Zahl

- i) null ist,
- ii) mindestens acht ist,
- iii) mindestens zwei, aber niedriger als neun ist


Markieren Sie die Wahrscheinlichkeiten in der in b) skizzierten Dichtefunktion.

i) $\mathbb{P}(X = 0) \stackrel{(X \text{ stetig})}{=} 0$ („keine Wahrscheinlichkeitsmasse unter einem Punkt“)

ii) $\mathbb{P}(X \geq 8) = 1 - \mathbb{P}(X < 8) \stackrel{(X \text{ stetig})}{=} 1 - \mathbb{P}(X \leq 8) \stackrel{(\text{Def.})}{=} 1 - F(8) = 1 - \frac{1}{10} \cdot 8 = \frac{2}{10}$

iii) $\mathbb{P}(2 \leq X < 9) = \mathbb{P}(X < 9) - \mathbb{P}(X < 2) \stackrel{(X \text{ stetig})}{=} \mathbb{P}(X \leq 9) - \mathbb{P}(X \leq 2) \stackrel{(\text{Def.})}{=} F(9) - F(2) = \frac{1}{10} \cdot 9 - \frac{1}{10} \cdot 2 = \frac{7}{10}$

Visualisierung:



h) Mit welcher Wahrscheinlichkeit ist die Zahl größer als 8, wenn bekannt ist, dass die Zahl größer als 5 ist.

Gesucht ist die bedingte Wahrscheinlichkeit $\mathbb{P}(X \geq 8 \mid X > 5)$. Da das Ereignis $\{X \geq 8\}$ eine Teilmenge von $\{X > 5\}$ ist, gilt $\{X \geq 8\} \cap \{X > 5\} = \{X \geq 8\}$. Also


$$\mathbb{P}(X \geq 8 \mid X > 5) = \frac{\mathbb{P}(\{X \geq 8\} \cap \{X > 5\})}{\mathbb{P}(X > 5)} = \frac{\mathbb{P}(X \geq 8)}{\mathbb{P}(X > 5)} = \frac{1 - F(8)}{1 - F(5)} = \frac{0,2}{0,5} = 0,4.$$

Teil B

Nehmen sie nun an, dass der Random-Number-Generator eine *ganze Zahl* aus dem Intervall $[0, 10]$ generiert.

- i) Wie ist X nun verteilt (Verteilungstyp und -parameter)? Skizzieren Sie die Wahrscheinlichkeitsfunktion sowie die Verteilungsfunktion von X .

X ist *diskret gleichverteilt* auf $\{0; 1; 2; \dots; 10\}$.



- j) Mit welcher Wahrscheinlichkeit ist die Zahl null? Warum unterscheidet sich dieses Ergebnis von dem in g) i)?

Es gilt $\mathbb{P}(X = 0) = \frac{1}{11}$.

☺ *Begründung:*

Das Ergebnis unterscheidet sich von dem in g) i), da die Zufallsvariable nun diskret ist und die Punktwahrscheinlichkeit damit größer als 0 sein kann.

Aufgabe 27 Lösungen

Betrachten Sie die Miethöhe *aller* Berliner Wohnungen mit einer Fläche von 50m^2 . Sei


X : „Miete einer zufällig ausgewählten 50m^2 Wohnung in Berlin (in EUR)“.

Teil A


Es werden zwei verschiedene Szenarien für die Verteilung von X betrachtet: X ist

- i) *stetig gleichverteilt* auf $[800, 2000]$. ii) *einpunktverteilt* auf $x = 1400$.
- a) Ist X eine diskrete oder stetige Zufallsvariable? Skizzieren Sie die Dichte- bzw. Wahrscheinlichkeitsfunktion sowie die Verteilungsfunktion von X für beide Szenarien.

i) Unter der Annahme einer *stetigen Gleichverteilung* ist X eine *stetige* Zufallsvariable mit der Dichtefunktion:



ii) Unter der Annahme einer *Einpunktverteilung* ist X eine *diskrete* Zufallsvariable mit der Wahrscheinlichkeitsfunktion:



b) Geben Sie für beide Szenarien das Ereignis A an für welches $\mathbb{P}(A) = 1$ gilt.

i) $A := \{X \in [800, 2000]\} = \{800 \leq X \leq 2000\}$


ii) $A := \{X = 1400\}$

💡 *Intuition:*

Ein Ereignis mit der Wahrscheinlichkeit 1 beschreibt das, was **sicher** passiert.

- i) Bei der stetigen Gleichverteilung ist nur bekannt, dass der Wert irgendwo im Intervall liegt. Sicher ist also, dass X zwischen 800 und 2000 landet.
- ii) Bei der Einpunktverteilung gibt es keine Streuung. Sicher ist hier genau die 1400.

Visualisierung:




Teil B

Im Folgenden wird die Miethöhe nun in Gruppen eingeteilt. Es ergibt sich folgenden Einteilung:

j	Gruppe j	$\mathbb{P}(X \in \text{Gruppe } j)$
1	[800 ; 1000)	0,25
2	[1000 ; 1400)	0,35
3	[1400 ; 1500)	0,20
4	[1500 ; 2000]	0,20

Es werden zwei verschiedene Szenarien für die Verteilung von X *innerhalb einer Gruppe* für alle Gruppen j , $j \in \{1, 2, 3, 4\}$, betrachtet: X ist

- i) *stetig gleichverteilt* innerhalb Gruppe j . ii) *einpunktverteilt* auf der Mitte der Gruppe j .
- c) Skizzieren Sie die neue Dichtefunktion bzw. Wahrscheinlichkeitsfunktion sowie die Verteilungsfunktion von X für beide Szenarien.



d) Woran erinnert die Form der Dichtefunktion in c)?

Die Dichtefunktion einer gruppierten Zufallsvariable entspricht, unter der Annahme einer stetigen Gleichverteilung innerhalb der Gruppen, in den horizontalen Linien der Form eines *Histogramms*.

💡 *Intuition:*

Da für die gruppierte Zufallsvariable X innerhalb jeder Klasse/Gruppe eine stetige Gleichverteilung angenommen wird, ist die Dichtefunktion von X innerhalb jeder Gruppe konstant. Das Histogramm stellt die *empirischen Dichtefunktion* (=relative Häufigkeitsfunktion) in der (deskriptiven) Statistik grafisch dar.

✚ *Zusatz:*

Das statistische Erfordernis, dass die Summe aller relativen Häufigkeiten 1 ergeben muss (Prinzip der Flächentreue) übersetzt sich hier direkt in die wahrscheinlichkeitstheoretische Bedingung für Dichtefunktionen: Die Gesamtfläche unter der Funktion muss exakt 1 sein: $\int_{-\infty}^{\infty} x \cdot f(x) dx = 1$.

Die Fläche unter jeder Klasse entspricht genau der Klassenwahrscheinlichkeit (in der WT) bzw. relativen Klassenhäufigkeit (in der deskriptiven Statistik):

$$\text{Fläche} = \underbrace{(g_j - g_{j-1})}_{\text{Breite}} \cdot \underbrace{\tilde{f}_j}_{\text{Höhe}} = \begin{cases} \mathbb{P}(X \in [g_{j-1}, g_j)), & \text{falls } X \text{ Zufallsvariable.} \\ f_j, & \text{falls } X \text{ stat. Merkmal.} \end{cases}$$

e) Bestimmen Sie den Erwartungswert von X unter der Verteilungsannahme in ii). Interpretieren Sie das Ergebnis im Kontext der Aufgabe.

$$\mathbb{E}(X) = 900 \cdot 0,25 + 1200 \cdot 0,35 + 1450 \cdot 0,2 + 1750 \cdot 0,2 = 1285$$

🧩 *Interpretation:*

Wählt man sehr viele $50m^2$ -Wohnungen in Berlin zufällig aus, so ist mit einer durchschnittlichen Miethöhe von circa 1285 EUR pro Wohnung zu rechnen.

- f) Es wird eine Stichprobe unter 4000 Berliner Haushalten mit einer Wohnfläche von $50m^2$ erhoben. Die resultierenden relativen Häufigkeiten der Mietpreisklassen können der Tabelle aus *Aufgabe 5 d)* entnommen werden. Erläutern Sie, weshalb diese ermittelten relativen Häufigkeiten von den in *Teil B* gegebenen Gruppenwahrscheinlichkeiten abweichen.

Wir beobachten:

j	Gruppe j	Teil B	Aufgabe 5 d)
		$\mathbb{P}(X \in \text{Gruppe } j)$	f_j
1	[800 ; 1000)	0,25	0,3
2	[1000 ; 1400)	0,35	0,4
3	[1400 ; 1500)	0,20	0,2
4	[1500 ; 2000]	0,20	0,1

Unter der Annahme, dass es in ganz Berlin mehr als 4000 $50m^2$ -Wohnungen gibt, stellt eine Stichprobe von $n = 4000$ Wohnungen nur einen Ausschnitt der Grundgesamtheit dar. Die beobachteten relativen Häufigkeiten f_j in *dieser einen* Stichprobe weichen aufgrund der zufälligen Auswahl aus der Grundgesamtheit von den zugrundeliegenden Wahrscheinlichkeiten der Grundgesamtheit $\mathbb{P}(X \in \text{Gruppe } j)$ ab. Für $n \rightarrow \infty$ „überdeckt“ die Stichprobe immer mehr die Grundgesamtheit, sodass sich die relativen Häufigkeiten (gemäß dem *Gesetz der großen Zahlen*) den wahren Wahrscheinlichkeiten annähern. Eine exakte Übereinstimmung ist bei endlichem Stichprobenumfang jedoch fast nie gegeben.

Aufgabe 28 Lösungen


Auch moderne Server sind von Ausfällen betroffen. Es laufen drei Server gleichzeitig, jedoch ohne sich gegenseitig zu beeinflussen. Server 1 fällt im Durchschnitt alle vier, Server 2 alle acht und Server 3 alle zwanzig Stunden aus. Seien

X_i : „Zeit bis zum Ausfall von Server i (in Std.)“ mit $i \in \{1, 2, 3\}$.

a) Wie sind die Zufallsvariablen X_1 , X_2 und X_3 verteilt (Verteilungstyp und -parameter)?

$$\begin{aligned} X_1 &\sim \text{Exp}(\lambda_1) \text{ mit } \lambda_1 = \frac{1}{4} = 0,25, & X_2 &\sim \text{Exp}(\lambda_2) \text{ mit } \lambda_2 = \frac{1}{8} = 0,125, \\ X_3 &\sim \text{Exp}(\lambda_3) \text{ mit } \lambda_3 = \frac{1}{20} = 0,05 \end{aligned}$$

b) Nachstehend sind die Wahrscheinlichkeitsdichten der Zufallsvariablen X_1 , X_2 und X_3 gegeben. Ordnen Sie die Wahrscheinlichkeitsdichten ihrer Zufallsvariable zu.



c) Zeigen Sie formal, dass es sich bei der Dichtefunktion von X_1 um eine Wahrscheinlichkeitsdichte handelt.

Es gilt zwei Bedingungen zu überprüfen:

i) $f(x_1) \geq 0$ für alle $x_1 \in \mathbb{R}$ aus Definition von f in b) erfüllt.

$$\begin{aligned} \text{ii) } \int_0^\infty f(x_1) dx_1 &= \int_0^\infty 0,25 \cdot e^{-0,25 \cdot x_1} dx_1 = 0,25 \cdot \int_0^\infty e^{-0,25 \cdot x_1} dx_1 = \\ &= 0,25 \cdot \left[-4e^{-0,25 \cdot x_1} \right]_0^\infty = 0,25 \cdot \left[\underbrace{(-4e^{-0,25 \cdot x_1})}_{\rightarrow 0 \text{ für } x_1 \rightarrow \infty} \right] - \underbrace{(-4e^{-0,25 \cdot 0})}_{=-4} = 0,25 \cdot 4 = 1 \end{aligned}$$

$\Rightarrow$ Damit handelt es sich bei f um eine Wahrscheinlichkeitsdichte.

d) Bestimmen Sie den Erwartungswert und die Varianz von X_1 .

Es gilt für $X \sim \text{Exp}(\lambda)$: $\mathbb{E}(X_1) = \frac{1}{\lambda_1}$ und $\text{Var}(X_1) = \frac{1}{\lambda_1^2}$.

Also hier für $X_1 \sim \text{Exp}(0,25)$: $\mathbb{E}(X_1) = \frac{1}{0,25} = 4$ und $\text{Var}(X_1) = \frac{1}{0,25^2} = 16$.

e) Berechnen Sie die Wahrscheinlichkeit, dass die Zeit bis zum nächsten Ausfall von Server 1

- i) weniger als vier Stunden,
- ii) mehr als sieben Stunden,
- iii) zwischen dreieinhalb und acht Stunden


beträgt. Markieren Sie die Wahrscheinlichkeiten in der in b) gegebenen zugehörigen Dichtefunktion.

$$\text{i) } \mathbb{P}(X_1 < 4) \stackrel{(X_1 \text{ stetig})}{=} \mathbb{P}(X_1 \leq 4) \stackrel{()}{=} 1 - e^{-0,25 \cdot 4} \approx 0,6321$$

$$\text{ii) } \mathbb{P}(X_1 > 7) = e^{-0,25 \cdot 7} \approx 0,1738$$

$$\begin{aligned} \text{iii) } \mathbb{P}(3,5 \leq X_1 \leq 8) &= \mathbb{P}(X_1 \leq 8) - \mathbb{P}(X_1 < 3,5) \\ &\stackrel{(X_1 \text{ stetig})}{=} \mathbb{P}(X_1 \leq 8) - \mathbb{P}(X_1 \leq 3,5) \\ &= 1 - e^{-0,25 \cdot 8} - (1 - e^{-0,25 \cdot 3,5}) = 0,2815 \end{aligned}$$

Visualisierung:



- f) Mit welcher Wahrscheinlichkeit fällt innerhalb von zehn Stunden mindestens ein Server aus?

Wir definieren das Ereignis

$$A := \text{„In den ersten zehn Stunden fällt kein Server aus“},$$

wobei gilt

$$A = \{X_1 > 10\} \cap \{X_2 > 10\} \cap \{X_3 > 10\}.$$

Gesucht ist die Wahrscheinlichkeit des Komplementärereignisses von A , also $\bar{A}$. Unter Ausnutzung der *gemeinsamen Unabhängigkeit* von X_1, X_2 und X_3 gilt nun:

$$\begin{aligned} \mathbb{P}(\bar{A}) &= 1 - \mathbb{P}(A) = 1 - \mathbb{P}(\{X_1 > 10\} \cap \{X_2 > 10\} \cap \{X_3 > 10\}) \\ &= 1 - (\mathbb{P}(X_1 > 10) \cdot \mathbb{P}(X_2 > 10) \cdot \mathbb{P}(X_3 > 10)) \\ &= 1 - (e^{-0,25 \cdot 10} \cdot e^{-0,125 \cdot 10} \cdot e^{-0,05 \cdot 10}) \approx 0,9857. \end{aligned}$$

- g) Server 1 läuft bereits seit 10 Stunden ohne Ausfall. Mit welcher Wahrscheinlichkeit kommt es innerhalb der nächsten vier Stunden zu einem Ausfall? Vergleichen Sie dieses Ergebnis mit e) i). Auf welche Eigenschaft ist dieser Zusammenhang zurückzuführen?

Es gilt

$$\begin{aligned} \mathbb{P}(X_1 \leq 10 + 4 \mid X_1 > 10) &= 1 - \mathbb{P}(X_1 > 14 \mid X_1 > 10) \\ &\stackrel{(\star)}{=} 1 - \mathbb{P}(X_1 > 4) = \mathbb{P}(X_1 \leq 4) \\ &= 1 - e^{-0,25 \cdot 4} \approx 0,6321. \end{aligned}$$

In $(\star)$ wird die Eigenschaft der *Gedächtnislosigkeit der Exponentialverteilung* ausgenutzt. Das Ergebnis ist damit identisch zu e) i).

💡 *Intuition:*

Wenn wir bereits wissen, dass das Ereignis bis zum Zeitpunkt 10 nicht eingetreten ist, „vergisst“ die Exponentialverteilung diese verstrichene Zeit. Die Wahrscheinlichkeit, dass das Ereignis innerhalb der nächsten 4 Zeiteinheiten eintritt, ist also exakt dieselbe wie die Wahrscheinlichkeit, dass es zu Beginn (ab Zeitpunkt 0) innerhalb von 4 Zeiteinheiten eingetreten wäre.

Aufgabe 29 Lösungen

Eine Social-Media-Plattform modelliert die tägliche Screentime ihrer Nutzer, welche in Gruppe 1 und Gruppe 2 unterteilt wurden. Seien

X : „tägliche Screentime eines zufällig ausgewählten Nutzers aus Gruppe 1 (in Std.)“,

Y : „tägliche Screentime eines zufällig ausgewählten Nutzers aus Gruppe 2 (in Std.)“.

Es wird angenommen, dass die Screentime in beiden Gruppen normalverteilt ist. Für beide Gruppen liegt der Erwartungswert der täglichen Nutzungsdauer bei 2,5 Stunden ($\mu_X = \mu_Y$). Die beiden Gruppen unterscheiden sich jedoch in ihrer Streuung σ . Es gelten $\sigma_X = 0,4$ und $\sigma_Y = 0,6$.

Teil A

a) Geben Sie die Verteilung von X und Y jeweils an (Verteilungstyp und -parameter).


$$X \sim \mathcal{N}(\mu; \sigma^2) \text{ mit } \mu = \mu_X = 2,5 \text{ und } \sigma^2 = \sigma_X^2 = 0,4^2 = 0,16$$

$$Y \sim \mathcal{N}(\mu; \sigma^2) \text{ mit } \mu = \mu_Y = 2,5 \text{ und } \sigma^2 = \sigma_Y^2 = 0,6^2 = 0,36$$

 *Notation:*

$$\mu := \mathbb{E}(X) \quad \text{und} \quad \sigma^2 := \text{Var}(X) \quad \text{und} \quad \sigma := \sqrt{\text{Var}(X)}$$

b) Ordnen Sie die nachstehenden Dichtefunktionen den Zufallsvariablen X und Y zu.



Betrachten Sie nun die folgenden Transformationen der Zufallsvariable X :

$$\text{i) } \tilde{X} := X - \mathbb{E}(X) \qquad \text{ii) } Z := \frac{X - \mathbb{E}(X)}{\sqrt{\text{Var}(X)}}$$

- c) Wie sind die Zufallsvariable $\tilde{X}$ und Z jeweils verteilt (Verteilungstyp- und parameter)? Berechnen Sie hierfür den jeweiligen Erwartungswert und die Varianz. Geben Sie die Dichtefunktion von $\tilde{X}$ und Z explizit an und skizzieren Sie diese in dem Koordinatensystem in b). Wie nennt man diese Transformationen?

i) Diese Transformation heißt *Zentrierung* der Zufallsvariable X . Es gilt

$$\begin{aligned} \mathbb{E}(\tilde{X}) &\stackrel{(Def. \tilde{X})}{=} \mathbb{E}(X - \underbrace{\mathbb{E}(X)}_{\text{Konstante}}) = \mathbb{E}(X) - \mathbb{E}(X) = 0 \\ \text{Var}(\tilde{X}) &\stackrel{(Def. \tilde{X})}{=} \text{Var}(X - \underbrace{\mathbb{E}(X)}_{\text{Konstante}}) = \text{Var}(X) \stackrel{a)}{=} 0,16 \end{aligned}$$

Es folgt $\tilde{X} \sim \mathcal{N}(0; 0,16)$. Die Dichtefunktion von $\tilde{X}$ ist

$$f_{\tilde{X}}(\tilde{x}) = \frac{1}{\sqrt{2\pi} \cdot 0,4} \cdot e^{\frac{-\tilde{x}^2}{2 \cdot 0,16}} \quad \text{für alle } \tilde{x} \in \mathbb{R}.$$

ii) Diese Transformation heißt *Standardisierung* der Zufallsvariable X . Sie impliziert die Zentrierung und die Normierung der Zufallsvariable X . Es gilt


$$\begin{aligned} \mathbb{E}(Z) &\stackrel{(Def. Z)}{=} \mathbb{E}\left(\frac{X - \mathbb{E}(X)}{\sqrt{\text{Var}(X)}}\right) \stackrel{c)}{=} \frac{1}{\sqrt{\text{Var}(X)}} \mathbb{E}(\tilde{X}) \stackrel{c)}{=} \frac{1}{\sqrt{\text{Var}(X)}} \cdot 0 = 0 \\ \text{Var}(Z) &\stackrel{(Def. Z)}{=} \text{Var}\left(\frac{X - \mathbb{E}(X)}{\sqrt{\text{Var}(X)}}\right) \stackrel{c)}{=} \frac{1}{\text{Var}(X)} \cdot \text{Var}(\tilde{X}) \stackrel{c)}{=} \frac{\text{Var}(X)}{\text{Var}(X)} = 1 \end{aligned}$$

Es folgt $Z \sim \mathcal{N}(0; 1)$. Die Zufallsvariable ist somit **standardnormalverteilt**. Die Dichtefunktion von Z ist

$$f_Z(z) = \varphi(z) = \frac{1}{\sqrt{2\pi}} \cdot e^{\frac{-z^2}{2}} \quad \text{für alle } z \in \mathbb{R}.$$

(Nebenrechnung: Für die Skizze von f_Z berechnen wir $f_Z(0) = \frac{1}{\sqrt{2\pi}} \approx 0,3989$.)


Skizze zu c):



d) Für eine standardnormalverteilte Zufallsvariable Z kann formal gezeigt werden, dass die nachfolgenden Symmetrieeigenschaften gelten:

$$\text{i) } \varphi(z) = \varphi(-z) \quad \text{ii) } \mathbb{P}(Z \leq -z) = \mathbb{P}(Z \geq z) \quad \text{iii) } \Phi(-z) = 1 - \Phi(z)$$

für alle $z \in \mathbb{R}$, wobei φ die Dichtefunktion und Φ die Verteilungsfunktion von Z darstellen. Visualisieren Sie die nachfolgenden Eigenschaften jeweils für den Fall $z = 1$ in den bereitgestellten Skizzen.



☺ In Worten:

- i) Die Dichte φ ist symmetrisch um 0.
- ii) Spiegelbildlich um 0 liegende Werte sind gleich wahrscheinlich.
- iii) Die Verteilungsfunktion Φ ist punktsymmetrisch um $(0; 0,5)$.

- e) Übertragen Sie die in d) gegebenen Symmetrieeigenschaften der Standardnormalverteilung auf eine normalverteilte Zufallsvariablen X . Es ist keine formale Herleitung erforderlich.

Sei $X \sim \mathcal{N}(\mu, \sigma^2)$, $\mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}^+$, mit Verteilungsfunktion F und zugehöriger Dichtefunktion f . Es gilt für alle $x \geq 0$

- | | |
|---|---|
| i) $f(\mu + x) = f(\mu - x)$ | „Die Dichte f ist (achsen-)symmetrisch um μ .“ |
| ii) $\mathbb{P}(X \leq \mu - x) = \mathbb{P}(X \geq \mu + x)$ | „Alle Werte, die x oder mehr links von μ liegen, haben die gleiche Whk. wie alle Werte, die x oder mehr rechts von μ liegen.“ / „Die Whk., dass X höchstens $x - \mu$ beträgt, ist gleich der Whk., dass X mindestens $x + \mu$ beträgt.“ |
| iii) $F(\mu - x) = 1 - F(\mu + x)$ | „Die VF F ist (punkt-)symmetrisch um $(\mu; 0,5)$.“ |


- f) Berechnen Sie für einen Nutzer aus Gruppe 1 die Wahrscheinlichkeit, dass die tägliche Screentime
- i) weniger als 4 Stunden beträgt.
 - ii) mehr als 2 Stunden beträgt.
 - iii) zwischen 2 und 3 Stunden beträgt.

Veranschaulichen Sie die in iii) berechnete Wahrscheinlichkeit, indem Sie die zugehörige Wahrscheinlichkeitsmasse als Fläche unter der Dichtefunktion von X und Z in b) markieren.

$$\begin{aligned}
 \text{i) } \mathbb{P}(X < 4) &= \mathbb{P}\left(\underbrace{\frac{X - \mathbb{E}(X)}{\sqrt{\text{Var}(X)}}}_{=: Z \text{ mit } Z \sim \mathcal{N}(0,1)} < \frac{4 - \mathbb{E}(X)}{\sqrt{\text{Var}(X)}}\right) \stackrel{\text{c) ii)}}{=} \mathbb{P}\left(Z < \frac{4 - 2,5}{0,4}\right) = \mathbb{P}(Z < 3,75) \\
 &\stackrel{(Z \text{ stetig})}{=} \mathbb{P}(Z \leq 3,75) \stackrel{(\text{Def. } \Phi)}{=} \Phi(3,75) = 0,999912
 \end{aligned}$$

$$\begin{aligned}
 \text{ii) } \mathbb{P}(X > 2) &\stackrel{\text{c) ii)}}{=} \mathbb{P}\left(Z > \frac{2 - 2,5}{0,4}\right) \stackrel{(Z \text{ stetig})}{=} \mathbb{P}(Z \geq -1,25) \\
 &\stackrel{\text{d) ii)}}{=} \mathbb{P}(Z \leq 1,25) \stackrel{(\text{Def. } \Phi)}{=} \Phi(1,25) = 0,894350
 \end{aligned}$$

$$\begin{aligned}
 \text{iii) } \mathbb{P}(2 < X < 3) &\stackrel{\text{c) ii)}}{=} \mathbb{P}\left(\frac{2 - 2,5}{0,4} < Z < \frac{3 - 2,5}{0,4}\right) \stackrel{(Z \text{ stetig})}{=} \mathbb{P}(-1,25 < Z < 1,25) \\
 &\stackrel{(\text{Def. } \Phi)}{=} \Phi(1,25) - \Phi(-1,25) \stackrel{\text{d) iii)}}{=} \Phi(1,25) - [1 - \Phi(1,25)] \\
 &= 2 \cdot \Phi(1,25) - 1 = 2 \cdot 0,894350 - 1 = 0,7887
 \end{aligned}$$



☞ Die Wahrscheinlichkeitsmasse (Fläche) bleibt unter der Transformation einer Zufallsvariable (hier: „Standardisierungs-Transformation“) erhalten, d.h. die Wahrscheinlichkeitsmasse (Fläche) unter Z und X sind beide gleich groß.

✍ *Notation:*

Für eine standardnormalverteilte Zufallsvariable $Z \sim \mathcal{N}(0, 1)$ wird die Verteilungsfunktion $F_Z(z)$ üblicherweise mit $\Phi(z)$ und die zugehörige Dichtefunktion $f_Z(z)$ mit $\varphi(z)$ bezeichnet.

Teil B

Ein Nutzer wird als „Digital Addict“ eingestuft, sofern seine tägliche Screentime das 95te Perzentil der Verteilung von X überschreitet. Die Grundgesamtheit setzt sich dabei zu zwei Dritteln aus Nutzern der Gruppe 1 und zu einem Drittel aus Nutzern der Gruppe 2 zusammen.

g) Berechnen Sie die tägliche Screentime, ab der ein Nutzer als „Digital Addict“ gilt.

Wir definieren analog zu c) ii) $Z := \frac{X-2,5}{0,4}$, wobei für die Realisierungen von Z gilt:

$$z = \frac{x - 2,5}{0,4} \Leftrightarrow x = 2,5 + z \cdot 0,4. \quad (\star)$$

Gesucht ist $x \in \mathbb{R}$, sodass $\mathbb{P}(X \leq x) \stackrel{!}{=} 0,95$. Analog zu c) ii) gilt dann:


$$\mathbb{P}(X \leq x) = 0,95 \stackrel{c) ii)}{\Leftrightarrow} \mathbb{P}(Z \leq z) = 0,95 \Leftrightarrow z = 1,65.$$

Eingesetzt in $(\star)$:

$$x = 2,5 + 1,65 \cdot 0,4 = 3,16.$$

☞ Ab einer täglichen Screentime von 3,16 Stunden (d.h. ca. 3 Stunden und 9 Minuten) gilt ein Nutzer aus Gruppe 1 als „Digital Addict“.

+ Zusatz: Visualisierung



- h) Mit welcher Wahrscheinlichkeit gilt ein zufällig ausgewählter Nutzer aus Gruppe 2 als „Digital Addict“?

$$\begin{aligned}\mathbb{P}(Y \geq 3,16) &\stackrel{c) ii)}{=} \mathbb{P}(Z \geq \frac{3,16-2,5}{0,6}) = \mathbb{P}(Z \geq 1,10) = 1 - \mathbb{P}(Z < 1,10) \\ &\stackrel{(Z \text{ stetig})}{=} 1 - \mathbb{P}(Z \leq 1,10) \stackrel{(\text{Def. } \Phi)}{=} 1 - \Phi(1,10) = 1 - 0,864334 = 0,135666\end{aligned}$$

- i) Mit welcher Wahrscheinlichkeit gilt ein zufällig ausgewählter Nutzer als „Digital Addict“?

Wir definieren die Ereignisse

$D :=$ „Ein zufällig ausgewählter Nutzer ist ein Digital Addict.“

$G_1 :=$ „Ein zufällig ausgewählter Nutzer gehört zu Gruppe 1.“

$G_2 :=$ „Ein zufällig ausgewählter Nutzer gehört zu Gruppe 2.“

Mit dem *Satz der Totalen Wahrscheinlichkeit* gilt nun

$$\mathbb{P}(D) = \mathbb{P}(D|G_1) \cdot \mathbb{P}(G_1) + \mathbb{P}(D|G_2) \cdot \mathbb{P}(G_2),$$

wobei aus der Definition von X_1 und X_2 hervorgeht, dass

$$\mathbb{P}(D|G_1) = \mathbb{P}(X \geq 3,6) \quad \text{und} \quad \mathbb{P}(D|G_2) = \mathbb{P}(Y \geq 3,157)$$

gilt. Es folgt also

$$\begin{aligned}\mathbb{P}(D) &= \mathbb{P}(X \geq 3,6) \cdot \frac{2}{3} + \mathbb{P}(Y \geq 3,157) \cdot \frac{1}{3} \\ &\approx 0,05 \cdot \frac{2}{3} + 0,1357 \cdot \frac{1}{3} \approx 0,0786\end{aligned}$$

Teil C

Es wird angenommen, dass jede studentische Wohngemeinschaft (WG) aus genau drei Personen besteht. Dabei gehören Person 1 und Person 2 der Gruppe 1 an, während Person 3 der Gruppe 2 angehört. Die Mediennutzungsdauer der einzelnen Personen erfolgt unabhängig voneinander. Sei

S : „durchschnittliche tägliche Screentime pro Kopf in einer zufällig ausgewählten WG“.

j) Wie ist die Zufallsvariable S verteilt (Verteilungstyp und -parameter)?

Wir definieren X_i , $i = 1, 2$ als iid „Kopien“ der Zufallsvariable X , also X_i : „tägliche Screentime des i -ten zufällig ausgewählten Nutzers aus Gruppe 1 (in Std.)“. Die Zufallsvariable S kann als Linearkombination von X_1, X_2 und Y beschrieben werden:

$$S := \frac{1}{3}(X_1 + X_2 + Y)$$

Da jede Linearkombination von unabhängigen normalverteilten Zufallsvariablen erneut normalverteilt ist, folgt direkt

$$S \sim \mathcal{N}(\mu_S, \sigma_S^2)$$

mit

$$\begin{aligned} \mu_S &= \mathbb{E}(S) = \mathbb{E}\left(\frac{1}{3}(X_1 + X_2 + Y)\right) = \frac{1}{3}(\mathbb{E}(X_1) + \mathbb{E}(X_2) + \mathbb{E}(Y)) \\ &= \frac{1}{3}(2,5 + 2,5 + 2,5) = 2,5 \quad \text{und} \\ \sigma_S^2 &= \text{Var}(S) = \text{Var}\left(\frac{1}{3}(X_1 + X_2 + Y)\right) \stackrel{(\text{Unabh.})}{=} \frac{1}{9}(\text{Var}(X_1) + \text{Var}(X_2) + \text{Var}(Y)) \\ &= \frac{1}{9}(0,16 + 0,16 + 0,36) = 0,0756. \end{aligned}$$

- k) Mit welcher Wahrscheinlichkeit ist die Screentime von Person 3 größer als die Screentime von Person 1 und 2 zusammen? Definieren Sie hierfür eine neue Zufallsvariable.

Für die Differenz zwischen der Screentime von Person 3 und der gemeinsamen Screentime von Person 1 und 2 definieren wir die Zufallsvariable

$$D := Y - X_1 - X_2.$$

Da D eine Linearkombination von unabhängigen normalverteilten Zufallsvariablen ist folgt, analog zu h),

$$D \sim \mathcal{N}(\mu_D, \sigma_D^2)$$

mit

$$\begin{aligned} \mu_D &= \mathbb{E}(D) = \mathbb{E}(Y - X_1 - X_2) = 2,5 - 2,5 - 2,5 = -2,5 \quad \text{und} \\ \sigma_D^2 &= \text{Var}(D) = \text{Var}(Y - X_1 - X_2) = \text{Var}(Y - 1 \cdot X_1 - 1 \cdot X_2) \\ &\stackrel{(\text{Unabh.})}{=} \text{Var}(Y) + (-1)^2 \cdot \text{Var}(X_1) + (-1)^2 \cdot \text{Var}(X_2) = 0,36 + 0,16 + 0,16 = 0,68. \end{aligned}$$

Gesucht ist die Wahrscheinlichkeit des Ereignisses $\{D > 0\}$:

$$\begin{aligned} \mathbb{P}(D > 0) &\stackrel{c) \text{ ii)}}{=} \mathbb{P}\left(Z > \frac{0 - (-2,5)}{\sqrt{0,68}}\right) \approx \mathbb{P}(Z > 3,03) = 1 - \mathbb{P}(Z \leq 3,03) \\ &\stackrel{(\text{Def. } \Phi)}{=} 1 - \Phi(3,03) = 1 - 0,998777 = 0,001223. \end{aligned}$$

2.6 Asymptotische Verteilungen

Aufgabe 30

Ein Online-Händler weiß, dass 20% der 100 täglich versendeten Pakete als Retouren zurückgesendet werden. Sei

X : „Anzahl der an einem zufällig ausgewählten Tag retournierten Pakete“.

a) Wie ist die Zufallsvariable X

i) exakt,

ii) approximativ

verteilt (Verteilungstyp und -parameter)? Prüfen Sie die Approximationskriterien.

b) Wie groß ist die Wahrscheinlichkeit, dass genau 20 Pakete retourniert werden nach der exakten **und** approximativen Verteilung? Um wie viel Prozent überschätzt die Approximation die wahre Wahrscheinlichkeit?

c) Mit welcher approximativen Wahrscheinlichkeit werden mehr als 30% der Pakete retourniert? Berechnen Sie die Wahrscheinlichkeit einmal mit **und** einmal ohne Stetigkeitskorrektur.

Aufgabe 31

In einem Berliner Bezirk werden pro Stunde durchschnittlich 30 Fahrten eines Car-Sharing Unternehmens beendet. Sei

X : „Anzahl der in einer zufällig ausgewählten Stunde beendeten Fahrten“.

a) Wie ist die Zufallsvariable X

i) exakt,

ii) approximativ

verteilt (Verteilungstyp und -parameter)? Prüfen Sie die Approximationskriterien.

b) Wie groß ist die Wahrscheinlichkeit, dass genau 30 Fahrten beendet werden nach der exakten **und** approximativen Verteilung?

c) Mit welcher approximativen Wahrscheinlichkeit werden zwischen 25 und 35 Fahrten beendet? Berechnen Sie die Wahrscheinlichkeit einmal mit **und** einmal ohne Stetigkeitskorrektur.

Aufgabe 30 Lösungen

Ein Online-Händler weiß, dass 20% der 100 täglich versendeten Pakete als Retouren zurückgesendet werden. Sei

X : „Anzahl der an einem zufällig ausgewählten Tag retournierten Pakete“.

a) Wie ist die Zufallsvariable X

i) exakt,

ii) approximativ

verteilt (Verteilungstyp und -parameter)? Prüfen Sie die Approximationskriterien.

i) Exakt gilt $X \sim \text{Bin}(n; \pi)$ mit $n = 100$ und $\pi = 0,2$.

ii) Approximativ gilt $X \stackrel{\text{appr.}}{\sim} \mathcal{N}(\mu; \sigma^2)$ mit $\mu = n \cdot \pi = 100 \cdot 0,2 = 20$ und $\sigma^2 = n \cdot \pi \cdot (1 - \pi) = 100 \cdot 0,2 \cdot 0,8 = 16$. Die Normal-Approximation ist zulässig, da $n \cdot \pi = 20 \geq 5$ und $n \cdot (1 - \pi) = 80 \geq 5$ erfüllt ist.

b) Wie groß ist die Wahrscheinlichkeit, dass genau 20 Pakete retourniert werden nach der exakten **und** approximativen Verteilung? Um wie viel Prozent überschätzt die Approximation die wahre Wahrscheinlichkeit?

$$\text{Exakt: } \mathbb{P}(X = 20) = \binom{100}{20} \cdot 0,2^{20} \cdot 0,8^{80} \approx 0,0993$$

Approximativ (über die Stetigkeitskorrektur (SK)):

$$\begin{aligned} \mathbb{P}(X = 20) &\stackrel{(\text{SK})}{=} \mathbb{P}(19,5 \leq X \leq 20,5) = \mathbb{P}\left(\frac{19,5-20}{\sqrt{16}} \leq Z \leq \frac{20,5-20}{\sqrt{16}}\right) \\ &\stackrel{(Z \text{ stetig})}{=} \mathbb{P}\left(-\frac{1}{8} < Z \leq \frac{1}{8}\right) \stackrel{(\text{Def. } \Phi)}{=} \Phi\left(\frac{1}{8}\right) - \Phi\left(-\frac{1}{8}\right) = \Phi\left(\frac{1}{8}\right) - (1 - \Phi\left(\frac{1}{8}\right)) \\ &\approx 2 \cdot \Phi(0,13) - 1 = 2 \cdot 0,551717 - 1 = 0,103434 \approx 0,1034 \end{aligned}$$

☞ Die Approximation überschätzt die wahre Wahrscheinlichkeit um

$$\frac{0,1034 - 0,0993}{0,0993} \cdot 100 \approx 4,13\%.$$

- c) Mit welcher approximativen Wahrscheinlichkeit werden mehr als 30% der Pakete retourniert? Berechnen Sie die Wahrscheinlichkeit einmal mit **und** einmal ohne Stetigkeitskorrektur.

Mit Stetigkeitskorrektur:

$$\begin{aligned}\mathbb{P}(X > 30) &\stackrel{(\text{SK})}{=} \mathbb{P}(X > 29,5) = \mathbb{P}\left(Z > \frac{29,5-20}{\sqrt{16}}\right) \approx \mathbb{P}(Z > 2,38) \\ &= 1 - \mathbb{P}(Z \leq 2,38) \stackrel{(\text{Def.}\Phi)}{=} 1 - \Phi(2,38) = 1 - 0,991344 = 0,008656\end{aligned}$$

Ohne Stetigkeitskorrektur:

$$\begin{aligned}\mathbb{P}(X > 30) &= \mathbb{P}\left(Z > \frac{30-20}{\sqrt{16}}\right) = \mathbb{P}(Z > 2,5) \\ &= 1 - \mathbb{P}(Z \leq 2,5) \stackrel{(\text{Def.}\Phi)}{=} 1 - \Phi(2,5) = 1 - 0,993790 = 0,00621\end{aligned}$$

Aufgabe 31 Lösungen

In einem Berliner Bezirk werden pro Stunde durchschnittlich 30 Fahrten eines Car-Sharing Unternehmens beendet. Sei

X : „Anzahl der in einer zufällig ausgewählten Stunde beendeten Fahrten“.

- a) Wie ist die Zufallsvariable X

i) exakt,

ii) approximativ

verteilt (Verteilungstyp und -parameter)? Prüfen Sie die Approximationskriterien.

i) Exakt gilt $X \sim \text{Poi}(\lambda)$ mit $\lambda = 30$.

ii) Approximativ gilt $X \stackrel{\text{appr.}}{\sim} \mathcal{N}(\mu; \sigma^2)$ mit $\mu = \sigma^2 = \lambda = 30$.

Die Normal-Approximation ist zulässig, da $\lambda = 30 \geq 5$ erfüllt ist.

- b) Wie groß ist die Wahrscheinlichkeit, dass genau 30 Fahrten beendet werden nach der exakten **und** approximativen Verteilung?

Exakt: $\mathbb{P}(X = 30) = \frac{30^{30}}{30!} \cdot e^{-30} \approx 0,0726$

Approximativ (über die Stetigkeitskorrektur (SK)):

$$\begin{aligned} \mathbb{P}(X = 30) &\stackrel{(\text{SK})}{=} \mathbb{P}(29,5 \leq X \leq 30,5) = \mathbb{P}\left(\frac{29,5-30}{\sqrt{30}} \leq Z \leq \frac{30,5-30}{\sqrt{30}}\right) \\ &= \mathbb{P}(-0,09 \leq Z \leq 0,09) \stackrel{(Z \text{ stetig})}{=} \mathbb{P}(-0,09 < Z \leq 0,09) \\ &\stackrel{(\text{Def. } \Phi)}{=} \Phi(0,09) - \Phi(-0,09) = \Phi(0,09) - (1 - \Phi(0,09)) \\ &= 2 \cdot \Phi(0,09) - 1 = 2 \cdot 0,535856 - 1 = 0,071712 \end{aligned}$$

- c) Mit welcher approximativen Wahrscheinlichkeit werden zwischen 25 und 35 Fahrten beendet? Berechnen Sie die Wahrscheinlichkeit einmal mit **und** einmal ohne Stetigkeitskorrektur.

Mit Stetigkeitskorrektur:

$$\begin{aligned} \mathbb{P}(25 \leq X \leq 35) &\stackrel{(\text{SK})}{=} \mathbb{P}(24,5 \leq X \leq 35,5) = \mathbb{P}\left(\frac{24,5-30}{\sqrt{30}} \leq X \leq \frac{35,5-30}{\sqrt{30}}\right) \\ &\approx \mathbb{P}(-1 \leq X \leq 1) \stackrel{(Z \text{ stetig})}{=} \mathbb{P}(-1 < X \leq 1) \stackrel{(\text{Def. } \Phi)}{=} \Phi(1) - \Phi(-1) \\ &= \Phi(1) - (1 - \Phi(1)) = 2 \cdot \Phi(1) - 1 = 2 \cdot 0,841345 - 1 = 0,68269 \end{aligned}$$

Ohne Stetigkeitskorrektur:

$$\begin{aligned} \mathbb{P}(25 \leq X \leq 35) &= \mathbb{P}\left(\frac{25-30}{\sqrt{30}} \leq X \leq \frac{35-30}{\sqrt{30}}\right) \approx \mathbb{P}(-0,91 \leq X \leq 0,91) \\ &\stackrel{(Z \text{ stetig})}{=} \mathbb{P}(-0,91 < X \leq 0,91) \stackrel{(\text{Def. } \Phi)}{=} \Phi(0,91) - \Phi(-0,91) \\ &= \Phi(0,91) - (1 - \Phi(0,91)) = 2 \cdot \Phi(0,91) - 1 \\ &= 2 \cdot 0,818589 - 1 = 0,637178 \end{aligned}$$